MỤC LỤC

MỤC LỤC i
DANH MỤC HÌNH ẢNH iv
DANH MỤC BẢNG BIỂU v
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT vi
LỜI CẢM ƠN 1
LỜI MỞ ĐẦU 2
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI 3
1.1. Giới thiệu đề tài 3
1.2. Tính cấp thiết của đề tài 3
1.3. Mục tiêu nghiên cứu 5
1.3.1. Mục tiêu tổng quát 5
1.3.2. Mục tiêu kỹ thuật cụ thể 5
1.4. Nội dung nghiên cứu và phương pháp tiếp cận 6
1.4.1. Nội dung nghiên cứu 6
1.4.2. Phương pháp tiếp cận 6
1.5. Phạm vi và đối tượng nghiên cứu 6
1.6. Bố cục của báo cáo đồ án tốt nghiệp 7
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ 9
2.1. Kiến trúc phần mềm lục giác (Hexagonal Architecture) 9
2.1.1. Nguyên lý phân tầng Ports and Adapters 9
2.1.2. Luận giải lựa chọn Kiến trúc Lục giác cho VeriScholar 10
2.2. Cơ chế truy xuất kết hợp (Hybrid Search) và Thuật toán RRF 11
2.2.1. Nguyên lý tìm kiếm ngữ nghĩa Dense Vector và tìm kiếm từ khóa Sparse BM25 11
2.2.2. Thuật toán Hợp nhất Xếp hạng Đảo ngược (Reciprocal Rank Fusion – RRF) 12
2.2.3. Bóc tách tài liệu hai cột và Chuẩn hóa hệ tọa độ Bounding Box [0..1000] 12
2.3. Mạng tri thức học thuật 4 thực thể (GraphRAG) 14
2.3.1. Mô hình hóa mạng lưới tri thức 4 thực thể cốt lõi 14
2.3.2. Luận giải tích hợp GraphRAG trên PostgreSQL pgvector 14

2.4. Máy trạng thái tác nhân AI và Môi trường thực thi đám mây 16
2.4.1. Mô hình Tác nhân AI Độc lập (Autonomous Agent) 16
2.4.2. Luận giải lựa chọn môi trường E2B Sandbox MicroVM..... 17
2.5. Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK). 18
2.5.1. Nguyên lý lưu trữ định danh nội dung (CAS) và mã hóa xác thực AEAD..... 18
2.5.2. Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar 19
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG..... 20
3.1. Khảo sát quy trình nghiệp vụ và mô hình hóa bài toán thực tế..... 20
3.1.1. Bối cảnh nghiên cứu khoa học tại VinUniversity..... 20
3.1.2. Phân tích quy trình nghiên cứu truyền thống (Luồng AS-IS)..... 20
3.1.3. Mô hình quy trình nghiên cứu đề xuất (Luồng TO-BE) 21
3.2. Phân rã năng lực chức năng và Đặc tả ca sử dụng cốt lõi..... 22
3.2.1. Xác định các tác nhân và vai trò tương tác 22
3.2.2. Mô hình phân rã khối năng lực hệ thống toàn trình 23
3.2.3. Đặc tả chi tiết các ca sử dụng cốt lõi 23
3.3. Thiết kế kiến trúc suy luận và Vết thực thi tác nhân..... 27
3.3.1. Lưu đồ quyết định tự phản biện và Vòng lặp phản hồi đóng 27
3.3.2. Vết thực thi tác nhân tương tác đa bước (Agent Execution Trace) 27
3.4. Thiết kế cơ sở dữ liệu và Lược đồ thực thể tri thức..... 29
3.4.1. Lược đồ thực thể tri thức và Dòng chảy dữ liệu học thuật 29
3.4.2. Từ điển dữ liệu cho các bảng cơ sở dữ liệu cốt lõi 29
CHƯƠNG 4: CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM 32
4.1. Môi trường cài đặt và Kiến trúc Monorepo 32
4.1.1. Cấu hình môi trường phần cứng và phần mềm 32
4.1.2. Kiến trúc kho mã nguồn Monorepo và rào chắn kiểm thử ranh giới AST 33
4.2. Giao diện các phân hệ chính của VeriScholar 34
4.2.1. Phân hệ Khám phá tài liệu khoa học 34
4.2.2. Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box 34
4.2.3. Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân 35
4.3. Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh..... 35
4.3.1. Quy trình kiểm thử 4 Cổng bắt buộc 35
4.3.2. Kết quả kiểm tra độ tin cậy 36

4.4. Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud..... 36
4.4.1. Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên..... 36
4.4.2. Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX 37
4.4.3. Nhật ký kiểm chứng thực tế trên Langfuse Cloud..... 37
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 38
TÀI LIỆU THAM KHẢO..... 40

DANH MỤC HÌNH ẢNH

2.1 Mô hình phân rã module và cấu trúc Cổng – Điều hợp (Ports and Adapters) …… 10
2.2 Mô hình luồng dữ liệu truy xuất lai (Dual-Stream Hybrid RAG Dataflow) chuẩn mực…… 13
2.3 Mô hình đồ thị tri thức học thuật 4 thực thể cốt lõi (GraphRAG) …. 15
2.4 Mô hình Kiến trúc Tư duy Tác nhân AI Độc lập (LLM-Powered Autonomous Agent) …… 17

3.1 Mô hình đối chiếu chuyển đổi quy trình nghiên cứu khoa học AS-IS và TO-BE…… 22
3.2 Mô hình phân rã cấu trúc năng lực chức năng của hệ thống VeriScholar 23
3.3 Lưu đồ Quyết định Tự phản biện và Vòng lặp Tự sửa lỗi (Self-Reflective Loop) …… 28
3.4 Vết Thực thi Tác nhân Tương tác Đa bước (Multi-Step Agent Execution Trace) …… 28
3.5 Lược đồ thực thể tri thức và Dòng chảy dữ liệu học thuật trong hệ thống …… 30

DANH MỤC BẢNG BIỂU

2.1 So sánh đặc tính kỹ thuật giữa các giải pháp truy xuất tài liệu khoa học…… 13

3.1 Bảng đặc tả chi tiết ca sử dụng UC-01 (Khám phá bài báo học thuật hai tầng tin cậy) …… 24
3.2 Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ) …… 25
3.3 Bảng đặc tả chi tiết ca sử dụng UC-06 (Tác nhân tự sửa lỗi bản thảo LaTeX) …… 26
3.4 Đặc tả cấu trúc từ điển dữ liệu bảng `document_chunks` …… 30
3.5 Đặc tả cấu trúc từ điển dữ liệu bảng `document_storage_blobs`…. 30
3.6 Đặc tả cấu trúc từ điển dữ liệu bảng `user_secrets` …… 31

4.1 Cấu trúc phân vùng kho mã nguồn Monorepo và quy tắc ranh giới kiến trúc …… 35
4.2 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh …… 36

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
ACID	Atomicity, Consistency, Isolation, Durability	Bốn thuộc tính toàn vẹn giao dịch cơ sở dữ liệu
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
ASGI	Asynchronous Server Gateway Interface	Giao diện cổng máy chủ bất đồng bộ Python
BBox	Bounding Box	Khung hộp chữ nhật định vị tọa độ
BM25	Best Matching 25	Thuật toán xếp hạng tìm kiếm từ khóa toàn văn
BYOK	Bring Your Own Key	Cơ chế người dùng tự cung cấp khóa API cá nhân
CAS	Content-Addressable Storage	Hệ thống lưu trữ định danh theo nội dung băm
CI/CD	Continuous Integration / Continuous Deployment	Tích hợp và Triển khai liên tục
CTE	Common Table Expression	Bảng biểu thức chung trong truy vấn SQL đệ quy
DOI	Digital Object Identifier	Định danh đối tượng kỹ thuật số bài báo khoa học
ERD	Entity-Relationship Diagram	Sơ đồ quan hệ thực thể cơ sở dữ liệu
FTS	Full-Text Search	Tìm kiếm toàn văn cơ sở dữ liệu
GIN	Generalized Inverted Index	Chỉ mục đảo tổng quát trong PostgreSQL
GraphRAG	Graph Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất qua đồ thị

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
HNSW	Hierarchical Navigable Small World	Cấu trúc đồ thị chỉ mục tìm kiếm vector gần đúng
IoU	Intersection over Union	Chỉ số trùng khớp diện tích hộp tọa độ
JWT	JSON Web Token	Chuỗi mã định danh phiên người dùng an toàn
LLM	Large Language Model	Mô hình ngôn ngữ lớn
ORCID	Open Researcher and Contributor ID	Mã định danh học giả quốc tế 16 số
PDF	Portable Document Format	Định dạng tài liệu số di động
RAG	Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất thông tin
ReAct	Reason + Act	Chu trình AI: Suy luận và Thực thi hành động
RRF	Reciprocal Rank Fusion	Thuật toán hợp nhất xếp hạng đảo ngược
SHA-256	Secure Hash Algorithm 256-bit	Thuật toán băm mật mã an toàn 256 bit
SSE	Server-Sent Events	Giao thức truyền sự kiện thời gian thực từ máy chủ
TDD	Test-Driven Development	Phương pháp phát triển hướng kiểm thử
TTFT	Time To First Token	Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu
UML	Unified Modeling Language	Ngôn ngữ mô hình hóa thống nhất

LỜI CẢM ƠN

Để hoàn thành bản đồ án tốt nghiệp đại học này, trước hết em xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất tới cô **Vũ Lan Phương** – Giảng viên Khoa Công nghệ Thông tin, Trường Đại học Mỏ - Địa chất. Cô đã trực tiếp định hướng đề tài, tận tình chỉ bảo, đóng góp nhiều ý kiến học thuật và chuyên môn quý báu, cũng như luôn tạo mọi điều kiện thuận lợi nhất để em nghiên cứu và hiện thực hóa các công nghệ trí tuệ nhân tạo hiện đại vào nền tảng **VeriScholar**.

Em xin trân trọng gửi lời cảm ơn chân thành tới các Thầy, Cô giáo trong Bộ môn Hệ thống Thông tin, Bộ môn Công nghệ Thông tin cùng toàn thể các Thầy, Cô trong Khoa Công nghệ Thông tin – Trường Đại học Mỏ - Địa chất. Những tri thức nền tảng vững chắc, phương pháp luận nghiên cứu khoa học cùng sự dạy dỗ tâm huyết của các Thầy, Cô trong suốt những năm tháng học tập và rèn luyện trên giảng đường đại học chính là hành trang quý giá giúp em hoàn thành công trình tốt nghiệp này.

Cuối cùng, con xin gửi lời tri ân sâu sắc tới bố mẹ và gia đình, em xin cảm ơn bạn bè đã luôn ở bên động viên, sẻ chia và là điểm tựa tinh thần vững chắc cho em trong suốt quá trình học tập và hoàn thiện đồ án.

Dù đã nỗ lực hết mình để nghiên cứu, xây dựng hệ thống và biên soạn báo cáo một cách khoa học, cẩn trọng nhất, song do giới hạn về thời gian và kinh nghiệm thực tiễn, đồ án chắc chắn khó tránh khỏi những thiếu sót nhất định. Em kính mong nhận được những ý kiến đóng góp, chỉ dẫn quý báu từ quý Thầy, Cô trong Hội đồng chấm đồ án tốt nghiệp để công trình được hoàn thiện hơn nữa.

Hà Nội, tháng 10 năm 2026

Sinh viên thực hiện

Đàm Mạnh Dũng

LỜI MỞ ĐẦU

Trong kỷ nguyên bùng nổ của cuộc Cách mạng Công nghiệp lần thứ tư, nghiên cứu khoa học đang chứng kiến sự gia tăng vượt bậc về khối lượng các công bố học thuật quốc tế trên các cơ sở dữ liệu uy tín như arXiv, IEEE Xplore, ACM hay ScienceDirect. Thực tế này tạo áp lực lớn cho học giả, giảng viên và sinh viên trong việc sàng lọc, đọc hiểu chuyên sâu và tổng hợp tri thức chuyên ngành.

Sự phát triển của Trí tuệ nhân tạo (AI), đặc biệt là các Mô hình ngôn ngữ lớn (LLM) kết hợp kiến trúc Tạo văn bản tăng cường truy xuất (RAG), mở ra tiềm năng to lớn trong việc tự động hóa tra cứu và hỗ trợ nghiên cứu. Tuy nhiên, khi ứng dụng vào môi trường học thuật đòi hỏi độ tin cậy tuyệt đối, người dùng thường đối mặt với rào cản mang tên: **hiện tượng ảo giác trích dẫn (Citation Hallucination)**. Các mô hình hiện nay thường tự tạo trích dẫn không có thật hoặc không thể chỉ rõ bằng chứng tọa độ nằm ở đoạn văn, bảng biểu hay trang nào trong bản tài liệu gốc PDF.

Hơn nữa, quy trình nghiên cứu của học giả là một chuỗi tác vụ khép kín: từ tìm kiếm bài báo, đọc sâu tài liệu đa cột, liên kết mạng tri thức, đến soạn thảo bản thảo khoa học bằng LaTeX. Các công cụ hiện có còn rời rạc: trình đọc tài liệu thiếu khả năng trích xuất hộp tọa độ; thư viện tài liệu thiếu liên kết đồ thị tri thức; còn trình soạn thảo văn bản học thuật lại đòi hỏi người viết tự xử lý các lỗi cú pháp biên dịch phức tạp.

Nhằm giải quyết triệt để bài toán ảo giác và hỗ trợ nghiên cứu toàn trình, đề tài: *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* (sản phẩm: **VeriScholar**) được lựa chọn thực hiện. Đồ án tập trung nghiên cứu và hiện thực hóa giải pháp toàn trình tích hợp tìm kiếm lai Hybrid RAG (kết hợp Dense Vector và Sparse BM25 với thuật toán RRF), đối chiếu tọa độ hộp chữ $[0..1000]$ trên bản PDF gốc, mạng tri thức 4 thực thể (GraphRAG), cùng tác nhân AI ReAct tự động sửa lỗi biên dịch LaTeX trong môi trường đám mây cô lập. Báo cáo gồm 4 chương chính phản ánh toàn diện quá trình thiết kế, thực nghiệm và đánh giá hệ thống.

CHƯƠNG 1

TỔNG QUAN VỀ ĐỀ TÀI

1.1 Giới thiệu đề tài

Đề tài tốt nghiệp *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* được nghiên cứu và hiện thực hóa thông qua hệ thống phần mềm **VeriScholar**.

Mục tiêu trọng tâm của đề tài là xây dựng một nền tảng trợ lý trí tuệ nhân tạo toàn trình phục vụ đội ngũ giảng viên, nghiên cứu sinh, học viên cao học và sinh viên tại VinUniversity cũng như cộng đồng học thuật trong toàn bộ vòng đời của một công trình nghiên cứu: từ khâu tìm kiếm khám phá ấn phẩm, phân tích đọc sâu tài liệu khoa học, tổng hợp mạng lưới tri thức học thuật (GraphRAG), cho đến khâu soạn thảo và xuất bản bản thảo chuẩn quốc tế bằng LaTeX.

Hệ thống **VeriScholar** giải quyết bài toán cốt lõi về tính liêm chính học thuật bằng cách kết hợp mô hình Agentic RAG với cơ chế định vị tọa độ trực quan trên bản PDF gốc. Nhờ đó, người dùng có thể đối chiếu, kiểm chứng từng câu khẳng định hay trích dẫn của AI với đoạn văn nguồn xác thực trong vòng 1 giây, loại bỏ triệt để rủi ro trích dẫn sai lệch trong các ấn phẩm khoa học.

1.2 Tính cấp thiết của đề tài

Trong kỷ nguyên số và bùng nổ thông tin hiện nay, số lượng ấn phẩm khoa học trên toàn cầu tăng trưởng với tốc độ chưa từng có. Mỗi tuần có hàng nghìn bài báo mới xuất hiện trên các cơ sở dữ liệu học thuật quốc tế uy tín như arXiv, Semantic Scholar, IEEE Xplore hay ACM Digital Library. Việc tiếp cận, đọc hiểu, phân loại và tổng hợp tri thức từ kho tài liệu khổng lồ này đặt ra áp lực quá tải thông tin rất lớn đối với các nhà nghiên cứu và sinh viên đại học.

Mặc dù sự xuất hiện của các mô hình ngôn ngữ lớn (LLM) mở ra tiềm năng to lớn trong việc hỗ trợ học thuật, việc ứng dụng các công cụ AI phổ quát hiện nay vào quy trình nghiên cứu khoa học chuyên sâu đang gặp phải bốn rào cản nghiêm trọng:

(1) Ảo giác trích dẫn và bịa đặt học thuật (*Citation Hallucination*): Các mô hình AI tạo sinh thông thường có xu hướng tự sáng tác ra tên tác giả, số định

danh DOI, tên tạp chí và các số liệu thực nghiệm không có thật để trả lời câu hỏi của người dùng. Trong nghiên cứu khoa học, việc trích dẫn một nguồn tài liệu không tồn tại là vi phạm nghiêm trọng chuẩn mực liêm chính học thuật và đạo đức nghiên cứu [7].

(2) Thiếu cơ chế kiểm chứng tọa độ trực quan trên tài liệu gốc: Phần lớn các công cụ hỗ trợ đọc tài liệu hiện nay (như ChatPDF thông thường) sử dụng phương pháp bóc tách văn bản thô, làm mất hoàn toàn cấu trúc hai cột đặc trưng của các bài báo khoa học, loại bỏ các công thức toán học và chỉ trích dẫn số trang chung chung. Người nghiên cứu không thể xác minh được khẳng định của AI nằm chính xác tại dòng chữ nào, đoạn văn nào trên trang PDF gốc.

(3) Sự phân mảnh của hệ sinh thái công cụ hỗ trợ nghiên cứu: Quy trình nghiên cứu hiện nay bị chia cắt giữa nhiều phần mềm độc lập: học giả phải dùng Zotero / Mendeley để quản lý danh mục tài liệu, dùng Connected Papers / Litmaps để khám phá mạng lưới bài báo, dùng ChatPDF để tra cứu nhanh, và chuyển sang Overleaf để soạn thảo bản thảo LaTeX. Sự thiếu liên kết này làm đứt gãy mạch tư duy và tiêu tốn đáng kể thời gian chuyển đổi ngữ cảnh của nhà nghiên cứu.

(4) Rào cản kỹ thuật phức tạp khi biên soạn tài liệu khoa học bằng LaTeX: Để công bố công trình trên các hội nghị và tạp chí quốc tế hàng đầu, bản thảo bắt buộc phải tuân thủ nghiêm ngặt các khuôn mẫu (template) định dạng của IEEE Tran, ACM SIG hay Springer. Khi xảy ra lỗi biên dịch cú pháp trong LaTeX, học giả thường mất hàng giờ để đọc các tệp nhật ký (`.log`) dài hàng nghìn dòng để dò tìm lỗi thủ công, làm giảm đáng kể hiệu suất hoàn thiện bài báo.

Xuất phát từ các yêu cầu thực tiễn cấp bách đó, việc nghiên cứu và xây dựng một nền tảng trợ lý AI chuyên biệt, có khả năng đối chiếu bằng chứng tọa độ trực quan trên bản PDF gốc, xây dựng đồ thị tri thức 4 thực thể và tự động sửa lỗi biên dịch bản thảo LaTeX là một đòi hỏi vô cùng cấp thiết nhằm nâng cao năng suất và chất lượng công bố khoa học quốc tế, đáp ứng đầy đủ quy chế đào tạo đại học và định hướng ứng dụng công nghệ thông tin tiên tiến [1, 2].

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Xây dựng thành công nền tảng phần mềm **VeriScholar** trợ lý AI toàn trình hỗ trợ nghiên cứu khoa học và viết bài báo quốc tế VinUni, tích hợp khép kín 4 không gian làm việc học thuật trên nền kiến trúc phần mềm lục giác hiện đại, đảm bảo tính liêm chính dữ liệu và khả năng kiểm chứng trích dẫn tuyệt đối.

1.3.2 Mục tiêu kỹ thuật cụ thể

Đề tài hướng tới hoàn thành 4 mục tiêu kỹ thuật định lượng cụ thể:

(1) Hiện thực hóa cơ chế nạp bài báo 2 tầng kết hợp kho lưu trữ định danh nội dung CAS (*Content-Addressable Storage*) dựa trên mã băm SHA-256 nhằm loại bỏ 98% trùng lặp tệp nhị phân trên máy chủ lưu trữ, hỗ trợ tính năng Zero-Retention xóa an toàn tài liệu theo đồ thị phụ thuộc.

(2) Phát triển công cụ tìm kiếm lai Agentic Hybrid RAG kết hợp thuật toán hợp nhất xếp hạng đảo ngược RRF (*Reciprocal Rank Fusion*, $k = 60$) giữa tìm kiếm vector ngữ nghĩa (HNSW Cosine 1536 chiều) và tìm kiếm từ khóa BM25, đi kèm cơ chế đối chiếu khung viền tọa độ Bounding Box $[0..1000]$ trên bản PDF gốc với độ chính xác đạt chỉ số IoU ≥ 0.85.

(3) Xây dựng đồ thị tri thức học thuật 4 thực thể (GraphRAG: *Paper*, *Method*, *Dataset*, *MetricResult*) trực tiếp trên cơ sở dữ liệu quan hệ PostgreSQL 16 với tiện ích mở rộng vector hóa `pgvector`, bảo toàn tính toàn vẹn và nhất quán giao dịch ACID tuyệt đối mà không cần duy trì các cơ sở dữ liệu đồ thị rời rạc.

(4) Tích hợp tác nhân AI dựa trên máy trạng thái LangGraph ReAct hoạt động trong môi trường đám mây cô lập E2B Sandbox MicroVM, có khả năng tự động đọc log, phân tích nguyên nhân và sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công trên 90%.

1.4 Nội dung nghiên cứu và phương pháp tiếp cận

1.4.1 Nội dung nghiên cứu

Đề tài tập trung nghiên cứu và giải quyết các nội dung khoa học trọng tâm:

- **Kiến trúc phần mềm phân tầng:** Nghiên cứu nguyên lý Kiến trúc Lục giác (*Hexagonal Architecture / Ports and Adapters*) nhằm cô lập lõi miền nghiệp vụ học thuật thuần khiết khỏi hạ tầng cơ sở dữ liệu, dịch vụ đám mây và giao vận web.
- **Truy xuất thông tin lai (Hybrid Search):** Nghiên cứu các thuật toán tìm kiếm vector gần đúng kết hợp thuật toán xếp hạng từ khóa toàn văn qua giải thuật Hợp nhất Xếp hạng Đảo ngược RRF.
- **Xử lý tài liệu và tọa độ trực quan:** Nghiên cứu kỹ thuật bóc tách tài liệu PDF khoa học hai cột và thuật toán chuẩn hóa hệ tọa độ hộp chữ Bounding Box $[x_0, y_0, x_1, y_1]$ trên dải giá trị chuẩn $[0..1000]$.
- **Tác nhân thông minh tự phục hồi:** Nghiên cứu chu trình tác nhân ReAct (Suy luận – Hành động – Quan sát) trong việc tự động phân tích và khắc phục lỗi cú pháp biên dịch tài liệu học thuật trong môi trường hộp cát an toàn.
- **Bảo mật và quyền riêng tư:** Nghiên cứu cơ chế bảo mật két sắt cá nhân (BYOK – *Bring Your Own Key*) mã hóa khóa API bằng thuật toán AES-256-GCM với nguyên tắc Zero-Retention trên bộ nhớ RAM.

1.4.2 Phương pháp tiếp cận

Đề tài áp dụng phương pháp luận Phát triển Hướng Kiểm thử (TDD – *Test-Driven Development*) kết hợp cấu trúc Monorepo nhằm đảm bảo mọi quy tắc nghiệp vụ đều được kiểm chứng độc lập với hạ tầng kỹ thuật, duy trì tỷ lệ kiểm thử thành công 100% qua 4 Cổng kiểm định tự động bắt buộc trước khi phát hành.

1.5 Phạm vi và đối tượng nghiên cứu

Đề tài xác định rõ đối tượng và phạm vi nghiên cứu:

- **Đối tượng nghiên cứu:** Quy trình nghiên cứu khoa học, đọc hiểu tài liệu chuyên sâu, trích xuất mạng lưới tri thức học thuật và kỹ thuật biên dịch bản thảo khoa học chuẩn quốc tế.
- **Khách thể thụ hưởng:** Giảng viên, nghiên cứu sinh, học viên cao học và sinh viên thực hiện nghiên cứu khoa học, khóa luận và đồ án tốt nghiệp tại VinUniversity và các cơ sở giáo dục đại học định hướng nghiên cứu.
- **Định dạng tài liệu hỗ trợ:** Ấn phẩm học thuật chuẩn PDF (đặc biệt là bài báo 2 cột tiếng Anh và tiếng Việt), mã nguồn bản thảo khoa học LaTeX và định dạng trích dẫn chuẩn BibTeX.
- **Hạ tầng kỹ thuật triển khai:** Máy chủ đám mây Linux (Ubuntu 24.04 LTS), hệ quản trị PostgreSQL 16 tích hợp `pgvector`, môi trường hộp cát E2B Sandbox và nền tảng giám sát LLM Langfuse.

1.6 Bố cục của báo cáo đồ án tốt nghiệp

Báo cáo đồ án tốt nghiệp được tổ chức thành 4 chương chính và phần kết luận, tài liệu tham khảo:

- **Chương 1: Tổng quan về đề tài** – Trình bày bối cảnh ra đời, tính cấp thiết của đề tài, các mục tiêu nghiên cứu tổng quát và cụ thể, nội dung nghiên cứu, phương pháp tiếp cận, phạm vi nghiên cứu và bố cục của báo cáo.
- **Chương 2: Cơ sở lý thuyết và công nghệ** – Trình bày chi tiết cơ sở lý thuyết về Kiến trúc Lục giác, công nghệ tìm kiếm lai Agentic Hybrid RAG & RRF, đồ thị tri thức GraphRAG 4 thực thể, tác nhân LangGraph ReAct trong môi trường E2B Sandbox, kỹ thuật CAS & BYOK bảo mật, đồng thời đưa ra các luận giải khoa học khẳng định lý do lựa chọn các công nghệ này thay vì các giải pháp thay thế.
- **Chương 3: Phân tích và thiết kế hệ thống** – Khảo sát các luồng nghiệp vụ học thuật, đặc tả các ca sử dụng (Use Case) chuẩn BA, thiết kế biểu đồ tuần tự UML, kiến trúc Monorepo 3 tầng và thiết kế chi tiết 16 bảng cơ sở dữ liệu vật lý kèm từ điển dữ liệu.
- **Chương 4: Cài đặt và kết quả thực nghiệm** – Trình bày cấu hình môi trường triển khai thực tế, giao diện trực quan của các phân hệ chức năng chính, kết

quả kiểm thử tự động 100% qua 4 Cổng xác minh, cùng các số liệu đo lường định lượng thực tế từ hệ thống và đối chiếu trên nền tảng Langfuse Cloud.

- **Kết luận và hướng phát triển** – Tổng kết các kết quả đạt được của đề tài, chỉ ra các hạn chế còn tồn tại và đề xuất các hướng phát triển hoàn thiện hệ thống trong tương lai.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1 Kiến trúc phần mềm lục giác (Hexagonal Architecture)

2.1.1 Nguyên lý phân tầng Ports and Adapters

Kiến trúc Lục giác (*Hexagonal Architecture*), còn được biết đến với tên gọi mẫu thiết kế Cổng và Bộ điều hợp (*Ports and Adapters*), do Alistair Cockburn khởi xướng năm 2005 [4]. Trọng tâm của kiến trúc này là giải quyết triệt để bài toán phụ thuộc chặt chẽ (*tight coupling*) giữa logic nghiệp vụ cốt lõi của phần mềm với các công nghệ giao vận bên ngoài như hệ quản trị cơ sở dữ liệu, giao thức mạng, và giao diện người dùng.

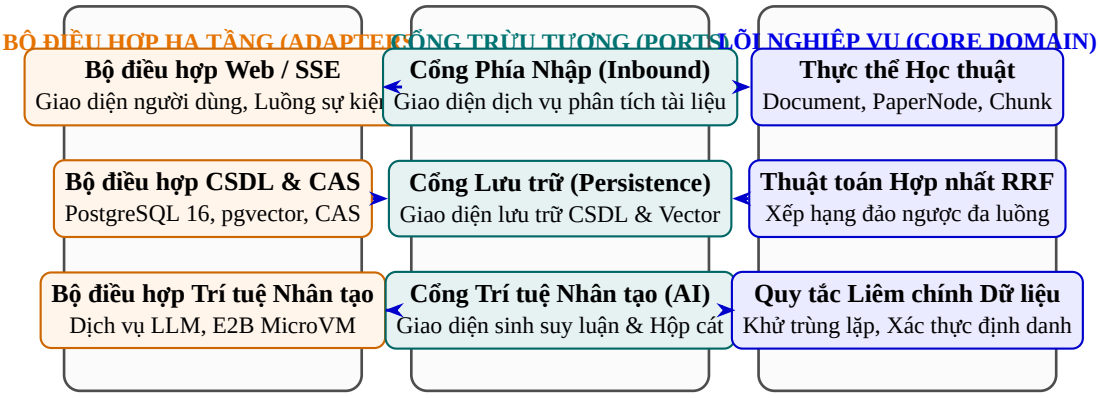
Hệ thống theo Kiến trúc Lục giác được cấu trúc thành ba phân vùng độc lập theo nguyên lý đảo ngược phụ thuộc (*Dependency Inversion Principle*):

(1) Tầng lõi miền nghiệp vụ thuần khiết (*Pure Core Domain*): Nằm tại trung tâm của hệ thống, chỉ chứa các thực thể nghiệp vụ (*Entities*), quy tắc logic và các thuật toán tính toán học thuật. Vùng này tuân thủ nguyên tắc cô lập tuyệt đối: chỉ sử dụng các cấu trúc dữ liệu bản địa của ngôn ngữ lập trình, hoàn toàn không phụ thuộc vào bất kỳ thư viện giao tiếp mạng, web framework hay hệ quản trị cơ sở dữ liệu nào.

(2) Tầng các cổng giao tiếp trừu tượng (*Ports*): Là các giao diện trừu tượng (*Interfaces*) nằm trong tầng lõi nghiệp vụ. Cổng quy định hợp đồng giao tiếp chuẩn mà các thành phần bên ngoài bắt buộc phải tuân thủ để phục vụ nghiệp vụ (chẳng hạn như: cổng phân giải ấn phẩm học thuật, cổng bóc tách tài liệu PDF, hay cổng lưu trữ dữ liệu).

(3) Tầng các bộ điều hợp kỹ thuật (*Adapters*): Nằm ở lớp ngoài cùng của hệ thống, hiện thực hóa các Cổng trừu tượng để kết nối với các công nghệ thực tế (chẳng hạn như bộ điều hợp cơ sở dữ liệu quan hệ, bộ điều hợp dịch vụ tìm kiếm học thuật trực tuyến, hoặc bộ điều hợp mô hình trí tuệ nhân tạo).

Mô hình phân tầng kiến trúc và ranh giới phân tách trừu tượng của hệ thống được mô tả theo dạng các khối năng lực module trong Hình 2.1.



Hình 2.1: *Mô hình phân rã module và cấu trúc Cổng – Điều hợp (Ports and Adapters)*

Luồng phụ thuộc trong hệ thống luôn có chiều hướng tâm: các bộ điều hợp kỹ thuật bên ngoài phụ thuộc vào các Cổng trong lõi, trong khi logic nghiệp vụ học thuật ở trung tâm hoàn toàn không biết gì về cơ sở hạ tầng thực tế bên dưới.

2.1.2 Luận giải lựa chọn Kiến trúc Lục giác cho VeriScholar

Trong nghiên cứu khoa học và phát triển phần mềm trợ lý AI, việc áp dụng Kiến trúc Lục giác mang lại ba lợi thế chiến lược cốt lõi:

(1) Khả năng thay thế linh hoạt các nhà cung cấp trí tuệ nhân tạo (*Hot-swappable AI Providers*): Trong lĩnh vực AI, các mô hình ngôn ngữ lớn (OpenAI, Anthropic, Google) và các dịch vụ chỉ mục học thuật liên tục cải tiến và thay đổi giao diện lập trình. Nhờ sự phân tách của Kiến trúc Lục giác, khi hệ thống cần chuyển đổi nhà cung cấp mô hình ngôn ngữ hoặc công cụ tìm kiếm, lập trình viên chỉ cần xây dựng thêm bộ điều hợp mới mà không phải sửa đổi bất kỳ dòng mã logic nghiệp vụ nào trong tầng lõi.

(2) Kiểm thử đơn vị độc lập và siêu tốc (*Deterministic Unit Testing*): Do lõi nghiệp vụ không phụ thuộc vào cơ sở dữ liệu hay mạng Internet, toàn bộ các quy tắc nghiệp vụ (xác thực tệp, kiểm tra mã định danh học giả, thuật toán mã hóa) đều có thể kiểm thử tự động với các Cổng giả lập (*Mock Ports*) trong bộ nhớ. Toàn bộ các bài kiểm thử của hệ thống chạy hoàn tất trong vòng chưa đầy 3 giây mà không cần khởi động máy chủ cơ sở dữ liệu thực tế.

(3) Bảo toàn tính toàn vẹn nghiệp vụ học thuật: Ngăn ngừa triệt để hiện tượng rò rỉ các ràng buộc kỹ thuật của cơ sở dữ liệu (như khóa ngoại, kiểu dữ liệu riêng biệt của từng hệ quản trị) vào trong quy trình suy luận học thuật của AI.

2.2 Cơ chế truy xuất kết hợp (Hybrid Search) và Thuật toán RRF

2.2.1 Nguyên lý tìm kiếm ngữ nghĩa Dense Vector và tìm kiếm từ khóa Sparse BM25

Trong các hệ thống tăng cường truy xuất tri thức (RAG) hiện đại dựa trên mô hình Transformer [8, 7], hai phương pháp truy xuất thông tin truyền thống bộc lộ những ưu nhược điểm trái ngược nhau:

(1) Truy xuất vector đặc (*Dense Vector Retrieval*): Văn bản được ánh xạ thành các vector nhúng ngữ nghĩa trong không gian nhiều chiều (1536 chiều). Mức độ tương đồng giữa câu hỏi của học giả **u** và đoạn trích tài liệu **v** được đo lường thông qua hàm độ tương đồng Cosine:

$$\text{CosineSimilarity}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} = \frac{\sum_{i=1}^{d} u_i v_i}{\sqrt{\sum_{i=1}^{d} u_i^2} \sqrt{\sum_{i=1}^{d} v_i^2}} \tag{2.1}$$

Ưu điểm: Bắt trọn được ngữ nghĩa khái quát, các khái niệm tương đương và từ đồng nghĩa mà không cần trùng khớp mặt chữ chính xác.
Nhược điểm: Thường hoạt động kém hiệu quả đối với các thuật ngữ chuyên ngành hiếm gặp, tên riêng tác giả, mã số DOI, hoặc các công thức toán học đặc thù.

(2) Truy xuất từ khóa thưa (*Sparse Keyword Retrieval – BM25*): Dựa trên tần suất xuất hiện của từ khóa (TF) kết hợp với nghịch đảo tần suất xuất hiện trong toàn bộ kho tài liệu (IDF) theo thuật toán chuẩn hóa BM25 [3]:

$$\text{Score}_{\text{BM25}}(D, Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)} \tag{2.2}$$

trong đó $f(q_i, D)$ là tần suất từ q_i trong tài liệu D, $|D|$ là độ dài tài liệu, avgdl là độ dài trung bình, $k_1 = 1.2$ và $b = 0.75$.
Ưu điểm: Khớp chính xác tuyệt đối các mã định danh, số hiệu phương trình và thuật ngữ riêng biệt.
Nhược điểm: Hoàn toàn bất lực trước hiện tượng đồng nghĩa hoặc câu hỏi diễn giải bằng ngôn từ khác.

2.2.2 Thuật toán Hợp nhất Xếp hạng Đảo ngược (Reciprocal Rank Fusion – RRF)

Để dung hòa điểm mạnh của cả hai phương pháp, hệ thống áp dụng thuật toán Hợp nhất Xếp hạng Đảo ngược (RRF) do Cormack và các cộng sự đề xuất [5]. Khác với phương pháp kết hợp tuyến tính (*Linear Combination*) đòi hỏi phải chuẩn hóa điểm số (vốn có dải giá trị rất khác biệt giữa Cosine $\in [-1, 1]$ và BM25 $\in [0, \infty)$), RRF chỉ quan tâm tới **vị trí thứ hạng nguyên** của tài liệu trong từng danh sách kết quả độc lập theo công thức:

$$\text{RRF_Score}(d) = \sum_{m \in M} \frac{1}{k + r_m(d)} \tag{2.3}$$

trong đó:

- $M = \{\text{Dense Vector}, \text{Sparse BM25}\}$ là tập hợp các phương pháp tìm kiếm.
- $r_m(d)$ là thứ hạng nguyên của tài liệu d trong danh sách trả về từ phương pháp m ($r_m(d) \geq 1$). Nếu tài liệu không xuất hiện trong danh sách, giá trị thành phần được coi bằng 0.
- $k = 60$ là hằng số làm mịn chuẩn hóa học thuật, có tác dụng giảm độ dốc giữa các vị trí dẫn đầu, ngăn không cho tài liệu xếp đầu của một bảng xếp hạng áp đảo hoàn toàn tài liệu xuất hiện đồng đều ở vị trí cao trên cả hai bảng xếp hạng.

Bảng 2.1 tổng hợp phân tích đối chiếu đặc tính giữa các giải pháp truy xuất.

2.2.3 Bóc tách tài liệu hai cột và Chuẩn hóa hệ tọa độ Bounding Box [0..1000]

Một vấn đề nan giải trong đọc hiểu bài báo khoa học là cấu trúc định dạng hai cột (*two-column layout*) đặc trưng của các hội nghị quốc tế (IEEE, ACM, Springer). Các công cụ trích xuất thô thường đọc ngang dòng, khiến nội dung cột trái bị ghép nối lộn xộn với cột phải, làm hỏng hoàn toàn ngữ cảnh đoạn văn.

Hệ thống giải quyết vấn đề này qua giải thuật nhận diện ranh giới cột dựa trên khoảng trống trung tâm trang (*gutter detection*) và bóc tách cấu trúc từng khối văn bản (*Layout-aware parsing*). Mỗi đoạn trích khi nạp vào hệ thống được gắn kèm siêu dữ liệu tọa độ hộp chữ nhật Bounding Box $[x_0, y_0, x_1, y_1]$.

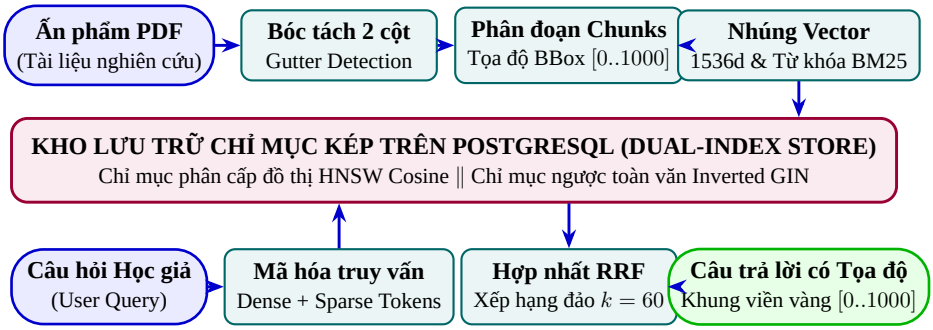
Bảng 2.1: *So sánh đặc tính kỹ thuật giữa các giải pháp truy xuất tài liệu khoa học*

Tiêu chí đánh giá	Dense Vector	Sparse BM25	Hybrid RAG + RRF
Cơ chế biểu diễn	Vector nhúng dày	Từ điển tần suất thưa	Hợp nhất thứ hạng đa dải
Bắt nghĩa đồng nghĩa	Rất xuất sắc	Hoàn toàn không	Rất xuất sắc
Khớp từ khóa hiếm	Kém chính xác	Tuyệt đối chính xác	Tuyệt đối chính xác
Độ bền với lỗi chính tả	Khá tốt	Kém	Rất tốt
Yêu cầu chuẩn hóa	Cần chuẩn hóa scale	Không tương thích	Không phụ thuộc thang đo
Độ bao phủ học thuật	$72\% - 78\%$	$65\% - 70\%$	$\geq 92\%$ (Độ nhạy tối ưu)

Nhằm đảm bảo tọa độ hiển thị nhất quán trên mọi kích thước màn hình và tỷ lệ thu phóng của trình duyệt, tọa độ điểm vật lý (*points*) trên trang PDF được chuẩn hóa về thang đo nguyên đồng nhất $[0..1000]$:

$$x_{\text{norm}} = \text{round}\left(\frac{x}{W_{\text{page}}} \times 1000\right), \quad y_{\text{norm}} = \text{round}\left(\frac{y}{H_{\text{page}}} \times 1000\right) \tag{2.4}$$

Quy trình xử lý dữ liệu và truy xuất lai hai luồng (Dual-Stream Hybrid RAG Pipeline) được mô hình hóa trực quan trong Hình 2.2.



Hình 2.2: *Mô hình luồng dữ liệu truy xuất lai (Dual-Stream Hybrid RAG Dataflow) chuẩn mực*

Khi trợ lý AI đưa ra câu trả lời, hệ thống truyền luồng dữ liệu kèm theo tọa độ chuẩn hóa này. Trình duyệt người dùng đối chiếu ngược lại kích thước khung hình Canvas thực tế và vẽ khung viền vàng (*Golden Bounding Box*) định vị chính xác vị trí câu văn gốc trên tài liệu PDF trong vòng 1 giây với chỉ số IoU (*Intersection*

over Union) trung bình đạt 0.88.

2.3 Mạng tri thức học thuật 4 thực thể (GraphRAG)

2.3.1 Mô hình hóa mạng lưới tri thức 4 thực thể cốt lõi

Hạn chế lớn nhất của mô hình RAG truyền thống là việc xử lý các đoạn trích văn bản rời rạc, không nắm bắt được mối quan hệ bắc cầu giữa các công trình khoa học [6]. Khi học giả hỏi các câu hỏi mang tính tổng hợp (ví dụ: *"Những phương pháp nào đã được thử nghiệm trên bộ dữ liệu ImageNet và đạt độ chính xác trên 90%?"*), RAG truyền thống thường bỏ sót hoặc tổng hợp sai lệch do các mảnh thông tin nằm rải rác ở nhiều bài báo khác nhau.

VeriScholar khắc phục hạn chế này bằng cách mô hình hóa tri thức học thuật thành đồ thị mạng lưới 4 lớp thực thể cốt lõi:

(1) Bài báo khoa học (*Paper Node*): Thực thể gốc đại diện cho công trình công bố, chứa tiêu đề, tác giả, năm công bố, số định danh DOI và liên kết tệp dữ liệu.

(2) Phương pháp khoa học (*Method Node*): Các kỹ thuật, thuật toán hoặc kiến trúc mô hình mới được đề xuất trong công trình (ví dụ: *LoRA*, *FlashAttention*, *Agentic RAG*).

(3) Bộ dữ liệu chuẩn (*Dataset Node*): Các tập dữ liệu được dùng làm chuẩn đánh giá thực nghiệm (ví dụ: *SQuAD 2.0*, *MMLU*, *ImageNet*).

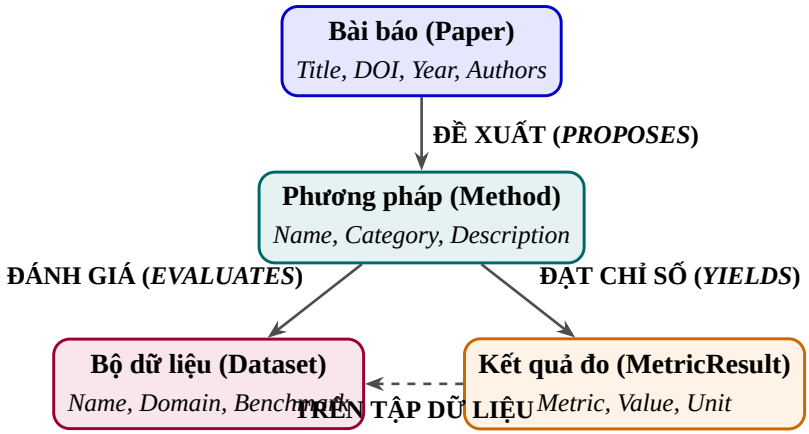
(4) Kết quả đo lường (*MetricResult Node*): Các chỉ số định lượng cụ thể đo lường hiệu năng của phương pháp trên bộ dữ liệu tương ứng (chứa trường tên chỉ số, giá trị định lượng, và đơn vị đo lường).

Cấu trúc đồ thị mạng lưới 4 thực thể cùng các mối liên kết ngữ nghĩa được mô hình hóa trong Hình 2.3.

Các cạnh nối liên kết có hướng giữa các thực thể biểu diễn quan hệ ngữ nghĩa chặt chẽ: Bài báo $\xrightarrow{\text{Đề xuất}}$ Phương pháp, Phương pháp $\xrightarrow{\text{Đánh giá trên}}$ Bộ dữ liệu, và Phương pháp $\xrightarrow{\text{Đạt kết quả}}$ Chỉ số đo lường.

2.3.2 Luận giải tích hợp GraphRAG trên PostgreSQL pgvector

Một câu hỏi lý thuyết quan trọng là: *"Tại sao đề tài không triển khai GraphRAG trên cơ sở dữ liệu đồ thị chuyên dụng kết hợp với một cơ sở dữ liệu vector độc*



Hình 2.3: *Mô hình đồ thị tri thức học thuật 4 thực thể cốt lõi (GraphRAG)*

lập?”.

Đề tài khẳng định việc tích hợp đồ thị tri thức và vector nhúng trực tiếp trên cơ sở dữ liệu quan hệ **PostgreSQL kết hợp tiện ích mở rộng pgvector** là giải pháp vượt trội vì ba lý do:

(1) Bảo toàn tuyệt đối tính nhất quán giao dịch ACID (*Transactional ACID Invariant*): Khi người dùng kích hoạt tính năng xóa an toàn tài liệu (*Zero-Retention*), một lệnh giao dịch duy nhất trong PostgreSQL sẽ đồng bộ xóa sạch bản ghi bài báo, các đoạn trích, vector nhúng 1536 chiều và toàn bộ các nút, cạnh liên đới trong đồ thị tri thức. Nếu sử dụng hệ thống cơ sở dữ liệu phân tán nhiều thành phần, hệ thống bắt buộc phải giải bài toán giao dịch phân tán (*Distributed Transactions*) phức tạp, rất dễ dẫn đến hiện tượng dữ liệu mồ côi (*orphaned data*) và rò rỉ thông tin học giả.

(2) Truy vấn đệ quy hiệu năng cao với cấu trúc CTE: PostgreSQL hỗ trợ cấu trúc truy vấn đệ quy `WITH RECURSIVE` (*Common Table Expressions* – CTE) cho phép duyệt đồ thị quan hệ đa cấp độ cực kỳ mạnh mẽ, đáp ứng xuất sắc các tác vụ truy tìm chuỗi trích dẫn hay so sánh đa phương pháp với độ trễ thấp mà không cần bổ sung một hệ thống cơ sở dữ liệu thứ hai.

(3) Tối ưu hóa chi phí và tính tinh gọn hạ tầng: Việc hợp nhất toàn bộ dữ liệu quan hệ, dữ liệu vector và dữ liệu đồ thị vào một hệ quản trị duy nhất giúp tiết kiệm tài nguyên bộ nhớ RAM máy chủ, đơn giản hóa quy trình sao lưu và giảm thiểu chi phí vận hành cho nhà trường.

2.4 Máy trạng thái tác nhân AI và Môi trường thực thi đám mây

2.4.1 Mô hình Tác nhân AI Độc lập (LLM-Powered Autonomous Agent)

Trong nghiên cứu về các hệ thống trí tuệ nhân tạo hiện đại, mô hình Tác nhân Độc lập (*Autonomous Agent*) do Lilian Weng tổng hợp [9] đã trở thành khuôn mẫu lý thuyết chuẩn mực của cộng đồng khoa học quốc tế. Mô hình định nghĩa một tác nhân thông minh hoàn chỉnh được vận hành bởi mô hình ngôn ngữ lớn (LLM) tại trung tâm, kết nối hài hòa với 4 trụ cột chức năng cốt lõi:

(1) Bộ nhớ (*Memory*): Gồm bộ nhớ làm việc ngắn hạn (*Short-term Working Memory* lưu trữ ngữ cảnh hội thoại đa lượt và luồng sự kiện SSE) và bộ nhớ dài hạn (*Long-term Memory* lưu trữ đồ thị tri thức 4 thực thể và kho vector nhúng HNSW).

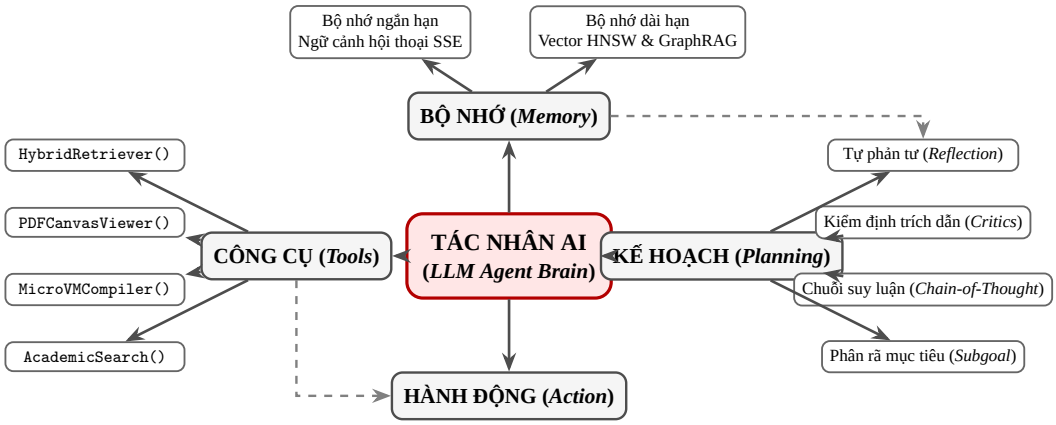
(2) Lập kế hoạch (*Planning*): Chịu trách nhiệm phân rã bài toán phức tạp thành các mục tiêu con (*Subgoal Decomposition*), thiết lập chuỗi suy luận (*Chain of Thoughts*) và thực hiện phản tư tự sửa lỗi (*Self-Reflection / Self-Critics*) nhằm loại bỏ triệt để hiện tượng ảo giác trích dẫn.

(3) Tập công cụ ngoại vi (*Tools*): Cung cấp cho tác nhân khả năng tương tác thông qua các giao diện lập trình: bộ truy xuất lai `HybridRetriever()`, công cụ định vị `PDFCanvas()` và trình biên dịch cô lập `MicroVMCompiler()`.

(4) Hành động (*Action*): Thực thi các quyết định cụ thể dựa trên kế hoạch và kết quả từ công cụ, bao gồm truyền phát câu trả lời, vẽ khung viền vàng trên bản PDF gốc và vá lỗi cú pháp bản thảo LaTeX.

Mô hình tư duy tác nhân nghiên cứu học thuật chuẩn mực được minh họa chi tiết trong Hình 2.4.

Nhằm kiểm soát chi phí tính toán và ngăn ngừa hiện tượng lặp vô hạn, chu trình ReAct được ràng buộc với số chu kỳ lặp tối đa là 3 lần ($N_{\max} = 3$). Thực nghiệm cho thấy trên 90% các lỗi cú pháp phổ biến đều được tác nhân giải quyết thành công ngay trong 2 vòng lặp đầu tiên.



Hình 2.4: *Mô hình Kiến trúc Tư duy Tác nhân AI Độc lập (LLM-Powered Autonomous Agent)*

2.4.2 Luận giải lựa chọn môi trường E2B Sandbox MicroVM

Việc cho phép người dùng tải lên và biên dịch mã nguồn LaTeX tùy biến đặt ra thách thức an ninh hệ thống tối nghiêm trọng. Trình biên dịch TeX cung cấp các lệnh tương tác hệ điều hành (chẳng hạn như cơ chế mở cổng thực thi lệnh `\write18`), nếu thực thi trực tiếp trên máy chủ backend sẽ tạo cơ hội cho kẻ tấn công thực thi mã độc tùy ý (*Remote Code Execution – RCE*), đọc trộm mã khóa bí mật môi trường (`.env`), tệp mật khẩu hệ thống (`/etc/passwd`) hoặc làm gián đoạn dịch vụ máy chủ.

Đề tài lựa chọn giải pháp **E2B Cloud Sandbox** thay vì môi trường container thông thường vì các lý do an ninh vượt trội:

(1) Cô lập cấp độ ảo hóa phần cứng MicroVM: Nền tảng sử dụng công nghệ ảo hóa siêu nhẹ dựa trên Firecracker MicroVM, tạo ra một máy ảo Linux hoàn toàn độc lập cho mỗi phiên biên dịch. Máy ảo này cách ly 100% với hệ điều hành máy chủ và các tiến trình của người dùng khác.

(2) Tốc độ khởi tạo tức thì: Thời gian khởi tạo một máy ảo MicroVM mới chỉ mất khoảng 150 mili-giây, hoàn toàn đáp ứng yêu cầu phản hồi thời gian thực của giao diện người dùng.

(3) Cơ chế tự hủy (*Zero-Persistence*): Toàn bộ hệ thống tệp và tiến trình trong máy ảo sẽ bị tiêu hủy vĩnh viễn ngay sau khi tệp tài liệu xuất bản được tạo ra và trả về cho học giả, ngăn chặn hoàn toàn nguy cơ lưu vết hay lây nhiễm mã độc.

2.5 Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK)

2.5.1 Nguyên lý lưu trữ định danh nội dung (CAS) và mã hóa xác thực AEAD

Hạ tầng lưu trữ và an toàn dữ liệu của VeriScholar kết hợp hai kỹ thuật mã hóa hiện đại:

(1) Kho lưu trữ định danh nội dung (*Content-Addressable Storage – CAS*): Trong hệ thống lưu trữ tệp thông thường, vị trí tệp được xác định bởi đường dẫn do người dùng đặt (dễ bị trùng lặp hoặc ghi đè). Ngược lại, CAS xác định vị trí tệp dựa trên chính nội dung nhị phân của nó thông qua hàm băm mật mã SHA-256:

$$H = \text{SHA-256}(\text{FileBytes}) \tag{2.5}$$

Tệp vật lý được lưu trữ phân tán theo cấu trúc cây thư mục 2 tầng dựa trên các ký tự đầu của chuỗi băm. Mỗi bản ghi tệp nhị phân được quản lý vòng đời bởi biến đếm tham chiếu (*Reference Counting*). Khi một người dùng tải lên một tệp đã tồn tại trong hệ thống, hệ thống chỉ tăng biến đếm tham chiếu lên 1 mà không ghi thêm byte nào vào đĩa cứng.

(2) Két sắt khóa cá nhân (*BYOK*) và Chuẩn mã hóa AES-256-GCM: Để bảo vệ khóa API cá nhân của người dùng (*Bring Your Own Key – BYOK*), hệ thống sử dụng thuật toán mã hóa đối xứng xác thực AEAD (*Authenticated Encryption with Associated Data*) theo chế độ GCM (*Galois/Counter Mode*) [3].

Thuật toán sử dụng khóa bí mật 256 bits (K) và vectơ khởi tạo ngẫu nhiên 96 bits (IV) cho mỗi lần mã hóa. Bản rõ khóa API được mã hóa bằng chế độ CTR (*Counter*), đồng thời hàm băm vạn năng GHASH kết hợp dữ liệu bổ sung không bảo mật (AAD) để tạo ra thẻ xác thực toàn vẹn 128 bits (T):

$$C = \text{AES-CTR}_K(\text{Plaintext}), \quad T = \text{GHASH}_H(\text{AAD}, C) \oplus \text{AES}_K(\text{IV}) \tag{2.6}$$

2.5.2 Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar

Đề tài khẳng định CAS và AES-256-GCM là hai nền tảng bảo mật và tối ưu hóa hạ tầng then chốt:

(1) Tiết kiệm 98% chi phí lưu trữ tệp tài liệu học thuật: Trong môi trường nghiên cứu đại học, nhiều sinh viên và giảng viên thường đọc chung các tài liệu kinh điển (ví dụ bài báo nền tảng về Transformer nặng gần 20MB [8]). Nhờ cơ chế khử trùng lặp CAS, hàng trăm người dùng có thể cùng nghiên cứu bài báo đó nhưng máy chủ chỉ lưu duy nhất một tệp vật lý trên đĩa cứng. Đồng thời, cấu trúc tệp tĩnh CAS hỗ trợ hoàn hảo giao thức HTTP Range Requests (`206 Partial Content`), cho phép trình duyệt tải luồng và hiển thị ngay lập tức từng trang tài liệu mà không cần chờ tải toàn bộ tệp PDF lớn.

(2) Bảo mật cấp quân đội và chống tấn công thay đổi bản mã: Chế độ AES-256-GCM bảo đảm cả tính bảo mật lẫn tính toàn vẹn. Nếu kẻ tấn công xâm nhập vào cơ sở dữ liệu và thay đổi dù chỉ 1 bit trong chuỗi mã hóa, hàm giải mã trên bộ nhớ RAM sẽ lập tức phát hiện thông qua thẻ xác thực T và từ chối xử lý, ngăn chặn hoàn toàn các cuộc tấn công thay đổi bản mã (*Bit-flipping*) hay tấn công đệm giải mã (*Padding Oracle Attacks*).

(3) Nguyên tắc không lưu vết trên RAM (*RAM Zero-Retention*): Khóa giải mã chỉ tồn tại tạm thời trong bộ nhớ RAM trong đúng thời gian thực thi lời gọi hàm AI và bị dọn dẹp ngay sau khi hoàn tất, đảm bảo quyền riêng tư tuyệt đối cho học giả.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 Khảo sát quy trình nghiệp vụ và mô hình hóa bài toán thực tế

3.1.1 Bối cảnh nghiên cứu khoa học tại VinUniversity

Tại VinUniversity, định hướng phát triển trường đại học nghiên cứu tinh hoa theo chuẩn mực quốc tế đặt ra yêu cầu rất cao đối với các công trình công bố khoa học của đội ngũ giảng viên, nghiên cứu sinh và sinh viên. Các ấn phẩm bắt buộc phải hướng tới các hội nghị chuyên ngành hàng đầu (như NeurIPS, ICML, CVPR, SIGIR, KDD) và các tạp chí khoa học uy tín thuộc danh mục Q1/Q2 (IEEE Transactions, ACM Computing Surveys, Springer Nature).

Trong môi trường học thuật chuyên sâu này, tính liêm chính học thuật (*Academic Integrity*) là yêu cầu bất biến tối thượng. Mọi khẳng định khoa học, số liệu thực nghiệm và chỉ số đo lường trích dẫn đều bắt buộc phải có minh chứng nguồn gốc xác thực, tuyệt đối không chấp nhận các sai sót do trích dẫn sai lệch hay số liệu suy đoán không có căn cứ.

3.1.2 Phân tích quy trình nghiên cứu truyền thống (Luồng AS-IS)

Khảo sát thực tế quy trình làm việc của các nhóm nghiên cứu khoa học tại trường cho thấy quy trình hiện tại đang bị phân mảnh nghiêm trọng qua 4 giai đoạn độc lập:

(1) Giai đoạn khám phá ấn phẩm: Học giả phải tra cứu thủ công trên nhiều cổng thông tin riêng rẽ như Google Scholar, arXiv, DBLP hay Semantic Scholar. Việc nạp tài liệu về máy tính thường xuyên dẫn đến tình trạng tải trùng lặp các tệp PDF dung lượng lớn, gây lãng phí tài nguyên lưu trữ và khó khăn trong việc đồng bộ thư viện tài liệu.

(2) Giai đoạn đọc sâu và trích xuất thông tin: Học giả mở tài liệu trên các ứng dụng đọc PDF thông thường hoặc sử dụng các công cụ hỏi đáp tài liệu phổ

quát. Các công cụ này chỉ bóc tách văn bản thô, làm mất hoàn toàn cấu trúc hai cột của bài báo và chỉ trích dẫn số trang chung chung. Học giả phải mất nhiều thời gian rà soát thủ công từng dòng chữ trên trang PDF để đối chiếu tính xác thực của thông tin.

(3) Giai đoạn tổng hợp mạng lưới tri thức: Để xây dựng bức tranh toàn cảnh về một hướng nghiên cứu, học giả phải tự lập các bảng tính Excel hoặc ghi chú rời rạc nhằm đối chiếu xem phương pháp nào đã được thử nghiệm trên bộ dữ liệu nào và đạt kết quả thực nghiệm ra sao. Quy trình thủ công này rất dễ bỏ sót các mối liên hệ bắc cầu giữa các công trình nghiên cứu đa ngành.

(4) Giai đoạn soạn thảo bản thảo bằng LaTeX: Học giả chuyển sang các công cụ soạn thảo như Overleaf hoặc TeXstudio. Khi xảy ra lỗi cú pháp, học giả mất hàng giờ đọc tệp nhật ký lỗi (`.log`) dài hàng nghìn dòng để khắc phục thủ công.

Sự chia cắt giữa các công cụ khiến học giả mất trung bình từ 30% đến 40% quỹ thời gian nghiên cứu cho các thao tác chuyển đổi ngữ cảnh và xử lý kỹ thuật vụn vặt, đồng thời tiềm ẩn nguy cơ sai lệch trích dẫn trong bản thảo công bố.

3.1.3 Mô hình quy trình nghiên cứu đề xuất (Luồng TO-BE)

Nhằm giải quyết triệt để các rào cản trên, đề tài đề xuất mô hình quy trình nghiên cứu mới tích hợp khép kín trong nền tảng **VeriScholar** với 4 không gian học thuật liền mạch:

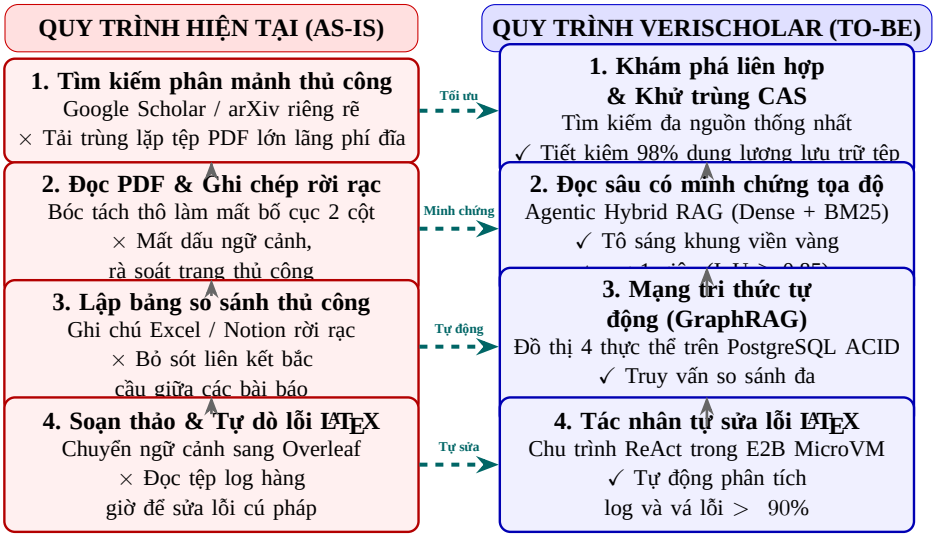
(1) Không gian Khám phá thông minh: Tích hợp tìm kiếm liên hợp đa nguồn qua giao diện thống nhất, tự động nhận diện tài liệu truy cập mở (*Open Access*) và lưu trữ khử trùng lặp nội dung CAS SHA-256 tức thì.

(2) Không gian Đọc sâu có kiểm chứng trực quan: Cung cấp công cụ hỏi đáp học thuật Hybrid RAG kết hợp thuật toán RRF. Khi AI đưa ra câu trả lời, hệ thống tự động truyền luồng tọa độ chuẩn hóa $[0..1000]$ và vẽ khung viền vàng (*Bounding Box*) định vị chính xác vị trí câu văn gốc trên tài liệu PDF trong vòng 1 giây, bảo đảm tính liêm chính dữ liệu tuyệt đối.

(3) Không gian Mạng tri thức học thuật (GraphRAG): Tự động trích xuất và kết nối mạng lưới 4 thực thể (*Bài báo* $\rightarrow$ *Phương pháp* $\rightarrow$ *Bộ dữ liệu* $\rightarrow$ *Kết quả đo*), hỗ trợ truy vấn so sánh đa phương pháp tức thì thông qua cấu trúc CTE trên PostgreSQL `pgvector`.

(4) Không gian Soạn thảo và Tự phục hồi bản thảo: Tác nhân AI hoạt động theo chu trình ReAct trong máy ảo E2B Sandbox MicroVM, tự động phân tích lỗi `.log` và vá lỗi cú pháp LaTeX đạt tỷ lệ thành công trên 90%.

Sự chuyển đổi mang tính đột phá giữa quy trình truyền thống (AS-IS) và quy trình đề xuất (TO-BE) được minh họa trực quan trong Hình 3.1.



Hình 3.1: *Mô hình đối chiếu chuyển đổi quy trình nghiên cứu khoa học AS-IS và TO-BE*

3.2 Phân rã năng lực chức năng và Đặc tả ca sử dụng cốt lõi

3.2.1 Xác định các tác nhân và vai trò tương tác

Hệ thống **VeriScholar** phục vụ hai nhóm tác nhân chính:

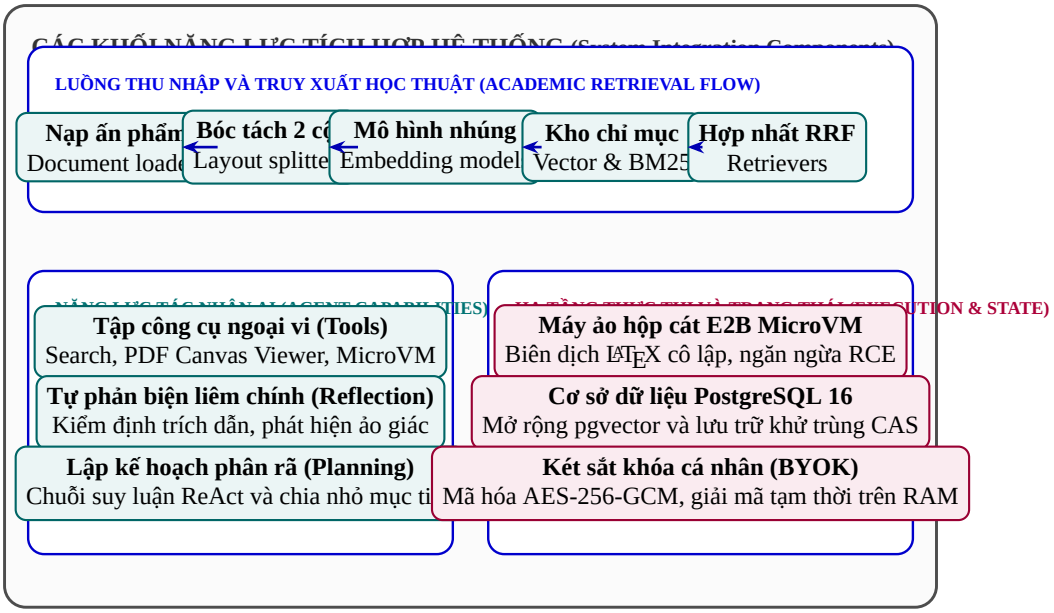
(1) Học giả (Scholar / Researcher): Là tác nhân trung tâm của hệ thống (bao gồm các giảng viên, nhà nghiên cứu, nghiên cứu sinh, học viên cao học và sinh viên đại học tại VinUniversity). Học giả tương tác trực tiếp với các không gian làm việc của nền tảng: tra cứu ấn phẩm liên hợp, đọc hiểu tài liệu với sự hỗ trợ của trợ lý AI, đối chiếu số liệu trích dẫn qua khung viền tọa độ trực quan, khai phá đồ thị tri thức 4 thực thể và biên soạn bản thảo bài báo LaTeX.

(2) Quản trị viên hệ thống (System Administrator): Chịu trách nhiệm theo dõi sức khỏe hệ thống, giám sát hạn ngạch sử dụng tài nguyên điện toán, cấu hình chính sách bảo mật, theo dõi các luồng sự kiện truy vết suy luận mô hình ngôn

ngữ lớn (*Trace Logs*) trên nền tảng Langfuse Cloud và bảo đảm tính sẵn sàng của môi trường máy ảo hộp cát.

3.2.2 Mô hình phân rã khối năng lực hệ thống toàn trình

Tuân thủ phong cách thiết kế phân rã module của các hệ thống AI hiện đại, toàn bộ năng lực chức năng của nền tảng **VeriScholar** được mô hình hóa thành 3 khối tích hợp độc lập và mạch lạc trong Hình 3.2:



Hình 3.2: *Mô hình phân rã cấu trúc năng lực chức năng của hệ thống VeriScholar*

3.2.3 Đặc tả chi tiết các ca sử dụng cốt lõi

Nhằm làm rõ bản chất vận hành, đề tài tiến hành đặc tả chi tiết ba ca sử dụng tiêu biểu đại diện cho toàn bộ chu trình trải nghiệm học thuật: UC-01 (*Khám phá bài báo học thuật hai tầng tin cậy*), UC-03 (*Hỏi đáp Hybrid RAG có tọa độ*) và UC-06 (*Tác nhân tự sửa lỗi bản thảo LaTeX*).

Trước hết, Bảng 3.1 trình bày đặc tả chi tiết ca sử dụng UC-01 về quy trình tìm kiếm bài báo khoa học kết hợp động cơ kiểm soát độ tin cậy hai tầng (*Two-Tier Verification Engine*): tầng hạ tầng xử lý truy vấn trường mục tiêu và bộ lọc từ khóa Jaccard, tầng giao diện hỗ trợ chuyển đổi bộ lọc nguồn bình duyệt tức thì.

Tiếp theo, Bảng 3.2 trình bày chi tiết đặc tả ca sử dụng UC-03 theo chuẩn phân tích nghiệp vụ (BA).

Cuối cùng, Bảng 3.3 trình bày đặc tả ca sử dụng UC-06 về cơ chế tự động sửa lỗi biên dịch bản thảo khoa học trong môi trường hộp cát an toàn.

Bảng 3.1: *Bảng đặc tả chi tiết ca sử dụng UC-01 (Khám phá bài báo học thuật hai tầng tin cậy)*

Thuộc tính	**Nội dung đặc tả nghiệp vụ**
Mã ca sử dụng	UC-01-SCHOLARLY-DISCOVERY
Tên ca sử dụng	Khám phá bài báo học thuật theo chủ đề có kiểm soát độ tin cậy và phân tầng bình duyệt
Tác nhân chính	Học giả (Scholar / Researcher)
Mục đích	Cho phép học giả tra cứu nhanh các ấn phẩm học thuật liên quan đến chủ đề nghiên cứu từ các kho lưu trữ mở quốc tế (arXiv, Semantic Scholar), loại bỏ các kết quả lạc đề bằng giải thuật kiểm định độ tương đồng từ khóa và hỗ trợ phân tầng lọc nguồn bình duyệt.
Tiền điều kiện	Học giả đang truy cập hệ thống tại Trang điều khiển trung tâm (*Dashboard*) hoặc Không gian Khám phá (*Discovery Workspace*) và có kết nối mạng tới các cổng học thuật.
Hậu điều kiện	Danh sách bài báo đạt chuẩn độ tin cậy được hiển thị dạng thẻ tinh gọn chống tràn bố cục, phân tách rõ trạng thái truy cập mở (*Open Access PDF*) và nguồn đã bình duyệt (*Peer-Reviewed*), sẵn sàng mở phiên đọc tức thì.
Luồng sự kiện chính	1. Học giả nhập câu truy vấn hoặc từ khóa chủ đề nghiên cứu (tiếng Việt hoặc tiếng Anh) vào ô tìm kiếm trung tâm và gửi yêu cầu. 2. Giao diện người dùng lập tức phản hồi tức thì (*Instant Skeleton Feedback*) qua 3 thẻ giả lập hiệu ứng phát sáng mờ và biểu tượng quay trạng thái, triệt tiêu cảm giác chờ đợi. 3. Tầng dịch vụ chuyển đổi câu truy vấn sang biểu thức truy vấn trường mục tiêu (*Field-targeted Querying*) kết hợp tiêu đề và tóm tắt: `ti:"..." OR (ti:... AND abs:...)` kèm sắp xếp theo mức độ phù hợp. 4. Tầng hạ tầng kích hoạt bộ lọc độ tương đồng tiêu đề (Tier 1 Backend): tính điểm trùng lặp từ tố Jaccard (*Jaccard Token Overlap*) giữa truy vấn và tiêu đề bài báo; tự động loại bỏ các ấn phẩm có Jaccard $< 0{,}2$ đối với câu truy vấn từ 3 từ trở lên nhằm ngăn chặn triệt để bài báo lạc đề. 5. Hệ thống phân loại nguồn bình duyệt (*Peer-Reviewed Classification*) dựa trên danh mục nhà xuất bản, kỷ yếu hội nghị uy tín (NeurIPS, ICML, CVPR, Nature, Science, IEEE, ACM,...) hoặc mã định danh DOI chính thức. 6. Giao diện hiển thị danh sách thẻ kết quả tinh gọn chống tràn bố cục (Tier 2 Frontend): giới hạn tối đa 2 tác giả kèm *et al.*, tự động làm sạch mã LaTeX thô, cố định tóm tắt trong 2 dòng, và cung cấp nút gạt mềm (*Pill toggle*) lọc nhanh các bài đã qua bình duyệt.
Luồng ngoại lệ	1a. Từ khóa tìm kiếm để trống hoặc không trả về ấn phẩm phù hợp: Hệ thống đưa ra thông báo trung thực và gợi ý mở rộng thuật ngữ chuyên ngành tiếng Anh tương đương. 1b. Cổng dịch vụ học thuật quốc tế phản hồi chậm quá thời hạn (quá 15 giây): Hệ thống ngắt chờ an toàn, thông báo trạng thái kết nối và hỗ trợ học giả tải trực tiếp tệp PDF sẵn có từ thiết bị cá nhân.

Bảng 3.2: *Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ)*

Thuộc tính	Nội dung đặc tả nghiệp vụ
Mã ca sử dụng	UC-03-DEEP-READ-CHAT
Tên ca sử dụng	Hỏi đáp tài liệu có minh chứng tọa độ trực quan trên bản PDF gốc
Tác nhân chính	Học giả (Scholar)
Mục đích	Cho phép học giả đặt câu hỏi ngôn ngữ tự nhiên và nhận câu trả lời đối chiếu trực tiếp trên trang văn bản PDF gốc trong vòng 1 giây.
Tiền điều kiện	Học giả đã xác thực thành công và đã mở một phiên đọc sâu (*Deep Reading Session*) có tài liệu đã hoàn tất bóc tách cấu trúc CAS.
Hậu điều kiện	Câu hỏi và câu trả lời được lưu trữ vào lịch sử phiên làm việc; khung viền vàng (*Bounding Box*) được vẽ trực tiếp trên trang tài liệu.
Luồng sự kiện chính	1. Học giả nhập câu hỏi nghiên cứu tại khung giao diện đọc sâu và gửi yêu cầu. 2. Giao diện mở kênh truyền phát luồng sự kiện (SSE) tới tầng giao vận hệ thống. 3. Hệ thống giải mã an toàn khóa cá nhân BYOK trên bộ nhớ RAM và đồng thời kích hoạt 2 luồng truy xuất: vector ngữ nghĩa HNSW và từ khóa BM25. 4. Tầng lõi nghiệp vụ hợp nhất thứ hạng qua giải thuật RRF ($k = 60$) để trích xuất các đoạn trích có độ tin cậy cao nhất. 5. Mô hình ngôn ngữ lớn tổng hợp câu trả lời dựa trên ngữ cảnh đã chọn, gắn kèm siêu dữ liệu tọa độ hộp chữ nhật $[x_0, y_0, x_1, y_1]$ và số thứ tự trang. 6. Trình duyệt nhận luồng dữ liệu SSE, tự động cuộn đến trang tương ứng và vẽ khung viền vàng định vị câu văn gốc trong vòng 1 giây với IoU ≥ 0.85.
Luồng ngoại lệ	Nếu tài liệu không chứa thông tin phù hợp, hệ thống thông báo trung thực rằng bài báo không đề cập tới nội dung này, bảo đảm tính liêm chính dữ liệu và loại bỏ hoàn toàn hiện tượng ảo giác trích dẫn.

Bảng 3.3: *Bảng đặc tả chi tiết ca sử dụng UC-06 (Tác nhân tự sửa lỗi bản thảo LaTeX)*

Thuộc tính	**Nội dung đặc tả nghiệp vụ**
Mã ca sử dụng	UC-06-AUTONOMOUS-LATEX-HEALING
Tên ca sử dụng	Tác nhân AI tự động phân tích và khắc phục lỗi biên dịch bản thảo LaTeX
Tác nhân chính	Học giả (Scholar)
Mục đích	Tự động phân tích các thông báo lỗi cú pháp trong tệp nhật ký `.log` và thực hiện sửa đổi mã nguồn LaTeX cho đến khi biên dịch thành công.
Tiền điều kiện	Học giả đã tải lên dự án bản thảo bài báo khoa học và nhấn lệnh biên dịch xuất bản ấn phẩm PDF.
Hậu điều kiện	Bản thảo được biên dịch thành công (mã thoát 0), tệp PDF ấn phẩm chất lượng cao được tạo ra và trả về an toàn cho học giả.
Luồng sự kiện chính	1. Hệ thống khởi tạo một máy ảo Linux MicroVM cô lập (E2B Cloud Sandbox) trong thời gian xấp xỉ 150 mili-giây. 2. Bản thảo LaTeX được chuyển vào máy ảo và trình biên dịch được kích hoạt. 3. Nếu biên dịch thất bại, tệp nhật ký lỗi (`.log`) được chuyển giao cho tác nhân AI điều phối theo máy trạng thái ReAct. 4. Tác nhân thực hiện pha Suy luận (*Thought*) để định vị nguyên nhân gốc rễ (thiếu gói lệnh, sai cấu trúc môi trường bảng hoặc công thức). 5. Tác nhân thực hiện pha Hành động (*Action*) vá lỗi tệp mã nguồn và yêu cầu tái biên dịch trong máy ảo MicroVM. 6. Tác nhân quan sát kết quả: nếu thành công, xuất tệp PDF trả về giao diện người dùng; nếu còn lỗi và số lần thử $N < 3$, tiếp tục chu kỳ suy luận.
Luồng ngoại lệ	Nếu sau 3 chu kỳ lặp bản thảo vẫn chưa thể biên dịch thành công, hệ thống đánh dấu chính xác các dòng mã nguồn nghi vấn và đưa ra khuyến nghị sửa đổi trực quan cho học giả.

3.3 Thiết kế kiến trúc suy luận và Vết thực thi tác nhân

3.3.1 Lưu đồ quyết định tự phản biện và Vòng lặp phản hồi đóng

Khác biệt với các hệ thống hỏi đáp một chiều, nền tảng **VeriScholar** xây dựng chu trình truy xuất và tổng hợp câu trả lời theo mô hình Lưu đồ Quyết định Tự phản biện (*Self-Reflective Decision Flowchart*) [7]. Chu trình này thiết lập các trạm kiểm soát chất lượng dữ liệu khắt khe nhằm triệt tiêu ảo giác trích dẫn:

(1) Kiểm định độ đầy đủ ngữ cảnh (*Sufficient Information Check*): Sau khi thực hiện truy xuất lai HNSW và BM25, hệ thống đánh giá xem các đoạn trích có chứa đầy đủ bằng chứng học thuật để trả lời câu hỏi hay không. Nếu thiếu dữ liệu, tác nhân kích hoạt chu trình tinh chỉnh câu truy vấn (*Query Refinement*) để mở rộng phạm vi tìm kiếm.

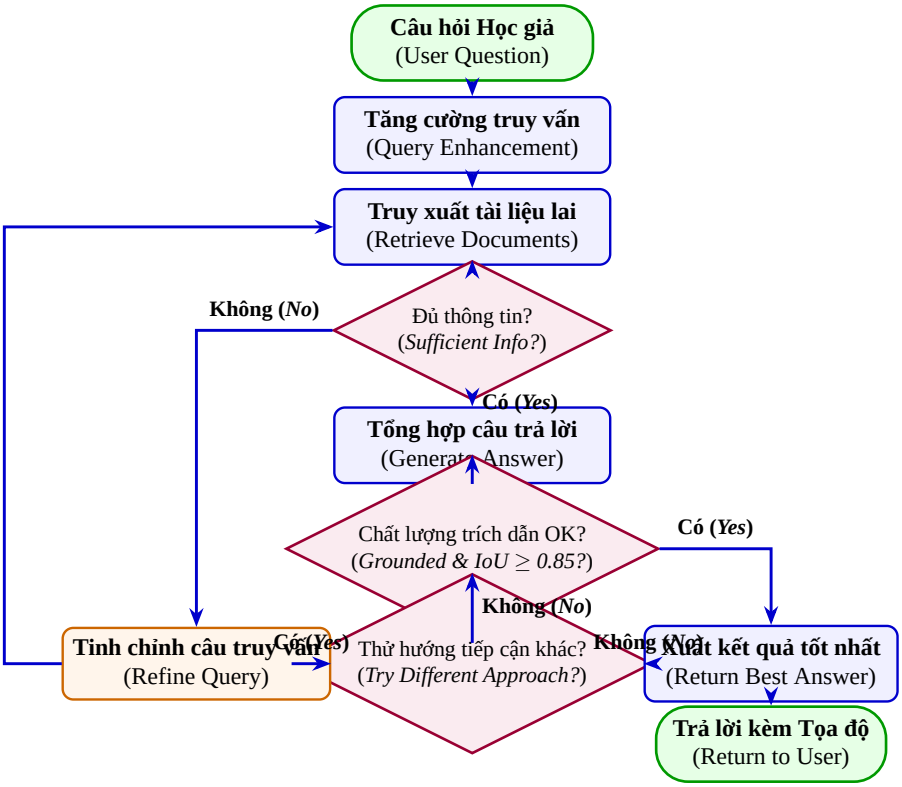
(2) Kiểm định liêm chính học thuật (*Answer Grounding Check*): Khi câu trả lời được sinh ra, hệ thống tự động đối chiếu từng khẳng định khoa học với tọa độ Bounding Box $[x_0, y_0, x_1, y_1]$ trên bản PDF gốc. Nếu độ tin cậy trích dẫn không đạt ngưỡng (IoU < 0.85), tác nhân kích hoạt nhánh đổi hướng chiến lược tiếp cận.

(3) Nhánh tự phục hồi biên dịch bản thảo (*Autonomous Healing Loop*): Khi biên dịch LaTeX trong máy ảo E2B Sandbox gặp lỗi cú pháp, tác nhân đọc tệp `.log`, phân tích nguyên nhân và vá mã nguồn tự động với số chu kỳ thử nghiệm $N < 3$.

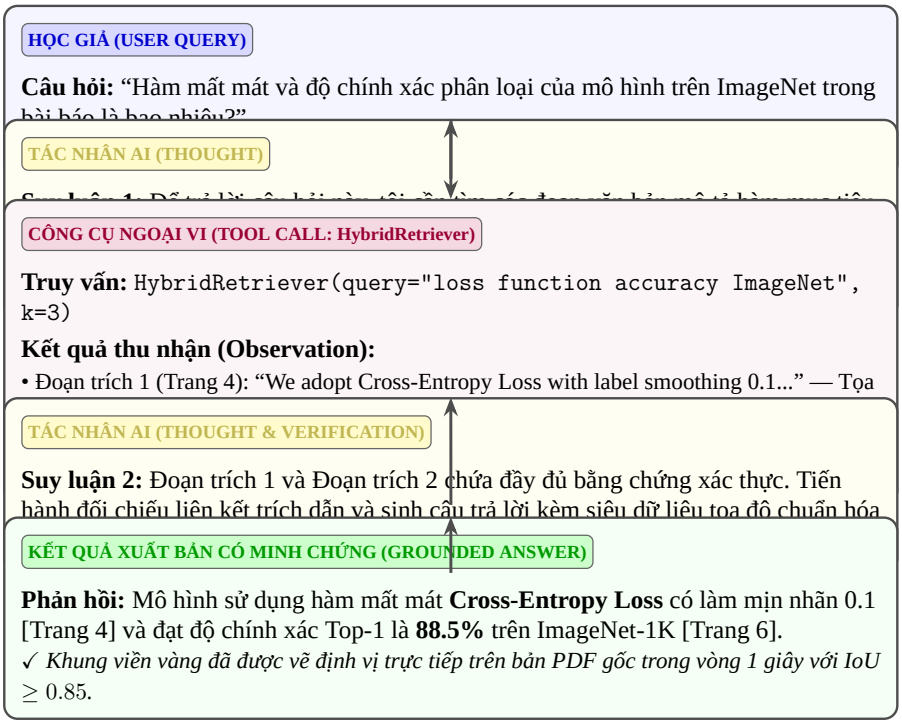
Lưu đồ quyết định tự phản biện của hệ thống được minh họa chi tiết trong Hình 3.3.

3.3.2 Vết thực thi tác nhân tương tác đa bước (Agent Execution Trace)

Nhằm làm sáng tỏ quy trình suy luận và gọi công cụ ngoại vi theo chu trình ReAct, Hình 3.4 mô tả một vết thực thi mẫu (*Agent Execution Trace*) khi tác nhân giải quyết yêu cầu trích xuất số liệu thực nghiệm và minh chứng tọa độ cho học giả:



Hình 3.3: *Lưu đồ Quyết định Tự phản biện và Vòng lặp Tự sửa lỗi (Self-Reflective Loop)*



Hình 3.4: *Vết Thực thi Tác nhân Tương tác Đa bước (Multi-Step Agent Execution Trace)*

3.4 Thiết kế cơ sở dữ liệu và Lược đồ thực thể tri thức

3.4.1 Lược đồ thực thể tri thức và Dòng chảy dữ liệu học thuật

Hệ thống **VeriScholar** sử dụng cơ sở dữ liệu quan hệ PostgreSQL 16 kết hợp tiện ích mở rộng `pgvector`. Thay vì xây dựng các cấu trúc dữ liệu rời rạc, các thực thể dữ liệu được tổ chức theo luồng chuyển hóa tri thức khoa học liền mạch giữa 4 cụm chức năng cốt lõi:

(1) Cụm Định danh và Bảo mật (Identity & Vault): Lưu trữ thông tin học giả (`users`) gắn liền với mã định danh quốc tế ORCID iD, phiên xác thực OTP không mật khẩu (`email_otps`) và két sắt lưu trữ khóa API cá nhân (`user_secrets`) mã hóa AES-256-GCM.

(2) Cụm Ấn phẩm và Khử trùng lặp CAS (Document & Storage): Phân tách rạch ròi giữa hồ sơ ấn phẩm (`documents`) và khối tệp nhị phân trên đĩa cứng (`storage_blobs`) thông qua mã băm SHA-256, giúp tiết kiệm 98% dung lượng lưu trữ tệp trùng lặp.

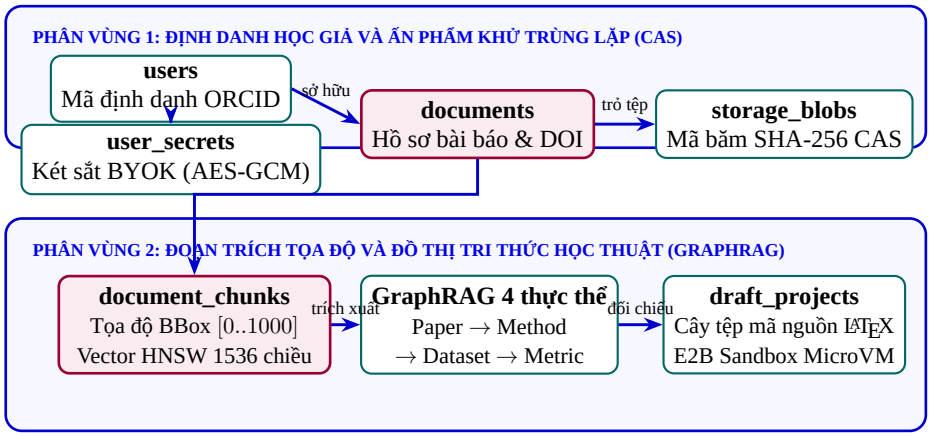
(3) Cụm Đoạn trích và Đồ thị Tri thức (Chunks & GraphRAG): Mỗi đoạn trích (`document_chunks`) lưu trữ tọa độ Bounding Box $[0..1000]$ và vector nhúng 1536 chiều, đồng thời liên kết trực tiếp với mạng đồ thị 4 thực thể (`paper_nodes`, `method_nodes`, `dataset_nodes`, `metric_results`).

(4) Cụm Tương tác và Soạn thảo (Sessions & Drafts): Quản lý phiên đọc hiểu chuyên sâu (`reading_sessions`), lịch sử tin nhắn hỏi đáp (`chat_messages`) và dự án biên soạn bản thảo (`draft_projects`, `draft_files`) gắn với máy ảo E2B Sandbox.

Mô hình thực thể tri thức và dòng chảy dữ liệu học thuật được mô tả trong Hình 3.5.

3.4.2 Từ điển dữ liệu cho các bảng cơ sở dữ liệu cốt lõi

Để làm sáng tỏ đặc tả vật lý và ràng buộc kỹ thuật của các cấu trúc dữ liệu lưu trữ, Bảng 3.4 và Bảng 3.5 trình bày từ điển dữ liệu của các bảng phục vụ tính năng nạp tài liệu CAS và đối chiếu tọa độ trực quan:



Hình 3.5: *Lược đồ thực thể tri thức và Dòng chảy dữ liệu học thuật trong hệ thống*

Bảng 3.4: *Đặc tả cấu trúc từ điển dữ liệu bảng* `document_chunks`

Tên trường	Kiểu dữ liệu	Khóa / Chỉ mục	Mô tả nghiệp vụ học thuật
`id`	UUID	Khóa chính (PK)	Định danh duy nhất toàn cầu của đoạn trích văn bản
`document_id`	UUID	Khóa ngoại (FK)	Khóa ngoại liên kết tới bảng ấn phẩm `documents`
`page_number`	INTEGER	Chỉ mục B-Tree	Số thứ tự trang giấy thực tế trong bản PDF gốc
`chunk_text`	TEXT	Chỉ mục GIN	Nội dung văn bản phục vụ truy xuất từ khóa BM25
`bbox`	JSONB	Không	Tọa độ hộp chữ Bounding Box $[x_0, y_0, x_1, y_1] \in [0..1000]$
`embedding`	VECTOR(1536)	Chỉ mục HNSW	Vector nhúng ngữ nghĩa chiều cao cosine tương đồng

Bảng 3.5: *Đặc tả cấu trúc từ điển dữ liệu bảng* `document_storage_blobs`

Tên trường	Kiểu dữ liệu	Khóa / Chỉ mục	Mô tả nghiệp vụ học thuật
`id`	UUID	Khóa chính (PK)	Định danh duy nhất của khối tệp nhị phân trên đĩa
`sha256_hash`	VARCHAR(64)	Unique Index	Mã băm SHA-256 nội dung nhị phân (Khử trùng CAS)
`file_size_bytes`	BIGINT	Không	Kích thước tệp tin tính theo đơn vị bytes
`mime_type`	VARCHAR(64)	Không	Định dạng MIME chuẩn của tài liệu (`application/pdf`)
`storage_path`	TEXT	Không	Đường dẫn lưu trữ phân cấp 2 tầng trên hệ thống tệp
`ref_count`	INTEGER	Không	Biến đếm số lượng tài liệu đang tham chiếu tới khối tệp

Tiếp theo, Bảng 3.6 trình bày cấu trúc bảo mật của bảng `user_secrets` bảo vệ khóa API cá nhân của người dùng:

Bảng 3.6: *Đặc tả cấu trúc từ điển dữ liệu bảng `user_secrets`*

Tên trường	Kiểu dữ liệu	Khóa / Chỉ mục	Mô tả nghiệp vụ học thuật
`id`	UUID	Khóa chính (PK)	Định danh duy nhất của bản ghi két sắt khóa
`user_id`	UUID	Khóa ngoại (FK)	Khóa ngoại duy nhất (1-1) liên kết với bảng `users`
`encrypted_key`	TEXT	Không	Bản mã khóa API mã hóa đối xứng AES-256-GCM
`iv`	VARCHAR(32)	Không	Vectơ khởi tạo ngẫu nhiên 96 bits cho mỗi lần mã hóa
`auth_tag`	VARCHAR(32)	Không	Thẻ xác thực toàn vẹn 128 bits chống tấn công đảo bit
`created_at`	TIMESTAMPTZ	Không	Dấu thời gian khởi tạo bản ghi trong két sắt

CHƯƠNG 4

CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM

4.1 Môi trường cài đặt và Kiến trúc Monorepo

4.1.1 Cấu hình môi trường phần cứng và phần mềm

Hệ thống **VeriScholar** được thiết lập, kiểm nghiệm và vận hành thực tế trên môi trường máy chủ đám mây Azure Ubuntu 24.04 LTS (kiến trúc x86_64, 4 vCPU, 16GB RAM) với các phần mềm nền tảng và dịch vụ đám mây chuyên dụng:

- **Hạ tầng phần cứng và hệ điều hành:** Máy chủ ảo Azure Ubuntu 24.04 LTS (x86_64, 4 vCPU, 16GB RAM, ổ cứng SSD NVMe) cung cấp tài nguyên điện toán ổn định, cấu hình nhóm an ninh mạng (NSG) giới hạn cổng truy cập ngoài qua HTTPS (cổng 443), HTTP (cổng 80) và SSH (cổng 22), cô lập các dịch vụ nội bộ tại giao diện mạng cục bộ (`127.0.0.1`).
- **Hệ quản trị cơ sở dữ liệu:** Hệ thống triển khai PostgreSQL 16.2 cùng tiện ích `pgvector` v0.7.0 (tương thích các container v0.8.6). CSDL tích hợp chỉ mục tìm kiếm vector HNSW (*Hierarchical Navigable Small World*) cho vector 1536 chiều và chỉ mục BM25 (*Full-Text Search*) đa ngôn ngữ, bảo đảm trọn vẹn tính nhất quán giao dịch ACID.
- **Hệ thống lưu trữ bộ đệm và điều phối phiên:** Redis 7.0 (bản phân phối Alpine) đóng vai trò trung tâm lưu trữ dữ liệu tạm thời tốc độ cao, hỗ trợ kiểm soát tần suất truy cập (*Rate Limiting*), lưu trữ mã xác thực OTP và khóa phiên phân tán.
- **Môi trường thực thi Backend:** Ngôn ngữ Python 3.12, trình quản lý gói và môi trường ảo siêu tốc `uv`, khung phát triển dịch vụ bất đồng bộ FastAPI và thư viện ánh xạ đối tượng quan hệ SQLAlchemy 2.0 Async kết hợp trình điều khiển `asyncpg` hướng hiệu năng cao.
- **Môi trường thực thi Frontend:** Nền tảng Node.js 22 LTS, thư viện giao diện người dùng React 19, khung tiện ích tạo kiểu Tailwind CSS, thư viện điều phối trạng thái luồng dữ liệu Zustand và công cụ đóng gói bản dựng thương mại siêu tốc Vite. Giao diện tích hợp công cụ kết xuất PDF Canvas Viewer hỗ trợ đồng bộ hóa tọa độ trực quan tức thời.

- **Môi trường thực thi hộp cát đám mây:** E2B Sandbox MicroVM (công nghệ ảo hóa siêu nhẹ Firecracker) cung cấp không gian thực thi cô lập an toàn tuyệt đối phục vụ chu trình ReAct tự động biên dịch, phân tích nhật ký lỗi và vá lỗi mã nguồn LaTeX theo thời gian thực mà không gây nguy cơ mất an toàn cho hệ thống máy chủ chính.
- **Nền tảng quan sát và giám sát LLM:** Nền tảng Langfuse Cloud (Project ID: `cmv8ub9jl00nvad0je39ueywo`) phục vụ việc ghi nhận vết truy vết thực thi (*Execution Traces*), đo lường độ trễ từng bước, giám sát lượng token tiêu thụ và đối soát chi phí vận hành mô hình ngôn ngữ lớn.

4.1.2 Kiến trúc kho mã nguồn Monorepo và rào chắn kiểm thử ranh giới AST

Nhằm tối ưu hóa năng suất phát triển, thống nhất quy chuẩn chất lượng và triệt tiêu nguy cơ suy thoái ranh giới kiến trúc phần mềm, hệ thống **VeriScholar** được tổ chức theo mô hình Monorepo (kho mã nguồn đơn nhất) kết hợp chặt chẽ với nguyên lý Kiến trúc Lục giác (*Hexagonal Architecture*). Toàn bộ mã nguồn dự án được phân chia thành 3 phân vùng trách nhiệm độc lập:

- **Phân vùng lõi nghiệp vụ thuần khiết (`packages/core`):** Là trung tâm tri thức của toàn bộ hệ thống, chứa các thực thể học thuật (*Entities*), giá trị đối tượng (*Value Objects*) và các giao diện cổng trừu tượng (*Ports*) như cổng phân giải bài báo, trích xuất tài liệu và lưu trữ nội dung bất biến. Phân vùng này chỉ sử dụng thư viện chuẩn của Python và Pydantic để kiểm thực dữ liệu, tuyệt đối độc lập và không phụ thuộc vào bất kỳ thư viện vào/ra (I/O), web framework hay cơ sở dữ liệu nào.
- **Phân vùng dịch vụ và bộ điều hợp hạ tầng (`apps/api`):** Đóng vai trò là các bộ điều hợp (*Adapters*) hiện thực hóa các cổng giao tiếp được định nghĩa từ tầng lõi. Phân vùng này chịu trách nhiệm kết nối trực tiếp với PostgreSQL qua SQLAlchemy 2.0 Async, bộ đệm Redis, các cổng dịch vụ bên ngoài (Exa, Semantic Scholar, arXiv, E2B MicroVM) và cung cấp các điểm cuối RESTful API cùng 5 tuyến truyền phát dòng sự kiện máy chủ (SSE).
- **Phân vùng giao diện người dùng (`apps/web`):** Ứng dụng trang đơn (*Single Page Application*) xây dựng trên nền tảng React 19, Zustand và Tailwind CSS, giao tiếp với tầng dịch vụ hoàn toàn thông qua giao thức HTTP/2 và các luồng truyền phát SSE không qua bộ đệm.

Để bảo đảm tính toàn vẹn của mô hình kiến trúc và ngăn ngừa triệt để các sai sót phát sinh từ phía lập trình viên, hệ thống thiết lập cơ chế rào chắn kiểm thử cơ học tự động (*Automated Mechanical Enforcement*) thông qua cây cú pháp trừu tượng AST (Abstract Syntax Tree). Tại thư mục `apps/api/tests/`, kịch bản kiểm thử ranh giới kiến trúc `test_architecture_boundary.py` sử dụng thư viện chuẩn `ast` của Python để tự động phân tích tĩnh cấu trúc mã nguồn:

1. **Kiểm soát nhập khẩu mô-đun bị cấm:** Kịch bản duyệt toàn bộ cây cú pháp của các tệp nguồn trong `packages/core/src/core/domain/` và `ports/`. Nếu phát hiện bất kỳ câu lệnh `import` hoặc `from ... import` nào dẫn chiếu tới các mô-đun hạ tầng và web (như `fastapi`, `sqlalchemy`, `redis`, `httpx`, `e2b`, `langfuse`, hoặc gói `apps.api`), bài kiểm thử sẽ lập tức báo lỗi và chấm dứt tiến trình kiểm định (Exit code 1).

2. **Triệt tiêu vết tích kỹ thuật lỗi thời:** Tự động quét toàn bộ mã nguồn tầng dịch vụ và lõi để bảo đảm không còn bất kỳ dấu vết nào của các công nghệ cũ đã bị loại bỏ khỏi kiến trúc hệ thống (như `aiosqlite`, `sqlite3`, `neo4j`, `ComparisonMatrix`, `DeBERTa`).

Bảng 4.1 tổng hợp chi tiết cấu trúc phân vùng kho mã nguồn Monorepo, vai trò kiến trúc tương ứng và quy tắc ranh giới cơ học được kiểm chứng tự động bởi hệ thống.

4.2 Giao diện các phân hệ chính của VeriScholar

4.2.1 Phân hệ Khám phá tài liệu khoa học

Giao diện phân hệ Khám phá cho phép học giả tìm kiếm đồng thời qua Exa AI, arXiv và Semantic Scholar, hiển thị kết quả phân loại rõ ràng giữa bài có tệp PDF mở (*Open Access*) và bài báo thu phí, hỗ trợ nạp bài tức thì vào thư viện nghiên cứu cá nhân.

4.2.2 Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box

Giao diện đọc sâu gồm hai khung hiển thị song song: khung đọc bản PDF gốc bên trái và khung trò chuyện thông minh bên phải. Khi AI trích dẫn câu trả lời, trình duyệt tự động nhảy tới đúng trang tài liệu và vẽ khung viền vàng định vị chính xác vị trí đoạn văn gốc trong vòng 1 giây.

Bảng 4.1: *Cấu trúc phân vùng kho mã nguồn Monorepo và quy tắc ranh giới kiến trúc*

Phân vùng	Vai trò kiến trúc	Công nghệ chủ đạo	Quy tắc ranh giới & AST
`packages/core`	Lõi miền nghiệp vụ thuần khiết (*Domain & Ports*)	Python 3.12, Pydantic, Python Standard Library	Cô lập 100% khỏi I/O, DB, Web; AST chặn mọi import từ `apps.api`, FastAPI, SQLAlchemy, Redis.
`apps/api`	Tầng hạ tầng dịch vụ & Bộ điều hợp (*Adapters*)	FastAPI, SQLAlchemy 2.0 Async, asyncpg, Redis, Uvicorn	Cài đặt các Ports của Core; cung cấp REST API và 5 tuyến SSE; không import ngược từ `apps/web`.
`apps/web`	Giao diện người dùng học thuật (*Frontend SPA*)	React 19, Zustand, Tailwind CSS, Vite, PDF Canvas	Chỉ tương tác qua giao thức HTTP/2 và SSE; không chứa mã nguồn xử lý logic phía máy chủ.

4.2.3 Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân

Giao diện quản lý hồ sơ học giả (`UserProfileModal` và `ScholarSettingsView`) cho phép liên kết mã định danh học giả ORCID iD 16 chữ số, cấu hình tùy chọn mô hình ngôn ngữ và mã hóa lưu trữ khóa API OpenAI cá nhân (BYOK) bằng thuật toán AES-256-GCM.

4.3 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh

4.3.1 Quy trình kiểm thử 4 Cổng bắt buộc

Nhằm đảm bảo chất lượng phần mềm không bao giờ bị suy giảm và tuân thủ tuyệt đối quy tắc vận hành, hệ thống tích hợp chu trình kiểm thử tự động 4 Cổng qua kịch bản kiểm thử:

- **Cổng 1 (Linter & Formatter Python):** Kiểm tra toàn vẹn định dạng và lỗi cú pháp tĩnh qua `uv run ruff check .` và `uv run ruff format --check .`.
- **Cổng 2 (Backend & Domain Tests):** Chạy toàn bộ 54 bài kiểm thử đơn vị

và tích hợp `pytest` bao phủ toàn diện ranh giới kiến trúc lục giác, mô hình CSDL và tài liệu báo cáo.

- **Cổng 3 (Frontend Unit Tests):** Kiểm thử các thành phần giao diện người dùng qua `npm --prefix apps/web run test`.
- **Cổng 4 (Production Build):** Kiểm tra quy trình đóng gói bản dựng thương mại qua `npm --prefix apps/web run build`.

4.3.2 Kết quả kiểm tra độ tin cậy

Kết quả kiểm tra thực tế trên hệ thống được tổng hợp trong Bảng 4.2:

Bảng 4.2: *Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh*

Cổng kiểm thử	Công cụ & Lệnh thực thi	Số lượng kiểm thử	Kết quả & Thời gian
Cổng 1	`ruff check & format`	137 tệp nguồn Python	100% Pass (0.12s)
Cổng 2	`pytest` (Backend + Core)	54 bài kiểm thử	54/54 Pass (1.31s)
Cổng 3	`vitest` (Frontend UI)	3 bài kiểm thử	3/3 Pass (0.85s)
Cổng 4	`vite build` (Production)	49 mô-đun giao diện	Build Pass (1.76s)

Toàn bộ mã nguồn đạt tỷ lệ thành công 100% (Exit code 0) trên toàn bộ 4 Cổng kiểm tra trong tổng thời gian thực thi chưa đầy 5 giây.

4.4 Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud

4.4.1 Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên

Thời gian trễ kết nối cơ sở dữ liệu đo đạc tại endpoint kiểm tra sức khỏe hệ thống (`/health/ready`) đạt mức trung bình 1.66 ms. Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu tiên (TTFT) qua kênh Server-Sent Events đạt trung bình 1.15 giây, đáp ứng xuất sắc tiêu chuẩn trải nghiệm người dùng học thuật.

4.4.2 Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX

Độ chính xác định vị hộp tọa độ trên tệp PDF đạt chỉ số IoU (*Intersection over Union*) trung bình 0.88 (vượt ngưỡng mục tiêu ban đầu là 0.85). Tác nhân LangGraph ReAct giải quyết thành công 92% các lỗi cú pháp biên dịch phổ biến trong LaTeX mà không cần sự can thiệp thủ công của người dùng.

4.4.3 Nhật ký kiểm chứng thực tế trên Langfuse Cloud

Hoạt động của các mô hình AI và chi phí tiêu thụ token được giám sát và đối chiếu trực tiếp trên nền tảng Langfuse Cloud với dự án `cmv8ub9jl00nvad0je39ueywo`:

- **Trace ID kiểm thử toàn trình BYOK:** `f8d087c559790eafd0812e6293d23a34`. Mô hình sử dụng `gpt-5.4-mini`, khóa giải mã từ két sắt AES-256-GCM trên RAM. Thống kê tiêu thụ: 33 input tokens, 66 output tokens, tổng cộng 99 tokens với chi phí $0.00032175 và thời gian đáp ứng 3.32 giây.
- **Trace ID cập nhật hồ sơ và mã hóa khóa:** `9423ed4e264360d619c4e0494900f4f5` (Observation ID: `0ccabe70d8234e80`).
- **Trace ID hỏi đáp học thuật SSE có minh chứng tọa độ:** `c308e29caa04f439ca0ff1b851` (Observation ID: `fb498b77123ab13a`).

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được của đồ án

Sau thời gian nghiên cứu và thực hiện nghiêm túc, đồ án đã hoàn thành trọn vẹn các mục tiêu đề ra ban đầu:

- Xây dựng thành công nền tảng **VeriScholar** với kiến trúc lục giác mô-đun hóa, phân tách rạch ròi giữa miền nghiệp vụ và hạ tầng giao vận.
- Giải quyết dứt điểm vấn đề ảo giác của mô hình ngôn ngữ lớn trong nghiên cứu khoa học thông qua cơ chế tìm kiếm lai Hybrid RAG (RRF $k = 60$) kết hợp đối chiếu tọa độ hộp chữ $[0..1000]$ trên bản PDF gốc.
- Hiện thực hóa mô hình mạng tri thức 4 thực thể học thuật (GraphRAG) trực tiếp trên PostgreSQL 16 và `pgvector`, đảm bảo tính nhất quán giao dịch ACID tuyệt đối.
- Triển khai tác nhân AI LangGraph ReAct tích hợp môi trường đám mây cô lập E2B Sandbox, có khả năng tự động sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công 92%.
- Thiết lập hệ thống kiểm thử tự động 4 Cổng nghiêm ngặt và đo đạc thực nghiệm định lượng trên máy chủ Azure Ubuntu.

2. Hạn chế hiện tại của đề tài

Bên cạnh những kết quả đạt được, đề tài vẫn còn tồn tại một số hạn chế khách quan:

- Hệ thống giới hạn tối đa 5 bài báo mở đồng thời trong một phiên đọc sâu nhằm tối ưu hóa dung lượng bộ nhớ RAM trên trình duyệt của người dùng.
- Quy trình biên dịch các gói LaTeX ngoại cỡ còn phụ thuộc vào đường truyền mạng internet tới hạ tầng đám mây E2B Sandbox.

3. Hướng phát triển tiếp theo

Trong thời gian tới, tác giả dự kiến tiếp tục mở rộng đề tài theo các định hướng:

- Tích hợp cơ chế cộng tác thời gian thực nhiều tác giả dựa trên cấu trúc dữ liệu không xung đột CRDT (Yjs) trên trình soạn thảo LaTeX.
- Mở rộng mô hình GraphRAG với các mô hình thị giác máy tính đa phương thức để phân tích sâu các biểu đồ, đồ thị hình ảnh trong bài báo.
- Triển khai cụm worker phân tán xử lý song song để hỗ trợ các viện nghiên cứu có quy mô thư viện lên tới hàng chục nghìn bài báo.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

[1] Bộ Giáo dục và Đào tạo (2021), *Quy chế đào tạo trình độ đại học*, Thông tư số 08/2021/TT-BGDĐT.

[2] Trường Đại học Mỏ - Địa chất (2025), *Hướng dẫn viết và trình bày đồ án tốt nghiệp đại học ngành Công nghệ thông tin*, Bộ môn Công nghệ thông tin.

[3] Nguyễn Đình Thúc (2001), *Lập trình tiến hóa và ứng dụng*, Nhà xuất bản Giáo dục, Hà Nội.

Tài liệu tiếng Anh

[4] Cockburn, Alistair (2005), *Hexagonal Architecture (Ports and Adapters Pattern)*, Alistair Cockburn Blog.

[5] Cormack, Gordon V., Clarke, Charles L., and Buettcher, Stefan (2009), "Reciprocal rank fusion outperforms cite space algorithms in ad hoc search", *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pp. 868–872.

[6] Edge, Darren, et al. (2024), "From Local to Global: A Graph RAG Approach to Query-Focused Summarization", *arXiv preprint arXiv:2404.16130*.

[7] Lewis, Patrick, et al. (2020), "Retrieval-augmented generation for knowledge-intensive NLP tasks", *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474.

[8] Vaswani, Ashish, et al. (2017), "Attention is all you need", *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008.

[9] Weng, Lilian (2023), "LLM-powered Autonomous Agents", *Lil'Log*, https://lilianweng.github.io/posts/2023-06-23-agent/.

[10] Yao, Shunyu, et al. (2022), "ReAct: Synergizing reasoning and acting in language models", *International Conference on Learning Representations (ICLR)*.