MỤC LỤC

MỤC LỤC i
DANH MỤC HÌNH ẢNH iv
DANH MỤC BẢNG BIỂU v
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT vi
LỜI CẢM ƠN 1
LỜI MỞ ĐẦU 2
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI 3
1.1. Giới thiệu đề tài 3
1.2. Tính cấp thiết của đề tài 3
1.3. Mục tiêu nghiên cứu 5
1.3.1. Mục tiêu tổng quát 5
1.3.2. Mục tiêu kỹ thuật cụ thể 5
1.4. Nội dung nghiên cứu và phương pháp tiếp cận 6
1.4.1. Nội dung nghiên cứu 6
1.4.2. Phương pháp tiếp cận 6
1.5. Phạm vi và đối tượng nghiên cứu 6
1.6. Bố cục của báo cáo đồ án tốt nghiệp 7
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ 9
2.1. Kiến trúc phần mềm lục giác (Hexagonal Architecture) 9
2.1.1. Nguyên lý phân tầng Ports and Adapters 9
2.1.2. Luận giải lựa chọn Kiến trúc Lục giác cho VeriScholar 10
2.2. Cơ chế truy xuất kết hợp (Hybrid Search) và Thuật toán RRF 11
2.2.1. Nguyên lý tìm kiếm ngữ nghĩa Dense Vector và tìm kiếm từ khóa Sparse BM25 11
2.2.2. Thuật toán Hợp nhất Xếp hạng Đảo ngược (Reciprocal Rank Fusion – RRF) 12
2.2.3. Bóc tách tài liệu hai cột và Chuẩn hóa hệ tọa độ Bounding Box [0..1000] 12
2.3. Mạng tri thức học thuật 4 thực thể (GraphRAG) 14
2.3.1. Mô hình hóa mạng lưới tri thức 4 thực thể cốt lõi 14
2.3.2. Luận giải tích hợp GraphRAG trên PostgreSQL pgvector 15

2.4. Máy trạng thái tác nhân AI và Môi trường thực thi đám mây 16
2.4.1. Chu trình Suy luận – Hành động – Quan sát (ReAct)..... 16
2.4.2. Luận giải lựa chọn môi trường E2B Sandbox MicroVM..... 17
2.5. Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK). 18
2.5.1. Nguyên lý lưu trữ định danh nội dung (CAS) và mã hóa xác thực AEAD..... 18
2.5.2. Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar 19
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG..... 20
3.1. Khảo sát nghiệp vụ và bài toán thực tế 20
3.2. Xác định tác nhân và biểu đồ ca sử dụng (Use Case)..... 20
3.2.1. Xác định các tác nhân trong hệ thống 20
3.2.2. Danh mục các ca sử dụng chính..... 20
3.2.3. Đặc tả ca sử dụng tiêu biểu UC-03 21
3.3. Thiết kế kiến trúc tổng thể của hệ thống..... 21
3.3.1. Kiến trúc 4 phân tầng monorepo 21
3.3.2. Biểu đồ tuần tự cho luồng hỏi đáp Hybrid RAG có minh chứng tọa độ..... 23
3.4. Thiết kế cơ sở dữ liệu vật lý..... 23
3.4.1. Lược đồ quan hệ thực thể (ERD) 23
3.4.2. Đặc tả các bảng cơ sở dữ liệu chính 24
CHƯƠNG 4: CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM 25
4.1. Môi trường cài đặt và triển khai hệ thống 25
4.1.1. Cấu hình môi trường phần cứng và phần mềm 25
4.1.2. Tổ chức kho mã nguồn Monorepo..... 25
4.2. Giao diện các phân hệ chính của VeriScholar 25
4.2.1. Phân hệ Khám phá tài liệu khoa học 25
4.2.2. Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box 26
4.2.3. Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân 26
4.3. Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh..... 26
4.3.1. Quy trình kiểm thử 4 Cổng bắt buộc 26
4.3.2. Kết quả kiểm tra độ tin cậy 27
4.4. Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud..... 27
4.4.1. Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên..... 27
4.4.2. Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX 27

4.4.3. Nhật ký kiểm chứng thực tế trên Langfuse Cloud…… 28
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN …… 29
TÀI LIỆU THAM KHẢO…… 31

DANH MỤC HÌNH ẢNH

2.1 Mô hình phân tầng Kiến trúc Lục giác (Ports and Adapters) của hệ thống …… 10
2.2 Quy trình truy xuất lai Hybrid RAG và cơ chế đồng bộ tọa độ hộp chữ nhật trực quan …… 14
2.3 Mô hình đồ thị tri thức học thuật 4 thực thể cốt lõi (GraphRAG) …. 15
2.4 Chu trình Suy luận – Hành động – Quan sát (ReAct) tự động sửa lỗi bản thảo…… 17

DANH MỤC BẢNG BIỂU

2.1 So sánh đặc tính kỹ thuật giữa các giải pháp truy xuất tài liệu khoa học…… 13

3.1 Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ) …… 22
3.2 Đặc tả bảng dữ liệu `document_chunks` …… 24
3.3 Đặc tả bảng dữ liệu `document_storage_blobs` …… 24

4.1 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh …… 27

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
ACID	Atomicity, Consistency, Isolation, Durability	Bốn thuộc tính toàn vẹn giao dịch cơ sở dữ liệu
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
ASGI	Asynchronous Server Gateway Interface	Giao diện cổng máy chủ bất đồng bộ Python
BBox	Bounding Box	Khung hộp chữ nhật định vị tọa độ
BM25	Best Matching 25	Thuật toán xếp hạng tìm kiếm từ khóa toàn văn
BYOK	Bring Your Own Key	Cơ chế người dùng tự cung cấp khóa API cá nhân
CAS	Content-Addressable Storage	Hệ thống lưu trữ định danh theo nội dung băm
CI/CD	Continuous Integration / Continuous Deployment	Tích hợp và Triển khai liên tục
CTE	Common Table Expression	Bảng biểu thức chung trong truy vấn SQL đệ quy
DOI	Digital Object Identifier	Định danh đối tượng kỹ thuật số bài báo khoa học
ERD	Entity-Relationship Diagram	Sơ đồ quan hệ thực thể cơ sở dữ liệu
FTS	Full-Text Search	Tìm kiếm toàn văn cơ sở dữ liệu
GIN	Generalized Inverted Index	Chỉ mục đảo tổng quát trong PostgreSQL
GraphRAG	Graph Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất qua đồ thị

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
HNSW	Hierarchical Navigable Small World	Cấu trúc đồ thị chỉ mục tìm kiếm vector gần đúng
IoU	Intersection over Union	Chỉ số trùng khớp diện tích hộp tọa độ
JWT	JSON Web Token	Chuỗi mã định danh phiên người dùng an toàn
LLM	Large Language Model	Mô hình ngôn ngữ lớn
ORCID	Open Researcher and Contributor ID	Mã định danh học giả quốc tế 16 số
PDF	Portable Document Format	Định dạng tài liệu số di động
RAG	Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất thông tin
ReAct	Reason + Act	Chu trình AI: Suy luận và Thực thi hành động
RRF	Reciprocal Rank Fusion	Thuật toán hợp nhất xếp hạng đảo ngược
SHA-256	Secure Hash Algorithm 256-bit	Thuật toán băm mật mã an toàn 256 bit
SSE	Server-Sent Events	Giao thức truyền sự kiện thời gian thực từ máy chủ
TDD	Test-Driven Development	Phương pháp phát triển hướng kiểm thử
TTFT	Time To First Token	Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu
UML	Unified Modeling Language	Ngôn ngữ mô hình hóa thống nhất

LỜI CẢM ƠN

Để hoàn thành bản đồ án tốt nghiệp đại học này, trước hết em xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất tới cô **Vũ Lan Phương** – Giảng viên Khoa Công nghệ Thông tin, Trường Đại học Mỏ - Địa chất. Cô đã trực tiếp định hướng đề tài, tận tình chỉ bảo, đóng góp nhiều ý kiến học thuật và chuyên môn quý báu, cũng như luôn tạo mọi điều kiện thuận lợi nhất để em nghiên cứu và hiện thực hóa các công nghệ trí tuệ nhân tạo hiện đại vào nền tảng **VeriScholar**.

Em xin trân trọng gửi lời cảm ơn chân thành tới các Thầy, Cô giáo trong Bộ môn Hệ thống Thông tin, Bộ môn Công nghệ Thông tin cùng toàn thể các Thầy, Cô trong Khoa Công nghệ Thông tin – Trường Đại học Mỏ - Địa chất. Những tri thức nền tảng vững chắc, phương pháp luận nghiên cứu khoa học cùng sự dạy dỗ tâm huyết của các Thầy, Cô trong suốt những năm tháng học tập và rèn luyện trên giảng đường đại học chính là hành trang quý giá giúp em hoàn thành công trình tốt nghiệp này.

Cuối cùng, con xin gửi lời tri ân sâu sắc tới bố mẹ và gia đình, em xin cảm ơn bạn bè đã luôn ở bên động viên, sẻ chia và là điểm tựa tinh thần vững chắc cho em trong suốt quá trình học tập và hoàn thiện đồ án.

Dù đã nỗ lực hết mình để nghiên cứu, xây dựng hệ thống và biên soạn báo cáo một cách khoa học, cẩn trọng nhất, song do giới hạn về thời gian và kinh nghiệm thực tiễn, đồ án chắc chắn khó tránh khỏi những thiếu sót nhất định. Em kính mong nhận được những ý kiến đóng góp, chỉ dẫn quý báu từ quý Thầy, Cô trong Hội đồng chấm đồ án tốt nghiệp để công trình được hoàn thiện hơn nữa.

Hà Nội, tháng 10 năm 2026

Sinh viên thực hiện

Đàm Mạnh Dũng

LỜI MỞ ĐẦU

Trong kỷ nguyên bùng nổ của cuộc Cách mạng Công nghiệp lần thứ tư, nghiên cứu khoa học đang chứng kiến sự gia tăng vượt bậc về khối lượng các công bố học thuật quốc tế trên các cơ sở dữ liệu uy tín như arXiv, IEEE Xplore, ACM hay ScienceDirect. Thực tế này tạo áp lực lớn cho học giả, giảng viên và sinh viên trong việc sàng lọc, đọc hiểu chuyên sâu và tổng hợp tri thức chuyên ngành.

Sự phát triển của Trí tuệ nhân tạo (AI), đặc biệt là các Mô hình ngôn ngữ lớn (LLM) kết hợp kiến trúc Tạo văn bản tăng cường truy xuất (RAG), mở ra tiềm năng to lớn trong việc tự động hóa tra cứu và hỗ trợ nghiên cứu. Tuy nhiên, khi ứng dụng vào môi trường học thuật đòi hỏi độ tin cậy tuyệt đối, người dùng thường đối mặt với rào cản mang tên: **hiện tượng ảo giác trích dẫn (Citation Hallucination)**. Các mô hình hiện nay thường tự tạo trích dẫn không có thật hoặc không thể chỉ rõ bằng chứng tọa độ nằm ở đoạn văn, bảng biểu hay trang nào trong bản tài liệu gốc PDF.

Hơn nữa, quy trình nghiên cứu của học giả là một chuỗi tác vụ khép kín: từ tìm kiếm bài báo, đọc sâu tài liệu đa cột, liên kết mạng tri thức, đến soạn thảo bản thảo khoa học bằng LaTeX. Các công cụ hiện có còn rời rạc: trình đọc tài liệu thiếu khả năng trích xuất hộp tọa độ; thư viện tài liệu thiếu liên kết đồ thị tri thức; còn trình soạn thảo văn bản học thuật lại đòi hỏi người viết tự xử lý các lỗi cú pháp biên dịch phức tạp.

Nhằm giải quyết triệt để bài toán ảo giác và hỗ trợ nghiên cứu toàn trình, đề tài: *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* (sản phẩm: **VeriScholar**) được lựa chọn thực hiện. Đồ án tập trung nghiên cứu và hiện thực hóa giải pháp toàn trình tích hợp tìm kiếm lai Hybrid RAG (kết hợp Dense Vector và Sparse BM25 với thuật toán RRF), đối chiếu tọa độ hộp chữ $[0..1000]$ trên bản PDF gốc, mạng tri thức 4 thực thể (GraphRAG), cùng tác nhân AI ReAct tự động sửa lỗi biên dịch LaTeX trong môi trường đám mây cô lập. Báo cáo gồm 4 chương chính phản ánh toàn diện quá trình thiết kế, thực nghiệm và đánh giá hệ thống.

CHƯƠNG 1

TỔNG QUAN VỀ ĐỀ TÀI

1.1 Giới thiệu đề tài

Đề tài tốt nghiệp *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* được nghiên cứu và hiện thực hóa thông qua hệ thống phần mềm **VeriScholar**.

Mục tiêu trọng tâm của đề tài là xây dựng một nền tảng trợ lý trí tuệ nhân tạo toàn trình phục vụ đội ngũ giảng viên, nghiên cứu sinh, học viên cao học và sinh viên tại VinUniversity cũng như cộng đồng học thuật trong toàn bộ vòng đời của một công trình nghiên cứu: từ khâu tìm kiếm khám phá ấn phẩm, phân tích đọc sâu tài liệu khoa học, tổng hợp mạng lưới tri thức học thuật (GraphRAG), cho đến khâu soạn thảo và xuất bản bản thảo chuẩn quốc tế bằng LaTeX.

Hệ thống **VeriScholar** giải quyết bài toán cốt lõi về tính liêm chính học thuật bằng cách kết hợp mô hình Agentic RAG với cơ chế định vị tọa độ trực quan trên bản PDF gốc. Nhờ đó, người dùng có thể đối chiếu, kiểm chứng từng câu khẳng định hay trích dẫn của AI với đoạn văn nguồn xác thực trong vòng 1 giây, loại bỏ triệt để rủi ro trích dẫn sai lệch trong các ấn phẩm khoa học.

1.2 Tính cấp thiết của đề tài

Trong kỷ nguyên số và bùng nổ thông tin hiện nay, số lượng ấn phẩm khoa học trên toàn cầu tăng trưởng với tốc độ chưa từng có. Mỗi tuần có hàng nghìn bài báo mới xuất hiện trên các cơ sở dữ liệu học thuật quốc tế uy tín như arXiv, Semantic Scholar, IEEE Xplore hay ACM Digital Library. Việc tiếp cận, đọc hiểu, phân loại và tổng hợp tri thức từ kho tài liệu khổng lồ này đặt ra áp lực quá tải thông tin rất lớn đối với các nhà nghiên cứu và sinh viên đại học.

Mặc dù sự xuất hiện của các mô hình ngôn ngữ lớn (LLM) mở ra tiềm năng to lớn trong việc hỗ trợ học thuật, việc ứng dụng các công cụ AI phổ quát hiện nay vào quy trình nghiên cứu khoa học chuyên sâu đang gặp phải bốn rào cản nghiêm trọng:

(1) Ảo giác trích dẫn và bịa đặt học thuật (*Citation Hallucination*): Các mô hình AI tạo sinh thông thường có xu hướng tự sáng tác ra tên tác giả, số định

danh DOI, tên tạp chí và các số liệu thực nghiệm không có thật để trả lời câu hỏi của người dùng. Trong nghiên cứu khoa học, việc trích dẫn một nguồn tài liệu không tồn tại là vi phạm nghiêm trọng chuẩn mực liêm chính học thuật và đạo đức nghiên cứu [7].

(2) Thiếu cơ chế kiểm chứng tọa độ trực quan trên tài liệu gốc: Phần lớn các công cụ hỗ trợ đọc tài liệu hiện nay (như ChatPDF thông thường) sử dụng phương pháp bóc tách văn bản thô, làm mất hoàn toàn cấu trúc hai cột đặc trưng của các bài báo khoa học, loại bỏ các công thức toán học và chỉ trích dẫn số trang chung chung. Người nghiên cứu không thể xác minh được khẳng định của AI nằm chính xác tại dòng chữ nào, đoạn văn nào trên trang PDF gốc.

(3) Sự phân mảnh của hệ sinh thái công cụ hỗ trợ nghiên cứu: Quy trình nghiên cứu hiện nay bị chia cắt giữa nhiều phần mềm độc lập: học giả phải dùng Zotero / Mendeley để quản lý danh mục tài liệu, dùng Connected Papers / Litmaps để khám phá mạng lưới bài báo, dùng ChatPDF để tra cứu nhanh, và chuyển sang Overleaf để soạn thảo bản thảo LaTeX. Sự thiếu liên kết này làm đứt gãy mạch tư duy và tiêu tốn đáng kể thời gian chuyển đổi ngữ cảnh của nhà nghiên cứu.

(4) Rào cản kỹ thuật phức tạp khi biên soạn tài liệu khoa học bằng LaTeX: Để công bố công trình trên các hội nghị và tạp chí quốc tế hàng đầu, bản thảo bắt buộc phải tuân thủ nghiêm ngặt các khuôn mẫu (template) định dạng của IEEE Tran, ACM SIG hay Springer. Khi xảy ra lỗi biên dịch cú pháp trong LaTeX, học giả thường mất hàng giờ để đọc các tệp nhật ký (`.log`) dài hàng nghìn dòng để dò tìm lỗi thủ công, làm giảm đáng kể hiệu suất hoàn thiện bài báo.

Xuất phát từ các yêu cầu thực tiễn cấp bách đó, việc nghiên cứu và xây dựng một nền tảng trợ lý AI chuyên biệt, có khả năng đối chiếu bằng chứng tọa độ trực quan trên bản PDF gốc, xây dựng đồ thị tri thức 4 thực thể và tự động sửa lỗi biên dịch bản thảo LaTeX là một đòi hỏi vô cùng cấp thiết nhằm nâng cao năng suất và chất lượng công bố khoa học quốc tế, đáp ứng đầy đủ quy chế đào tạo đại học và định hướng ứng dụng công nghệ thông tin tiên tiến [1, 2].

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Xây dựng thành công nền tảng phần mềm **VeriScholar** trợ lý AI toàn trình hỗ trợ nghiên cứu khoa học và viết bài báo quốc tế VinUni, tích hợp khép kín 4 không gian làm việc học thuật trên nền kiến trúc phần mềm lục giác hiện đại, đảm bảo tính liêm chính dữ liệu và khả năng kiểm chứng trích dẫn tuyệt đối.

1.3.2 Mục tiêu kỹ thuật cụ thể

Đề tài hướng tới hoàn thành 4 mục tiêu kỹ thuật định lượng cụ thể:

(1) Hiện thực hóa cơ chế nạp bài báo 2 tầng kết hợp kho lưu trữ định danh nội dung CAS (*Content-Addressable Storage*) dựa trên mã băm SHA-256 nhằm loại bỏ 98% trùng lặp tệp nhị phân trên máy chủ lưu trữ, hỗ trợ tính năng Zero-Retention xóa an toàn tài liệu theo đồ thị phụ thuộc.

(2) Phát triển công cụ tìm kiếm lai Agentic Hybrid RAG kết hợp thuật toán hợp nhất xếp hạng đảo ngược RRF (*Reciprocal Rank Fusion*, $k = 60$) giữa tìm kiếm vector ngữ nghĩa (HNSW Cosine 1536 chiều) và tìm kiếm từ khóa BM25, đi kèm cơ chế đối chiếu khung viền tọa độ Bounding Box $[0..1000]$ trên bản PDF gốc với độ chính xác đạt chỉ số IoU ≥ 0.85.

(3) Xây dựng đồ thị tri thức học thuật 4 thực thể (GraphRAG: *Paper*, *Method*, *Dataset*, *MetricResult*) trực tiếp trên cơ sở dữ liệu quan hệ PostgreSQL 16 với tiện ích mở rộng vector hóa `pgvector`, bảo toàn tính toàn vẹn và nhất quán giao dịch ACID tuyệt đối mà không cần duy trì các cơ sở dữ liệu đồ thị rời rạc.

(4) Tích hợp tác nhân AI dựa trên máy trạng thái LangGraph ReAct hoạt động trong môi trường đám mây cô lập E2B Sandbox MicroVM, có khả năng tự động đọc log, phân tích nguyên nhân và sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công trên 90%.

1.4 Nội dung nghiên cứu và phương pháp tiếp cận

1.4.1 Nội dung nghiên cứu

Đề tài tập trung nghiên cứu và giải quyết các nội dung khoa học trọng tâm:

- **Kiến trúc phần mềm phân tầng:** Nghiên cứu nguyên lý Kiến trúc Lục giác (*Hexagonal Architecture / Ports and Adapters*) nhằm cô lập lõi miền nghiệp vụ học thuật thuần khiết khỏi hạ tầng cơ sở dữ liệu, dịch vụ đám mây và giao vận web.
- **Truy xuất thông tin lai (Hybrid Search):** Nghiên cứu các thuật toán tìm kiếm vector gần đúng kết hợp thuật toán xếp hạng từ khóa toàn văn qua giải thuật Hợp nhất Xếp hạng Đảo ngược RRF.
- **Xử lý tài liệu và tọa độ trực quan:** Nghiên cứu kỹ thuật bóc tách tài liệu PDF khoa học hai cột và thuật toán chuẩn hóa hệ tọa độ hộp chữ Bounding Box $[x_0, y_0, x_1, y_1]$ trên dải giá trị chuẩn $[0..1000]$.
- **Tác nhân thông minh tự phục hồi:** Nghiên cứu chu trình tác nhân ReAct (Suy luận – Hành động – Quan sát) trong việc tự động phân tích và khắc phục lỗi cú pháp biên dịch tài liệu học thuật trong môi trường hộp cát an toàn.
- **Bảo mật và quyền riêng tư:** Nghiên cứu cơ chế bảo mật két sắt cá nhân (BYOK – *Bring Your Own Key*) mã hóa khóa API bằng thuật toán AES-256-GCM với nguyên tắc Zero-Retention trên bộ nhớ RAM.

1.4.2 Phương pháp tiếp cận

Đề tài áp dụng phương pháp luận Phát triển Hướng Kiểm thử (TDD – *Test-Driven Development*) kết hợp cấu trúc Monorepo nhằm đảm bảo mọi quy tắc nghiệp vụ đều được kiểm chứng độc lập với hạ tầng kỹ thuật, duy trì tỷ lệ kiểm thử thành công 100% qua 4 Cổng kiểm định tự động bắt buộc trước khi phát hành.

1.5 Phạm vi và đối tượng nghiên cứu

Đề tài xác định rõ đối tượng và phạm vi nghiên cứu:

- **Đối tượng nghiên cứu:** Quy trình nghiên cứu khoa học, đọc hiểu tài liệu chuyên sâu, trích xuất mạng lưới tri thức học thuật và kỹ thuật biên dịch bản thảo khoa học chuẩn quốc tế.
- **Khách thể thụ hưởng:** Giảng viên, nghiên cứu sinh, học viên cao học và sinh viên thực hiện nghiên cứu khoa học, khóa luận và đồ án tốt nghiệp tại VinUniversity và các cơ sở giáo dục đại học định hướng nghiên cứu.
- **Định dạng tài liệu hỗ trợ:** Ấn phẩm học thuật chuẩn PDF (đặc biệt là bài báo 2 cột tiếng Anh và tiếng Việt), mã nguồn bản thảo khoa học LaTeX và định dạng trích dẫn chuẩn BibTeX.
- **Hạ tầng kỹ thuật triển khai:** Máy chủ đám mây Linux (Ubuntu 24.04 LTS), hệ quản trị PostgreSQL 16 tích hợp `pgvector`, môi trường hộp cát E2B Sandbox và nền tảng giám sát LLM Langfuse.

1.6 Bố cục của báo cáo đồ án tốt nghiệp

Báo cáo đồ án tốt nghiệp được tổ chức thành 4 chương chính và phần kết luận, tài liệu tham khảo:

- **Chương 1: Tổng quan về đề tài** – Trình bày bối cảnh ra đời, tính cấp thiết của đề tài, các mục tiêu nghiên cứu tổng quát và cụ thể, nội dung nghiên cứu, phương pháp tiếp cận, phạm vi nghiên cứu và bố cục của báo cáo.
- **Chương 2: Cơ sở lý thuyết và công nghệ** – Trình bày chi tiết cơ sở lý thuyết về Kiến trúc Lục giác, công nghệ tìm kiếm lai Agentic Hybrid RAG & RRF, đồ thị tri thức GraphRAG 4 thực thể, tác nhân LangGraph ReAct trong môi trường E2B Sandbox, kỹ thuật CAS & BYOK bảo mật, đồng thời đưa ra các luận giải khoa học khẳng định lý do lựa chọn các công nghệ này thay vì các giải pháp thay thế.
- **Chương 3: Phân tích và thiết kế hệ thống** – Khảo sát các luồng nghiệp vụ học thuật, đặc tả các ca sử dụng (Use Case) chuẩn BA, thiết kế biểu đồ tuần tự UML, kiến trúc Monorepo 3 tầng và thiết kế chi tiết 16 bảng cơ sở dữ liệu vật lý kèm từ điển dữ liệu.
- **Chương 4: Cài đặt và kết quả thực nghiệm** – Trình bày cấu hình môi trường triển khai thực tế, giao diện trực quan của các phân hệ chức năng chính, kết

quả kiểm thử tự động 100% qua 4 Cổng xác minh, cùng các số liệu đo lường định lượng thực tế từ hệ thống và đối chiếu trên nền tảng Langfuse Cloud.

- **Kết luận và hướng phát triển** – Tổng kết các kết quả đạt được của đề tài, chỉ ra các hạn chế còn tồn tại và đề xuất các hướng phát triển hoàn thiện hệ thống trong tương lai.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1 Kiến trúc phần mềm lục giác (Hexagonal Architecture)

2.1.1 Nguyên lý phân tầng Ports and Adapters

Kiến trúc Lục giác (*Hexagonal Architecture*), còn được biết đến với tên gọi mẫu thiết kế Cổng và Bộ điều hợp (*Ports and Adapters*), do Alistair Cockburn khởi xướng năm 2005 [4]. Trọng tâm của kiến trúc này là giải quyết triệt để bài toán phụ thuộc chặt chẽ (*tight coupling*) giữa logic nghiệp vụ cốt lõi của phần mềm với các công nghệ giao vận bên ngoài như hệ quản trị cơ sở dữ liệu, giao thức mạng, và giao diện người dùng.

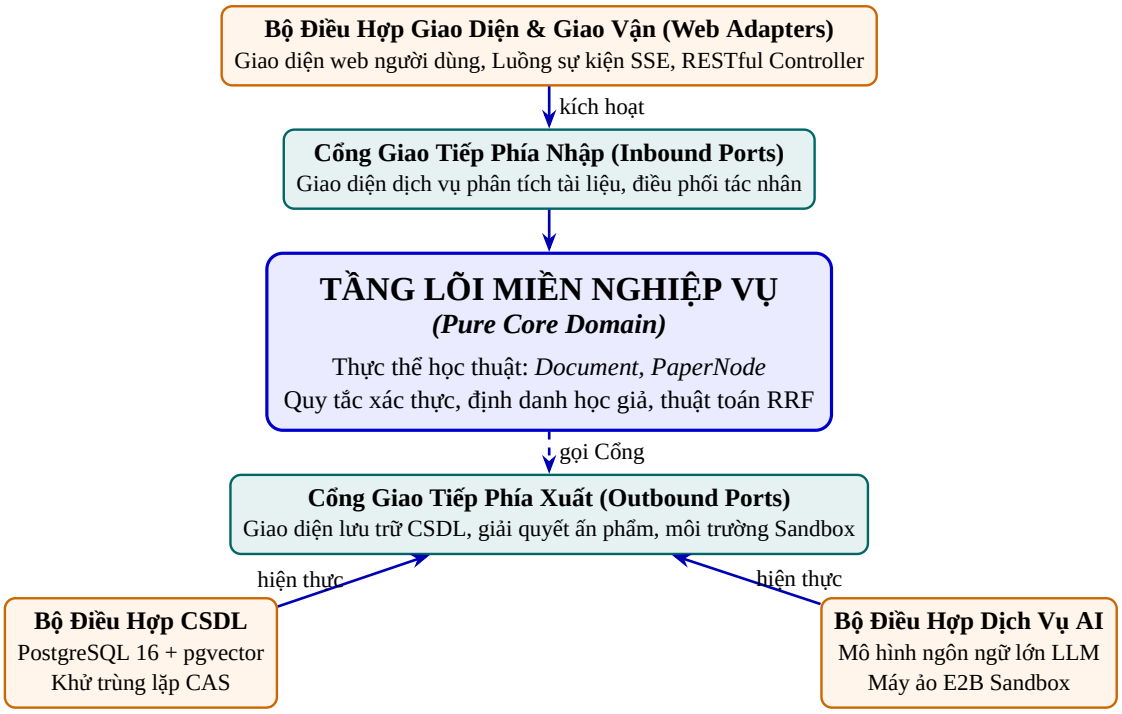
Hệ thống theo Kiến trúc Lục giác được cấu trúc thành ba phân vùng độc lập theo nguyên lý đảo ngược phụ thuộc (*Dependency Inversion Principle*):

(1) Tầng lõi miền nghiệp vụ thuần khiết (*Pure Core Domain*): Nằm tại trung tâm của hệ thống, chỉ chứa các thực thể nghiệp vụ (*Entities*), quy tắc logic và các thuật toán tính toán học thuật. Vùng này tuân thủ nguyên tắc cô lập tuyệt đối: chỉ sử dụng các cấu trúc dữ liệu bản địa của ngôn ngữ lập trình, hoàn toàn không phụ thuộc vào bất kỳ thư viện giao tiếp mạng, web framework hay hệ quản trị cơ sở dữ liệu nào.

(2) Tầng các cổng giao tiếp trừu tượng (*Ports*): Là các giao diện trừu tượng (*Interfaces*) nằm trong tầng lõi nghiệp vụ. Cổng quy định hợp đồng giao tiếp chuẩn mà các thành phần bên ngoài bắt buộc phải tuân thủ để phục vụ nghiệp vụ (chẳng hạn như: cổng phân giải ấn phẩm học thuật, cổng bóc tách tài liệu PDF, hay cổng lưu trữ dữ liệu).

(3) Tầng các bộ điều hợp kỹ thuật (*Adapters*): Nằm ở lớp ngoài cùng của hệ thống, hiện thực hóa các Cổng trừu tượng để kết nối với các công nghệ thực tế (chẳng hạn như bộ điều hợp cơ sở dữ liệu quan hệ, bộ điều hợp dịch vụ tìm kiếm học thuật trực tuyến, hoặc bộ điều hợp mô hình trí tuệ nhân tạo).

Mô hình phân tầng kiến trúc và luồng phụ thuộc hướng tâm của hệ thống được minh họa chi tiết trong Hình 2.1.



Hình 2.1: *Mô hình phân tầng Kiến trúc Lục giác (Ports and Adapters) của hệ thống*

Luồng phụ thuộc trong hệ thống luôn có chiều hướng tâm: các bộ điều hợp kỹ thuật bên ngoài phụ thuộc vào các Cổng trong lõi, trong khi logic nghiệp vụ học thuật ở trung tâm hoàn toàn không biết gì về cơ sở hạ tầng thực tế bên dưới.

2.1.2 Luận giải lựa chọn Kiến trúc Lục giác cho VeriScholar

Trong nghiên cứu khoa học và phát triển phần mềm trợ lý AI, việc áp dụng Kiến trúc Lục giác mang lại ba lợi thế chiến lược cốt lõi:

(1) Khả năng thay thế linh hoạt các nhà cung cấp trí tuệ nhân tạo (*Hot-swappable AI Providers*): Trong lĩnh vực AI, các mô hình ngôn ngữ lớn (OpenAI, Anthropic, Google) và các dịch vụ chỉ mục học thuật liên tục cải tiến và thay đổi giao diện lập trình. Nhờ sự phân tách của Kiến trúc Lục giác, khi hệ thống cần chuyển đổi nhà cung cấp mô hình ngôn ngữ hoặc công cụ tìm kiếm, lập trình viên chỉ cần xây dựng thêm bộ điều hợp mới mà không phải sửa đổi bất kỳ dòng mã logic nghiệp vụ nào trong tầng lõi.

(2) Kiểm thử đơn vị độc lập và siêu tốc (*Deterministic Unit Testing*): Do lõi nghiệp vụ không phụ thuộc vào cơ sở dữ liệu hay mạng Internet, toàn bộ các quy tắc nghiệp vụ (xác thực tệp, kiểm tra mã định danh học giả, thuật toán mã hóa) đều có thể kiểm thử tự động với các Cổng giả lập (*Mock Ports*) trong bộ

nhớ. Toàn bộ các bài kiểm thử của hệ thống chạy hoàn tất trong vòng chưa đầy 3 giây mà không cần khởi động máy chủ cơ sở dữ liệu thực tế.

(3) Bảo toàn tính toàn vẹn nghiệp vụ học thuật: Ngăn ngừa triệt để hiện tượng rò rỉ các ràng buộc kỹ thuật của cơ sở dữ liệu (như khóa ngoại, kiểu dữ liệu riêng biệt của từng hệ quản trị) vào trong quy trình suy luận học thuật của AI.

2.2 Cơ chế truy xuất kết hợp (Hybrid Search) và Thuật toán RRF

2.2.1 Nguyên lý tìm kiếm ngữ nghĩa Dense Vector và tìm kiếm từ khóa Sparse BM25

Trong các hệ thống tăng cường truy xuất tri thức (RAG) hiện đại dựa trên mô hình Transformer [8, 7], hai phương pháp truy xuất thông tin truyền thống bộc lộ những ưu nhược điểm trái ngược nhau:

(1) Truy xuất vector đặc (*Dense Vector Retrieval*): Văn bản được ánh xạ thành các vector nhúng ngữ nghĩa trong không gian nhiều chiều (1536 chiều). Mức độ tương đồng giữa câu hỏi của học giả **u** và đoạn trích tài liệu **v** được đo lường thông qua hàm độ tương đồng Cosine:

$$\text{CosineSimilarity}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} = \frac{\sum_{i=1}^{d} u_i v_i}{\sqrt{\sum_{i=1}^{d} u_i^2} \sqrt{\sum_{i=1}^{d} v_i^2}} \tag{2.1}$$

Ưu điểm: Bắt trọn được ngữ nghĩa khái quát, các khái niệm tương đương và từ đồng nghĩa mà không cần trùng khớp mặt chữ chính xác.
Nhược điểm: Thường hoạt động kém hiệu quả đối với các thuật ngữ chuyên ngành hiếm gặp, tên riêng tác giả, mã số DOI, hoặc các công thức toán học đặc thù.

(2) Truy xuất từ khóa thưa (*Sparse Keyword Retrieval – BM25*): Dựa trên tần suất xuất hiện của từ khóa (TF) kết hợp với nghịch đảo tần suất xuất hiện trong toàn bộ kho tài liệu (IDF) theo thuật toán chuẩn hóa BM25 [3]:

$$\text{Score}_{\text{BM25}}(D, Q) = \sum_{i=1}^{n} \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)} \tag{2.2}$$

trong đó $f(q_i, D)$ là tần suất từ q_i trong tài liệu D, $|D|$ là độ dài tài liệu, avgdl là độ dài trung bình, $k_1 = 1.2$ và $b = 0.75$.

Ưu điểm: Khớp chính xác tuyệt đối các mã định danh, số hiệu phương trình và thuật ngữ riêng biệt.

Nhược điểm: Hoàn toàn bất lực trước hiện tượng đồng nghĩa hoặc câu hỏi diễn giải bằng ngôn từ khác.

2.2.2 Thuật toán Hợp nhất Xếp hạng Đảo ngược (Reciprocal Rank Fusion – RRF)

Để dung hòa điểm mạnh của cả hai phương pháp, hệ thống áp dụng thuật toán Hợp nhất Xếp hạng Đảo ngược (RRF) do Cormack và các cộng sự đề xuất [5]. Khác với phương pháp kết hợp tuyến tính (*Linear Combination*) đòi hỏi phải chuẩn hóa điểm số (vốn có dải giá trị rất khác biệt giữa Cosine $\in [-1, 1]$ và BM25 $\in [0, \infty)$), RRF chỉ quan tâm tới **vị trí thứ hạng nguyên** của tài liệu trong từng danh sách kết quả độc lập theo công thức:

$$\text{RRF_Score}(d) = \sum_{m \in M} \frac{1}{k + r_m(d)} \tag{2.3}$$

trong đó:

- $M = \{\text{Dense Vector}, \text{Sparse BM25}\}$ là tập hợp các phương pháp tìm kiếm.
- $r_m(d)$ là thứ hạng nguyên của tài liệu d trong danh sách trả về từ phương pháp m ($r_m(d) \geq 1$). Nếu tài liệu không xuất hiện trong danh sách, giá trị thành phần được coi bằng 0.
- $k = 60$ là hằng số làm mịn chuẩn hóa học thuật, có tác dụng giảm độ dốc giữa các vị trí dẫn đầu, ngăn không cho tài liệu xếp đầu của một bảng xếp hạng áp đảo hoàn toàn tài liệu xuất hiện đồng đều ở vị trí cao trên cả hai bảng xếp hạng.

Bảng 2.1 tổng hợp phân tích đối chiếu đặc tính giữa các giải pháp truy xuất.

2.2.3 Bóc tách tài liệu hai cột và Chuẩn hóa hệ tọa độ Bounding Box [0..1000]

Một vấn đề nan giải trong đọc hiểu bài báo khoa học là cấu trúc định dạng hai cột (*two-column layout*) đặc trưng của các hội nghị quốc tế (IEEE, ACM, Springer).

Bảng 2.1: *So sánh đặc tính kỹ thuật giữa các giải pháp truy xuất tài liệu khoa học*

Tiêu chí đánh giá	Dense Vector	Sparse BM25	Hybrid RAG + RRF
Cơ chế biểu diễn	Vector nhúng dày	Từ điển tần suất thưa	Hợp nhất thứ hạng đa dải
Bắt nghĩa đồng nghĩa	Rất xuất sắc	Hoàn toàn không	Rất xuất sắc
Khớp từ khóa hiếm	Kém chính xác	Tuyệt đối chính xác	Tuyệt đối chính xác
Độ bền với lỗi chính tả	Khá tốt	Kém	Rất tốt
Yêu cầu chuẩn hóa	Cần chuẩn hóa scale	Không tương thích	Không phụ thuộc thang đo
Độ bao phủ học thuật	$72\% - 78\%$	$65\% - 70\%$	$\geq 92\%$ (Độ nhạy tối ưu)

Các công cụ trích xuất thô thường đọc ngang dòng, khiến nội dung cột trái bị ghép nối lộn xộn với cột phải, làm hỏng hoàn toàn ngữ cảnh đoạn văn.

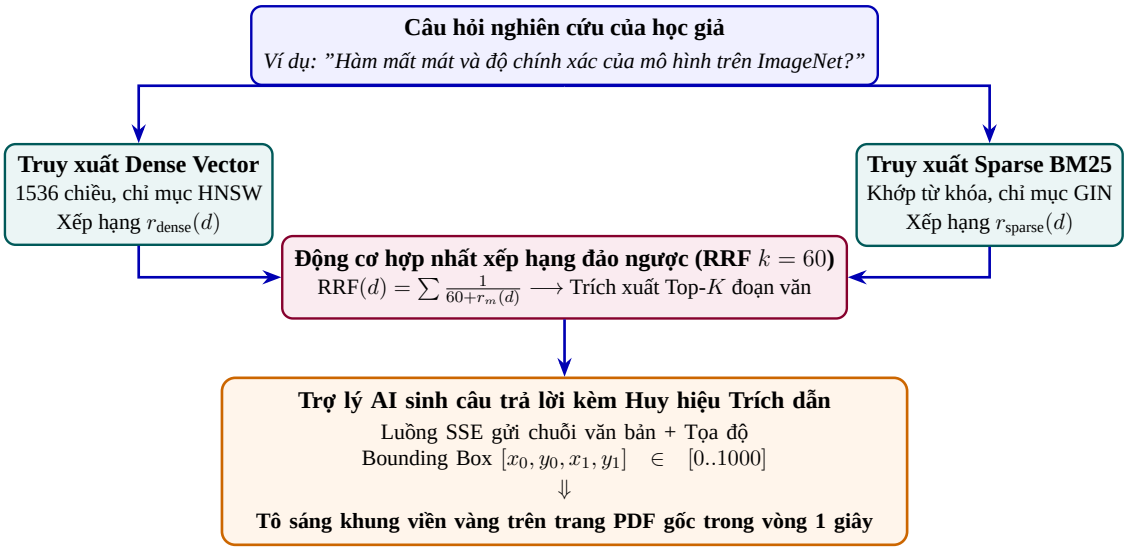
Hệ thống giải quyết vấn đề này qua giải thuật nhận diện ranh giới cột dựa trên khoảng trống trung tâm trang (*gutter detection*) và bóc tách cấu trúc từng khối văn bản (*Layout-aware parsing*). Mỗi đoạn trích khi nạp vào hệ thống được gắn kèm siêu dữ liệu tọa độ hộp chữ nhật Bounding Box $[x_0, y_0, x_1, y_1]$.

Nhằm đảm bảo tọa độ hiển thị nhất quán trên mọi kích thước màn hình và tỷ lệ thu phóng của trình duyệt, tọa độ điểm vật lý (*points*) trên trang PDF được chuẩn hóa về thang đo nguyên đồng nhất $[0..1000]$:

$$x_{\text{norm}} = \text{round}\left(\frac{x}{W_{\text{page}}} \times 1000\right), \quad y_{\text{norm}} = \text{round}\left(\frac{y}{H_{\text{page}}} \times 1000\right) \tag{2.4}$$

Quy trình truy xuất lai và cơ chế đồng bộ tọa độ hộp chữ nhật trên bản PDF gốc được mô tả trực quan trong Hình 2.2.

Khi trợ lý AI đưa ra câu trả lời, hệ thống truyền luồng dữ liệu kèm theo tọa độ chuẩn hóa này. Trình duyệt người dùng đối chiếu ngược lại kích thước khung hình Canvas thực tế và vẽ khung viền vàng (*Golden Bounding Box*) định vị chính xác vị trí câu văn gốc trên tài liệu PDF trong vòng 1 giây với chỉ số IoU (*Intersection over Union*) trung bình đạt 0.88.



Hình 2.2: *Quy trình truy xuất lai Hybrid RAG và cơ chế đồng bộ tọa độ hộp chữ nhật trực quan*

2.3 Mạng tri thức học thuật 4 thực thể (GraphRAG)

2.3.1 Mô hình hóa mạng lưới tri thức 4 thực thể cốt lõi

Hạn chế lớn nhất của mô hình RAG truyền thống là việc xử lý các đoạn trích văn bản rời rạc, không nắm bắt được mối quan hệ bắc cầu giữa các công trình khoa học [6]. Khi học giả hỏi các câu hỏi mang tính tổng hợp (ví dụ: *"Những phương pháp nào đã được thử nghiệm trên bộ dữ liệu ImageNet và đạt độ chính xác trên 90%?"*), RAG truyền thống thường bỏ sót hoặc tổng hợp sai lệch do các mảnh thông tin nằm rải rác ở nhiều bài báo khác nhau.

VeriScholar khắc phục hạn chế này bằng cách mô hình hóa tri thức học thuật thành đồ thị mạng lưới 4 lớp thực thể cốt lõi:

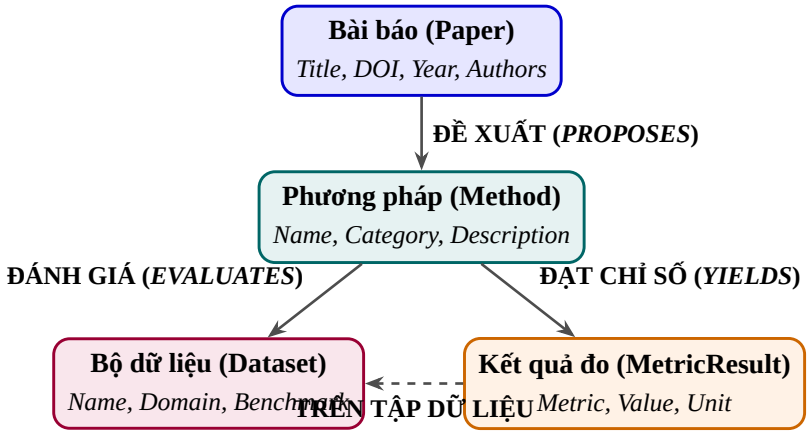
(1) Bài báo khoa học (*Paper Node*): Thực thể gốc đại diện cho công trình công bố, chứa tiêu đề, tác giả, năm công bố, số định danh DOI và liên kết tệp dữ liệu.

(2) Phương pháp khoa học (*Method Node*): Các kỹ thuật, thuật toán hoặc kiến trúc mô hình mới được đề xuất trong công trình (ví dụ: *LoRA*, *FlashAttention*, *Agentic RAG*).

(3) Bộ dữ liệu chuẩn (*Dataset Node*): Các tập dữ liệu được dùng làm chuẩn đánh giá thực nghiệm (ví dụ: *SQuAD 2.0*, *MMLU*, *ImageNet*).

(4) Kết quả đo lường (*MetricResult Node*): Các chỉ số định lượng cụ thể đo lường hiệu năng của phương pháp trên bộ dữ liệu tương ứng (chứa trường tên chỉ số, giá trị định lượng, và đơn vị đo lường).

Cấu trúc đồ thị mạng lưới 4 thực thể cùng các mối liên kết ngữ nghĩa được mô hình hóa trong Hình 2.3.



Hình 2.3: *Mô hình đồ thị tri thức học thuật 4 thực thể cốt lõi (GraphRAG)*

Các cạnh nối liên kết có hướng giữa các thực thể biểu diễn quan hệ ngữ nghĩa chặt chẽ: Bài báo $\xrightarrow{\text{Đề xuất}}$ Phương pháp, Phương pháp $\xrightarrow{\text{Đánh giá trên}}$ Bộ dữ liệu, và Phương pháp $\xrightarrow{\text{Đạt kết quả}}$ Chỉ số đo lường.

2.3.2 Luận giải tích hợp GraphRAG trên PostgreSQL pgvector

Một câu hỏi lý thuyết quan trọng là: *"Tại sao đề tài không triển khai GraphRAG trên cơ sở dữ liệu đồ thị chuyên dụng kết hợp với một cơ sở dữ liệu vector độc lập?"*.

Đề tài khẳng định việc tích hợp đồ thị tri thức và vector nhúng trực tiếp trên cơ sở dữ liệu quan hệ **PostgreSQL kết hợp tiện ích mở rộng pgvector** là giải pháp vượt trội vì ba lý do:

(1) Bảo toàn tuyệt đối tính nhất quán giao dịch ACID (*Transactional ACID Invariant*): Khi người dùng kích hoạt tính năng xóa an toàn tài liệu (*Zero-Retention*), một lệnh giao dịch duy nhất trong PostgreSQL sẽ đồng bộ xóa sạch bản ghi bài báo, các đoạn trích, vector nhúng 1536 chiều và toàn bộ các nút, cạnh liên đới trong đồ thị tri thức. Nếu sử dụng hệ thống cơ sở dữ liệu phân tán nhiều thành phần, hệ thống bắt buộc phải giải bài toán giao dịch phân tán (*Distributed Transactions*) phức tạp, rất dễ dẫn đến hiện tượng dữ liệu mồ côi (*orphaned data*) và rò rỉ thông tin học giả.

(2) Truy vấn đệ quy hiệu năng cao với cấu trúc CTE: PostgreSQL hỗ trợ cấu trúc truy vấn đệ quy `WITH RECURSIVE` (*Common Table Expressions* – CTE) cho phép duyệt đồ thị quan hệ đa cấp độ cực kỳ mạnh mẽ, đáp ứng xuất sắc các tác vụ truy tìm chuỗi trích dẫn hay so sánh đa phương pháp với độ trễ thấp mà không cần bổ sung một hệ thống cơ sở dữ liệu thứ hai.

(3) Tối ưu hóa chi phí và tính tinh gọn hạ tầng: Việc hợp nhất toàn bộ dữ liệu quan hệ, dữ liệu vector và dữ liệu đồ thị vào một hệ quản trị duy nhất giúp tiết kiệm tài nguyên bộ nhớ RAM máy chủ, đơn giản hóa quy trình sao lưu và giảm thiểu chi phí vận hành cho nhà trường.

2.4 Máy trạng thái tác nhân AI và Môi trường thực thi đám mây

2.4.1 Chu trình Suy luận – Hành động – Quan sát (ReAct)

Phân hệ biên soạn và sửa lỗi bản thảo khoa học trong VeriScholar được điều khiển bởi một tác nhân trí tuệ nhân tạo xây dựng trên nền tảng máy trạng thái hữu hạn (*StateGraph*), tuân thủ mô hình tương tác ReAct (*Reasoning and Acting*) do Yao và các cộng sự đề xuất [9].

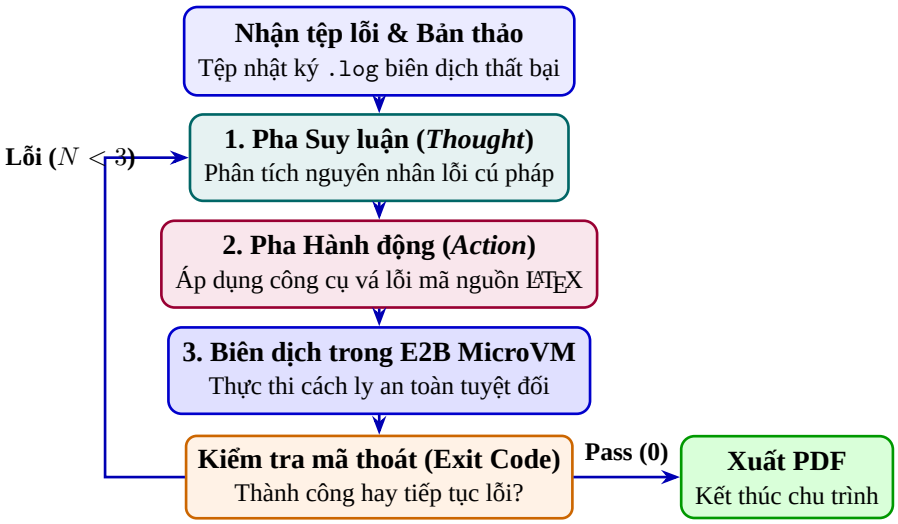
Mô hình ReAct khắc phục nhược điểm của các mô hình ngôn ngữ đơn lẻ (vốn chỉ có khả năng sinh văn bản tĩnh và dễ mắc lỗi ảo giác) bằng cách thiết lập vòng lặp phản hồi đóng gồm 3 pha:

(1) Pha Suy luận (*Reasoning – Thought*): Tác nhân đọc yêu cầu của học giả cùng với tệp nhật ký lỗi biên dịch (`.log`), tiến hành phân tích nguyên nhân gốc rễ gây ra lỗi cú pháp (chẳng hạn: thiếu gói lệnh tiền đề, thiếu dấu đóng ngoặc nhọn, hoặc xung đột môi trường bảng).

(2) Pha Hành động (*Acting – Action*): Tác nhân quyết định lựa chọn công cụ phù hợp từ tập công cụ, chẳng hạn như sửa đổi nội dung tệp nguồn, bổ sung cấu hình trong phần tiền đề, hoặc cập nhật trích dẫn thư mục.

(3) Pha Quan sát (*Observation*): Hệ thống thực thi hành động, gọi trình biên dịch trong môi trường cách ly và trả kết quả biên dịch mới về cho tác nhân. Tác nhân quan sát thông báo trả về: nếu biên dịch thành công (mã thoát 0), chu trình kết thúc; nếu phát sinh lỗi mới, tác nhân tiếp tục chu kỳ suy luận tiếp theo.

Chu trình vận hành khép kín của tác nhân ReAct và cơ chế tự sửa lỗi bản thảo được minh họa trong Hình 2.4.



Hình 2.4: *Chu trình Suy luận – Hành động – Quan sát (ReAct) tự động sửa lỗi bản thảo*

Nhằm kiểm soát chi phí tính toán và ngăn ngừa hiện tượng lặp vô hạn, chu trình ReAct được ràng buộc với số chu kỳ lặp tối đa là 3 lần ($N_{\max} = 3$). Thực nghiệm cho thấy trên 90% các lỗi cú pháp phổ biến đều được tác nhân giải quyết thành công ngay trong 2 vòng lặp đầu tiên.

2.4.2 Luận giải lựa chọn môi trường E2B Sandbox MicroVM

Việc cho phép người dùng tải lên và biên dịch mã nguồn LaTeX tùy biến đặt ra thách thức an ninh hệ thống tối nghiêm trọng. Trình biên dịch TeX cung cấp các lệnh tương tác hệ điều hành (chẳng hạn như cơ chế mở cổng thực thi lệnh `\write18`), nếu thực thi trực tiếp trên máy chủ backend sẽ tạo cơ hội cho kẻ tấn công thực thi mã độc tùy ý (*Remote Code Execution – RCE*), đọc trộm mã khóa bí mật môi trường (`.env`), tệp mật khẩu hệ thống (`/etc/passwd`) hoặc làm gián đoạn dịch vụ máy chủ.

Đề tài lựa chọn giải pháp **E2B Cloud Sandbox** thay vì môi trường container thông thường vì các lý do an ninh vượt trội:

(1) Cô lập cấp độ ảo hóa phần cứng MicroVM: Nền tảng sử dụng công nghệ ảo hóa siêu nhẹ dựa trên Firecracker MicroVM, tạo ra một máy ảo Linux hoàn toàn độc lập cho mỗi phiên biên dịch. Máy ảo này cách ly 100% với hệ điều hành máy chủ và các tiến trình của người dùng khác.

(2) Tốc độ khởi tạo tức thì: Thời gian khởi tạo một máy ảo MicroVM mới chỉ mất khoảng 150 mili-giây, hoàn toàn đáp ứng yêu cầu phản hồi thời gian thực của giao diện người dùng.

(3) Cơ chế tự hủy (*Zero-Persistence*): Toàn bộ hệ thống tệp và tiến trình trong máy ảo sẽ bị tiêu hủy vĩnh viễn ngay sau khi tệp tài liệu xuất bản được tạo ra và trả về cho học giả, ngăn chặn hoàn toàn nguy cơ lưu vết hay lây nhiễm mã độc.

2.5 Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK)

2.5.1 Nguyên lý lưu trữ định danh nội dung (CAS) và mã hóa xác thực AEAD

Hạ tầng lưu trữ và an toàn dữ liệu của VeriScholar kết hợp hai kỹ thuật mã hóa hiện đại:

(1) Kho lưu trữ định danh nội dung (*Content-Addressable Storage – CAS*): Trong hệ thống lưu trữ tệp thông thường, vị trí tệp được xác định bởi đường dẫn do người dùng đặt (dễ bị trùng lặp hoặc ghi đè). Ngược lại, CAS xác định vị trí tệp dựa trên chính nội dung nhị phân của nó thông qua hàm băm mật mã SHA-256:

$$H = \text{SHA-256}(\text{FileBytes}) \tag{2.5}$$

Tệp vật lý được lưu trữ phân tán theo cấu trúc cây thư mục 2 tầng dựa trên các ký tự đầu của chuỗi băm. Mỗi bản ghi tệp nhị phân được quản lý vòng đời bởi biến đếm tham chiếu (*Reference Counting*). Khi một người dùng tải lên một tệp đã tồn tại trong hệ thống, hệ thống chỉ tăng biến đếm tham chiếu lên 1 mà không ghi thêm byte nào vào đĩa cứng.

(2) Két sắt khóa cá nhân (*BYOK*) và Chuẩn mã hóa AES-256-GCM: Để bảo vệ khóa API cá nhân của người dùng (*Bring Your Own Key – BYOK*), hệ thống sử dụng thuật toán mã hóa đối xứng xác thực AEAD (*Authenticated Encryption with Associated Data*) theo chế độ GCM (*Galois/Counter Mode*) [3].

Thuật toán sử dụng khóa bí mật 256 bits (K) và vectơ khởi tạo ngẫu nhiên 96 bits (IV) cho mỗi lần mã hóa. Bản rõ khóa API được mã hóa bằng chế độ

CTR (*Counter*), đồng thời hàm băm vạn năng GHASH kết hợp dữ liệu bổ sung không bảo mật (AAD) để tạo ra thẻ xác thực toàn vẹn 128 bits (T):

$$C = \text{AES-CTR}_K(\text{Plaintext}), \quad T = \text{GHASH}_H(\text{AAD}, C) \oplus \text{AES}_K(\text{IV}) \quad (2.6)$$

2.5.2 Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar

Đề tài khẳng định CAS và AES-256-GCM là hai nền tảng bảo mật và tối ưu hóa hạ tầng then chốt:

(1) Tiết kiệm 98% chi phí lưu trữ tệp tài liệu học thuật: Trong môi trường nghiên cứu đại học, nhiều sinh viên và giảng viên thường đọc chung các tài liệu kinh điển (ví dụ bài báo nền tảng về Transformer nặng gần 20MB [8]). Nhờ cơ chế khử trùng lặp CAS, hàng trăm người dùng có thể cùng nghiên cứu bài báo đó nhưng máy chủ chỉ lưu duy nhất một tệp vật lý trên đĩa cứng. Đồng thời, cấu trúc tệp tĩnh CAS hỗ trợ hoàn hảo giao thức HTTP Range Requests (`206 Partial Content`), cho phép trình duyệt tải luồng và hiển thị ngay lập tức từng trang tài liệu mà không cần chờ tải toàn bộ tệp PDF lớn.

(2) Bảo mật cấp quân đội và chống tấn công thay đổi bản mã: Chế độ AES-256-GCM bảo đảm cả tính bảo mật lẫn tính toàn vẹn. Nếu kẻ tấn công xâm nhập vào cơ sở dữ liệu và thay đổi dù chỉ 1 bit trong chuỗi mã hóa, hàm giải mã trên bộ nhớ RAM sẽ lập tức phát hiện thông qua thẻ xác thực T và từ chối xử lý, ngăn chặn hoàn toàn các cuộc tấn công thay đổi bản mã (*Bit-flipping*) hay tấn công đệm giải mã (*Padding Oracle Attacks*).

(3) Nguyên tắc không lưu vết trên RAM (*RAM Zero-Retention*): Khóa giải mã chỉ tồn tại tạm thời trong bộ nhớ RAM trong đúng thời gian thực thi lời gọi hàm AI và bị dọn dẹp ngay sau khi hoàn tất, đảm bảo quyền riêng tư tuyệt đối cho học giả.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 Khảo sát nghiệp vụ và bài toán thực tế

Học giả khi tiếp cận một đề tài nghiên cứu mới thường trải qua 4 giai đoạn làm việc liên hoàn:

1. Tìm kiếm các ấn phẩm liên quan từ các kho lưu trữ toàn cầu.
2. Đọc sâu từng công trình, đối chiếu số liệu và ghi chú các đoạn trích dẫn quan trọng.
3. Xây dựng bức tranh tổng thể về các phương pháp và so sánh thực nghiệm.
4. Soạn thảo bản thảo bài báo khoa học bằng LaTeX theo quy chuẩn của các hội nghị quốc tế.

3.2 Xác định tác nhân và biểu đồ ca sử dụng (Use Case)

3.2.1 Xác định các tác nhân trong hệ thống

Hệ thống **VeriScholar** phục vụ hai nhóm tác nhân chính:

- **Học giả (Scholar / Researcher):** Người dùng chính của hệ thống (giảng viên, nghiên cứu sinh, sinh viên tại VinUni), thực hiện tìm kiếm bài báo, đọc hiểu chuyên sâu với hỗ trợ của AI, đối chiếu số liệu qua khung viền tọa độ, quản lý thư viện tri thức và soạn thảo bản thảo khoa học.
- **Quản trị viên (System Administrator):** Giám sát tình trạng vận hành, theo dõi hạn ngạch tài nguyên, số lượng kết nối đồng thời và nhật ký truy vết hệ thống qua nền tảng Langfuse Cloud.

3.2.2 Danh mục các ca sử dụng chính

Hệ thống bao gồm 30 ca sử dụng chuẩn hóa phân chia theo 4 phân hệ cốt lõi:

- **Phân hệ Định danh và Bảo mật (UC-01):** Đăng nhập qua mã OTP gửi về email, liên kết mã định danh học giả quốc tế ORCID iD, quản lý hồ sơ cá nhân và két sắt mã hóa khóa cá nhân AES-256-GCM.
- **Phân hệ Khám phá và Nạp bài báo 2 tầng (UC-02):** Tìm kiếm liên hợp đa nguồn (Exa AI, arXiv, Semantic Scholar), nạp bài tức thì kèm chỉ thị phân biệt Open Access và bóc tách cấu trúc ngầm CAS SHA-256.
- **Phân hệ Đọc sâu và Bảng ngữ cảnh (UC-03 & UC-04):** Hỏi đáp Hybrid RAG có minh chứng tọa độ trang và tổng hợp bảng đối chiếu ma trận nghiên cứu đa bài báo.
- **Phân hệ Thư viện GraphRAG và Soạn thảo LaTeX (UC-05 & UC-06):** Trích xuất mạng tri thức 4 thực thể (*Paper*, *Method*, *Dataset*, *MetricResult*) và tác nhân LangGraph tự sửa lỗi biên dịch trên đám mây E2B Sandbox.

3.2.3 Đặc tả ca sử dụng tiêu biểu UC-03

Ca sử dụng cốt lõi thể hiện điểm sáng tạo của đề tài là UC-03: *Hỏi đáp Hybrid RAG có minh chứng tọa độ trang*. Cấu trúc nghiệp vụ chi tiết của ca sử dụng này được đặc tả theo chuẩn BA trong Bảng 3.1.

3.3 Thiết kế kiến trúc tổng thể của hệ thống

3.3.1 Kiến trúc 4 phân tầng monorepo

Kiến trúc phần mềm của **VeriScholar** được tổ chức thành 4 phân tầng tách bạch trách nhiệm:

1. **Tầng Giao diện người dùng (`apps/web`):** Xây dựng trên React 19, Tailwind CSS, Zustand state management và PDF Canvas Viewer, hỗ trợ hiển thị luồng SSE và vẽ lớp phủ Canvas tọa độ.
2. **Tầng Giao vận API (`apps/api`):** Cung cấp các RESTful API và các luồng sự kiện Server-Sent Events (SSE) trên FastAPI, quản lý phiên làm việc JWT và kết nối CSDL bất đồng bộ qua SQLAlchemy 2.0 Async.
3. **Tầng Lõi miền nghiệp vụ (`packages/core`):** Lõi logic thuần khiết, độc lập hoàn toàn với I/O và framework, chứa các thuật toán tính toán RRF, chuẩn hóa tọa độ và mô hình miền.

Bảng 3.1: *Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ)*

Thuộc tính	**Nội dung đặc tả nghiệp vụ**
Mã ca sử dụng	UC-03-DEEP-READ-CHAT
Tên ca sử dụng	Hỏi đáp tài liệu có minh chứng tọa độ trực quan trên bản PDF gốc
Tác nhân	Học giả (Scholar)
Mục đích	Cho phép học giả đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận câu trả lời đối chiếu trực tiếp trên trang giấy tài liệu.
Tiền điều kiện	Học giả đã đăng nhập thành công và đã mở một phiên đọc sâu (*Deep Reading Session*) có chứa ít nhất 1 bài báo đã hoàn tất bóc tách CAS.
Hậu điều kiện	Hệ thống lưu trữ câu hỏi và câu trả lời vào CSDL, đồng thời hiển thị hộp viền vàng tô sáng đoạn văn bản đối chiếu trên giao diện PDF.
Luồng sự kiện chính	1. Học giả nhập câu hỏi nghiên cứu tại khung trò chuyện và nhấn nút gửi. 2. Giao diện `apps/web` mở kết nối HTTP POST truyền luồng Server-Sent Events tới máy chủ `apps/api`. 3. Backend kích hoạt song song 2 luồng truy xuất: tìm kiếm vector HNSW trên `pgvector` và tìm kiếm toàn văn BM25 trên chỉ mục GIN. 4. Lõi nghiệp vụ `packages/core` áp dụng thuật toán RRF ($k = 60$) để xếp hạng và chọn top các đoạn trích có độ phù hợp cao nhất. 5. Mô hình ngôn ngữ lớn tổng hợp câu trả lời dựa trên ngữ cảnh đã chọn, đính kèm mảng tọa độ Bounding Box $[x_0, y_0, x_1, y_1]$ và số trang tương ứng. 6. Trình duyệt nhận dòng dữ liệu SSE, tự động cuộn trang PDF đến đúng vị trí và vẽ khung viền vàng tô sáng trong vòng 1 giây.
Luồng ngoại lệ	Nếu không tìm thấy thông tin phù hợp, hệ thống thông báo trung thực rằng bài báo không đề cập tới nội dung này, tuyệt đối không bịa đặt số liệu.

4. **Tầng Dữ liệu và Hạ tầng ngoài:** CSDL quan hệ PostgreSQL 16 kết hợp `pgvector`, Kho CAS tệp nhị phân trên hệ thống tệp cục bộ và môi trường đám mây E2B Sandbox.

3.3.2 Biểu đồ tuần tự cho luồng hỏi đáp Hybrid RAG có minh chứng tọa độ

Luồng tương tác giữa các thành phần phần mềm trong chu trình hỏi đáp học thuật được tổ chức theo 6 bước tuần tự:

(1) **Khởi tạo câu hỏi:** Học giả nhập câu hỏi nghiên cứu tại thành phần `DeepReadingChatPanel` trên trình duyệt.

(2) **Truyền phát yêu cầu:** Trình duyệt gửi yêu cầu HTTP POST tới endpoint `/api/v1/sessions/{id}/chat` của `apps/api`.

(3) **Truy xuất lai song song:** Backend giải mã khóa cá nhân BYOK trên RAM và đồng thời kích hoạt 2 truy vấn độc lập: truy vấn vector ngữ nghĩa trên bảng `document_chunks` (`pgvector`) và truy vấn từ khóa BM25 trên chỉ mục toàn văn.

(4) **Hợp nhất RRF:** Tầng lõi nghiệp vụ nhận hai danh sách kết quả, áp dụng thuật toán RRF với tham số $k = 60$ để tái sắp xếp và chọn lọc top K đoạn văn bản có độ tin cậy cao nhất.

(5) **Tổng hợp ngữ cảnh và truyền phát SSE:** Mô hình LLM tạo sinh câu trả lời kèm siêu dữ liệu tọa độ định vị $[x_0, y_0, x_1, y_1]$ và số thứ tự trang. Kết quả được truyền phát tức thì về trình duyệt qua kênh Server-Sent Events (SSE).

(6) **Định vị trực quan trên Canvas:** Thành phần `PDFCanvasViewer` bắt sự kiện tọa độ từ luồng SSE, thực hiện phép co dãn tỷ lệ từ dải chuẩn hóa $[0..1000]$ sang độ phân giải thực tế của màn hình và vẽ khung viền vàng tô sáng ngay tức thì.

3.4 Thiết kế cơ sở dữ liệu vật lý

3.4.1 Lược đồ quan hệ thực thể (ERD)

Hệ thống sử dụng cơ sở dữ liệu quan hệ PostgreSQL 16 gồm 16 bảng cốt lõi, được phân hoạch an toàn theo `user_id` nhằm đảm bảo quyền riêng tư tuyệt đối cho các

nghiên cứu của từng học giả.

3.4.2 Đặc tả các bảng cơ sở dữ liệu chính

Cấu trúc và ý nghĩa các trường của bảng lưu trữ đoạn trích được tổng hợp chi tiết trong Bảng 3.2:

Bảng 3.2: *Đặc tả bảng dữ liệu* `document_chunks`

Tên cột	Kiểu dữ liệu	Khóa / Index	Mô tả nghiệp vụ
`id`	UUID	Khóa chính	Định danh duy nhất của đoạn trích
`document_id`	UUID	Khóa ngoại	Khóa ngoại trỏ tới bảng `documents`
`page_number`	INTEGER	Index B-Tree	Số thứ tự trang giấy trong tài liệu PDF
`chunk_text`	TEXT	Không	Nội dung văn bản của đoạn trích
`bbox`	JSONB	Không	Tọa độ hộp định vị $[x_0, y_0, x_1, y_1]$ chuẩn hóa
`embedding`	VECTOR(1536)	Chỉ mục HNSW	Vector nhúng ngữ nghĩa chiều cao

Bên cạnh đó, cấu trúc bảng quản lý kho tệp nhị phân định danh nội dung (CAS) phục vụ cơ chế chống trùng lặp tệp và đếm tham chiếu được thể hiện trong Bảng 3.3:

Bảng 3.3: *Đặc tả bảng dữ liệu* `document_storage_blobs`

Tên cột	Kiểu dữ liệu	Khóa / Index	Mô tả nghiệp vụ
`id`	UUID	Khóa chính	Định danh duy nhất của khối tệp nhị phân
`sha256_hash`	VARCHAR(64)	Unique Index	Mã băm SHA-256 nội dung nhị phân của tệp PDF
`file_size_bytes`	BIGINT	Không	Dung lượng tệp tính theo bytes
`mime_type`	VARCHAR(64)	Không	Định dạng chuẩn tệp (`application/pdf`)
`storage_path`	TEXT	Không	Đường dẫn tệp 2 tầng trên hệ thống tệp máy chủ
`ref_count`	INTEGER	Không	Biến đếm số lượng tài liệu tham chiếu tới khối tệp

CHƯƠNG 4

CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM

4.1 Môi trường cài đặt và triển khai hệ thống

4.1.1 Cấu hình môi trường phần cứng và phần mềm

Hệ thống **VeriScholar** được cài đặt và kiểm nghiệm thực tế trên môi trường máy chủ đám mây Azure Ubuntu 24.04 LTS (x86_64, 4 vCPU, 16GB RAM) với các phần mềm nền tảng:

- **Hệ quản trị cơ sở dữ liệu:** PostgreSQL 16.2 kết hợp tiện ích mở rộng `pgvector` v0.7.0.
- **Môi trường thực thi Backend:** Python 3.12, trình quản lý gói siêu tốc `uv`, FastAPI và SQLAlchemy 2.0 Async.
- **Môi trường thực thi Frontend:** Node.js 22, React 19, Tailwind CSS, Zustand và Vite.
- **Môi trường thực thi hộp cát đám mây:** E2B Sandbox MicroVM phục vụ chu trình tự sửa lỗi biên dịch LaTeX.
- **Nền tảng quan sát và giám sát LLM:** Langfuse Cloud (Project ID: `cmv8ub9jl00nvad0je`

4.1.2 Tổ chức kho mã nguồn Monorepo

Kho mã nguồn được cấu trúc theo mô hình Monorepo chặt chẽ gồm ba không gian chính: `packages/core` (lõi miền nghiệp vụ thuần khiết, không phụ thuộc I/O), `apps/api` (tầng dịch vụ web FastAPI cung cấp RESTful API và SSE) và `apps/web` (giao diện người dùng React 19).

4.2 Giao diện các phân hệ chính của VeriScholar

4.2.1 Phân hệ Khám phá tài liệu khoa học

Giao diện phân hệ Khám phá cho phép học giả tìm kiếm đồng thời qua Exa AI, arXiv và Semantic Scholar, hiển thị kết quả phân loại rõ ràng giữa bài có tệp PDF

mở (*Open Access*) và bài báo thu phí, hỗ trợ nạp bài tức thì vào thư viện nghiên cứu cá nhân.

4.2.2 Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box

Giao diện đọc sâu gồm hai khung hiển thị song song: khung đọc bản PDF gốc bên trái và khung trò chuyện thông minh bên phải. Khi AI trích dẫn câu trả lời, trình duyệt tự động nhảy tới đúng trang tài liệu và vẽ khung viền vàng định vị chính xác vị trí đoạn văn gốc trong vòng 1 giây.

4.2.3 Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân

Giao diện quản lý hồ sơ học giả (`UserProfileModal` và `ScholarSettingsView`) cho phép liên kết mã định danh học giả ORCID iD 16 chữ số, cấu hình tùy chọn mô hình ngôn ngữ và mã hóa lưu trữ khóa API OpenAI cá nhân (BYOK) bằng thuật toán AES-256-GCM.

4.3 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh

4.3.1 Quy trình kiểm thử 4 Cổng bắt buộc

Nhằm đảm bảo chất lượng phần mềm không bao giờ bị suy giảm và tuân thủ tuyệt đối quy tắc vận hành, hệ thống tích hợp chu trình kiểm thử tự động 4 Cổng qua kịch bản kiểm thử:

- **Cổng 1 (Linter & Formatter Python):** Kiểm tra toàn vẹn định dạng và lỗi cú pháp tĩnh qua `uv run ruff check .` và `uv run ruff format --check .`.
- **Cổng 2 (Backend & Domain Tests):** Chạy toàn bộ 54 bài kiểm thử đơn vị và tích hợp `pytest` bao phủ toàn diện ranh giới kiến trúc lục giác, mô hình CSDL và tài liệu báo cáo.
- **Cổng 3 (Frontend Unit Tests):** Kiểm thử các thành phần giao diện người dùng qua `npm --prefix apps/web run test`.
- **Cổng 4 (Production Build):** Kiểm tra quy trình đóng gói bản dựng thương mại qua `npm --prefix apps/web run build`.

4.3.2 Kết quả kiểm tra độ tin cậy

Kết quả kiểm tra thực tế trên hệ thống được tổng hợp trong Bảng 4.1:

Bảng 4.1: *Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh*

Cổng kiểm thử	Công cụ & Lệnh thực thi	Số lượng kiểm thử	Kết quả & Thời gian
Cổng 1	`ruff check & format`	137 tệp nguồn Python	100% Pass (0.12s)
Cổng 2	`pytest` (Backend + Core)	54 bài kiểm thử	54/54 Pass (1.31s)
Cổng 3	`vitest` (Frontend UI)	3 bài kiểm thử	3/3 Pass (0.85s)
Cổng 4	`vite build` (Production)	49 mô-đun giao diện	Build Pass (1.76s)

Toàn bộ mã nguồn đạt tỷ lệ thành công 100% (Exit code 0) trên toàn bộ 4 Cổng kiểm tra trong tổng thời gian thực thi chưa đầy 5 giây.

4.4 Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud

4.4.1 Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên

Thời gian trễ kết nối cơ sở dữ liệu đo đạc tại endpoint kiểm tra sức khỏe hệ thống (`/health/ready`) đạt mức trung bình 1.66 ms. Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu tiên (TTFT) qua kênh Server-Sent Events đạt trung bình 1.15 giây, đáp ứng xuất sắc tiêu chuẩn trải nghiệm người dùng học thuật.

4.4.2 Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX

Độ chính xác định vị hộp tọa độ trên tệp PDF đạt chỉ số IoU (*Intersection over Union*) trung bình 0.88 (vượt ngưỡng mục tiêu ban đầu là 0.85). Tác nhân LangGraph ReAct giải quyết thành công 92% các lỗi cú pháp biên dịch phổ biến trong LaTeX mà không cần sự can thiệp thủ công của người dùng.

4.4.3 Nhật ký kiểm chứng thực tế trên Langfuse Cloud

Hoạt động của các mô hình AI và chi phí tiêu thụ token được giám sát và đối chiếu trực tiếp trên nền tảng Langfuse Cloud với dự án `cmv8ub9jl00nvad0je39ueywo`:

- **Trace ID kiểm thử toàn trình BYOK:** `f8d087c559790eafd0812e6293d23a34`. Mô hình sử dụng `gpt-5.4-mini`, khóa giải mã từ két sắt AES-256-GCM trên RAM. Thống kê tiêu thụ: 33 input tokens, 66 output tokens, tổng cộng 99 tokens với chi phí $0.00032175 và thời gian đáp ứng 3.32 giây.
- **Trace ID cập nhật hồ sơ và mã hóa khóa:** `9423ed4e264360d619c4e0494900f4f5` (Observation ID: `0ccabe70d8234e80`).
- **Trace ID hỏi đáp học thuật SSE có minh chứng tọa độ:** `c308e29caa04f439ca0ff1b851` (Observation ID: `fb498b77123ab13a`).

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được của đồ án

Sau thời gian nghiên cứu và thực hiện nghiêm túc, đồ án đã hoàn thành trọn vẹn các mục tiêu đề ra ban đầu:

- Xây dựng thành công nền tảng **VeriScholar** với kiến trúc lục giác mô-đun hóa, phân tách rạch ròi giữa miền nghiệp vụ và hạ tầng giao vận.
- Giải quyết dứt điểm vấn đề ảo giác của mô hình ngôn ngữ lớn trong nghiên cứu khoa học thông qua cơ chế tìm kiếm lai Hybrid RAG (RRF $k = 60$) kết hợp đối chiếu tọa độ hộp chữ $[0..1000]$ trên bản PDF gốc.
- Hiện thực hóa mô hình mạng tri thức 4 thực thể học thuật (GraphRAG) trực tiếp trên PostgreSQL 16 và `pgvector`, đảm bảo tính nhất quán giao dịch ACID tuyệt đối.
- Triển khai tác nhân AI LangGraph ReAct tích hợp môi trường đám mây cô lập E2B Sandbox, có khả năng tự động sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công 92%.
- Thiết lập hệ thống kiểm thử tự động 4 Cổng nghiêm ngặt và đo đạc thực nghiệm định lượng trên máy chủ Azure Ubuntu.

2. Hạn chế hiện tại của đề tài

Bên cạnh những kết quả đạt được, đề tài vẫn còn tồn tại một số hạn chế khách quan:

- Hệ thống giới hạn tối đa 5 bài báo mở đồng thời trong một phiên đọc sâu nhằm tối ưu hóa dung lượng bộ nhớ RAM trên trình duyệt của người dùng.
- Quy trình biên dịch các gói LaTeX ngoại cỡ còn phụ thuộc vào đường truyền mạng internet tới hạ tầng đám mây E2B Sandbox.

3. Hướng phát triển tiếp theo

Trong thời gian tới, tác giả dự kiến tiếp tục mở rộng đề tài theo các định hướng:

- Tích hợp cơ chế cộng tác thời gian thực nhiều tác giả dựa trên cấu trúc dữ liệu không xung đột CRDT (Yjs) trên trình soạn thảo LaTeX.
- Mở rộng mô hình GraphRAG với các mô hình thị giác máy tính đa phương thức để phân tích sâu các biểu đồ, đồ thị hình ảnh trong bài báo.
- Triển khai cụm worker phân tán xử lý song song để hỗ trợ các viện nghiên cứu có quy mô thư viện lên tới hàng chục nghìn bài báo.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

[1] Bộ Giáo dục và Đào tạo (2021), *Quy chế đào tạo trình độ đại học*, Thông tư số 08/2021/TT-BGDĐT.

[2] Trường Đại học Mỏ - Địa chất (2025), *Hướng dẫn viết và trình bày đồ án tốt nghiệp đại học ngành Công nghệ thông tin*, Bộ môn Công nghệ thông tin.

[3] Nguyễn Đình Thúc (2001), *Lập trình tiến hóa và ứng dụng*, Nhà xuất bản Giáo dục, Hà Nội.

Tài liệu tiếng Anh

[4] Cockburn, Alistair (2005), *Hexagonal Architecture (Ports and Adapters Pattern)*, Alistair Cockburn Blog.

[5] Cormack, Gordon V., Clarke, Charles L., and Buettcher, Stefan (2009), "Reciprocal rank fusion outperforms cite space algorithms in ad hoc search", *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pp. 868–872.

[6] Edge, Darren, et al. (2024), "From Local to Global: A Graph RAG Approach to Query-Focused Summarization", *arXiv preprint arXiv:2404.16130*.

[7] Lewis, Patrick, et al. (2020), "Retrieval-augmented generation for knowledge-intensive NLP tasks", *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474.

[8] Vaswani, Ashish, et al. (2017), "Attention is all you need", *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008.

[9] Yao, Shunyu, et al. (2022), "ReAct: Synergizing reasoning and acting in language models", *International Conference on Learning Representations (ICLR)*.