MỤC LỤC

MỤC LỤC i
DANH MỤC HÌNH ẢNH iii
DANH MỤC BẢNG BIỂU iv
DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT v
LỜI CẢM ƠN 1
LỜI MỞ ĐẦU 2
CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI 3
1.1. Giới thiệu đề tài 3
1.2. Tính cấp thiết của đề tài 3
1.3. Mục tiêu nghiên cứu 4
1.3.1. Mục tiêu tổng quát 4
1.3.2. Mục tiêu cụ thể 4
1.4. Nội dung nghiên cứu và phương pháp tiếp cận 5
1.4.1. Nội dung nghiên cứu 5
1.4.2. Phương pháp tiếp cận 5
1.5. Phạm vi nghiên cứu 5
1.6. Bố cục của báo cáo đồ án tốt nghiệp 6
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ 7
2.1. Kiến trúc phần mềm lục giác (Hexagonal Architecture) 7
2.1.1. Nguyên lý Ports and Adapters 7
2.1.2. Luận giải lựa chọn kiến trúc lục giác cho VeriScholar 7
2.2. Tìm kiếm lai (Hybrid Search) và Thuật toán RRF 8
2.2.1. Nguyên lý tìm kiếm ngữ nghĩa và tìm kiếm từ khóa 8
2.2.2. Thuật toán Hợp nhất Xếp hạng Đảo ngược (RRF) 8
2.2.3. Luận giải lựa chọn thuật toán RRF 8
2.3. Mạng tri thức học thuật 4-thực thể (GraphRAG) 9
2.3.1. Mô hình hóa thực thể học thuật 9
2.3.2. Luận giải triển khai GraphRAG trên PostgreSQL pgvector 9
2.4. Máy trạng thái tác nhân AI và Sandbox đám mây 10
2.4.1. Chu trình Suy luận – Hành động – Quan sát (ReAct) 10
2.4.2. Luận giải lựa chọn môi trường E2B Sandbox 10

2.5. Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK). 11
2.5.1. Nguyên lý lưu trữ CAS và mã hóa xác thực AEAD 11
2.5.2. Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar 11
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG 12
3.1. Khảo sát nghiệp vụ và bài toán thực tế 12
3.2. Xác định tác nhân và biểu đồ ca sử dụng (Use Case)..... 12
3.2.1. Xác định các tác nhân trong hệ thống 12
3.2.2. Danh mục các ca sử dụng chính..... 12
3.2.3. Đặc tả ca sử dụng tiêu biểu UC-03 13
3.3. Thiết kế kiến trúc tổng thể của hệ thống..... 13
3.3.1. Kiến trúc 4 phân tầng monorepo 13
3.3.2. Biểu đồ tuần tự cho luồng hỏi đáp Hybrid RAG có minh chứng tọa độ 15
3.4. Thiết kế cơ sở dữ liệu vật lý 15
3.4.1. Lược đồ quan hệ thực thể (ERD) 15
3.4.2. Đặc tả các bảng cơ sở dữ liệu chính 16
CHƯƠNG 4: CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM 17
4.1. Môi trường cài đặt và triển khai hệ thống 17
4.1.1. Cấu hình môi trường phần cứng và phần mềm 17
4.1.2. Tổ chức kho mã nguồn Monorepo..... 17
4.2. Giao diện các phân hệ chính của VeriScholar 17
4.2.1. Phân hệ Khám phá tài liệu khoa học 17
4.2.2. Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box 18
4.2.3. Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân 18
4.3. Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh..... 18
4.3.1. Quy trình kiểm thử 4 Cổng bắt buộc 18
4.3.2. Kết quả kiểm tra độ tin cậy 19
4.4. Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud..... 19
4.4.1. Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên..... 19
4.4.2. Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX 19
4.4.3. Nhật ký kiểm chứng thực tế trên Langfuse Cloud..... 20
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 21
TÀI LIỆU THAM KHẢO..... 23

DANH MỤC HÌNH ẢNH

DANH MỤC BẢNG BIỂU

3.1 Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ) 14
3.2 Đặc tả bảng dữ liệu `document_chunks` 16
3.3 Đặc tả bảng dữ liệu `document_storage_blobs` 16

4.1 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh 19

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
ACID	Atomicity, Consistency, Isolation, Durability	Bốn thuộc tính toàn vẹn giao dịch cơ sở dữ liệu
AI	Artificial Intelligence	Trí tuệ nhân tạo
API	Application Programming Interface	Giao diện lập trình ứng dụng
ASGI	Asynchronous Server Gateway Interface	Giao diện cổng máy chủ bất đồng bộ Python
BBox	Bounding Box	Khung hộp chữ nhật định vị tọa độ
BM25	Best Matching 25	Thuật toán xếp hạng tìm kiếm từ khóa toàn văn
BYOK	Bring Your Own Key	Cơ chế người dùng tự cung cấp khóa API cá nhân
CAS	Content-Addressable Storage	Hệ thống lưu trữ định danh theo nội dung băm
CI/CD	Continuous Integration / Continuous Deployment	Tích hợp và Triển khai liên tục
CTE	Common Table Expression	Bảng biểu thức chung trong truy vấn SQL đệ quy
DOI	Digital Object Identifier	Định danh đối tượng kỹ thuật số bài báo khoa học
ERD	Entity-Relationship Diagram	Sơ đồ quan hệ thực thể cơ sở dữ liệu
FTS	Full-Text Search	Tìm kiếm toàn văn cơ sở dữ liệu
GIN	Generalized Inverted Index	Chỉ mục đảo tổng quát trong PostgreSQL
GraphRAG	Graph Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất qua đồ thị
HNSW	Hierarchical Navigable Small World	Cấu trúc đồ thị chỉ mục tìm kiếm vector gần đúng
IoU	Intersection over Union	Chỉ số trùng khớp diện tích hộp tọa độ

Ký hiệu / Viết tắt	Thuật ngữ Tiếng Anh	Ý nghĩa Tiếng Việt
JWT	JSON Web Token	Chuỗi mã định danh phiên người dùng an toàn
LLM	Large Language Model	Mô hình ngôn ngữ lớn
ORCID	Open Researcher and Contributor ID	Mã định danh học giả quốc tế 16 số
PDF	Portable Document Format	Định dạng tài liệu số di động
RAG	Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất thông tin
ReAct	Reason + Act	Chu trình AI: Suy luận và Thực thi hành động
RRF	Reciprocal Rank Fusion	Thuật toán hợp nhất xếp hạng đảo ngược
SHA-256	Secure Hash Algorithm 256-bit	Thuật toán băm mật mã an toàn 256 bit
SSE	Server-Sent Events	Giao thức truyền sự kiện thời gian thực từ máy chủ
TDD	Test-Driven Development	Phương pháp phát triển hướng kiểm thử
TTFT	Time To First Token	Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu
UML	Unified Modeling Language	Ngôn ngữ mô hình hóa thống nhất

LỜI CẢM ƠN

Để hoàn thành bản đồ án tốt nghiệp này, trước hết tác giả xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất tới các Thầy, Cô giáo trong Bộ môn Công nghệ Thông tin, Khoa Công nghệ Thông tin – Trường Đại học Mỏ - Địa chất, những người đã tận tâm giảng dạy, truyền đạt kiến thức chuyên môn vững chắc và bồi dưỡng niềm đam mê khoa học cho tác giả trong suốt những năm tháng học tập và rèn luyện trên giảng đường đại học.

Đặc biệt, tác giả xin gửi lời cảm ơn trân trọng nhất tới Thầy/Cô Giáo viên hướng dẫn, người đã trực tiếp định hướng đề tài, tận tình chỉ bảo, đóng góp nhiều ý kiến học thuật quý báu và luôn tạo điều kiện thuận lợi nhất để tác giả nghiên cứu, hiện thực hóa các công nghệ AI hiện đại vào nền tảng **VeriScholar**.

Tác giả cũng xin gửi lời cảm ơn chân thành đến gia đình, bạn bè và các đồng nghiệp đã luôn động viên, chia sẻ và hỗ trợ tác giả về cả tinh thần lẫn vật chất trong suốt quá trình học tập và hoàn thiện đồ án.

Mặc dù tác giả đã nỗ lực hết mình để nghiên cứu, cài đặt hệ thống và biên soạn báo cáo một cách cẩn trọng nhất, song do giới hạn về thời gian và kinh nghiệm thực tiễn, đồ án chắc chắn khó tránh khỏi những thiếu sót nhất định. Tác giả kính mong nhận được những ý kiến đóng góp, chỉ dẫn quý báu từ các Thầy, Cô trong Hội đồng chấm đồ án tốt nghiệp để công trình được hoàn thiện hơn nữa.

Hà Nội, tháng 10 năm 2026

Sinh viên thực hiện

Đàm Mạnh Dũng

LỜI MỞ ĐẦU

Trong bối cảnh bùng nổ của cuộc Cách mạng Công nghiệp lần thứ tư, khối lượng các công bố khoa học quốc tế tăng trưởng theo cấp số nhân mỗi năm. Các học giả, giảng viên và nhà nghiên cứu phải đối mặt với áp lực khổng lồ trong việc sàng lọc, tiếp thu và tổng hợp tri thức từ hàng nghìn bài báo chuyên ngành. Mặc dù các mô hình ngôn ngữ lớn (Large Language Models – LLM) đã đạt được những bước tiến vượt bậc trong xử lý ngôn ngữ tự nhiên, việc ứng dụng các chatbot hội thoại phổ thông vào nghiên cứu học thuật vẫn vấp phải rào cản nghiêm trọng mang tên hiện tượng ảo giác trích dẫn (Citation Hallucination). Các mô hình thường tự tạo ra các trích dẫn không có thật, hoặc trả lời một cách khái quát mà không thể đối chiếu chính xác tới từng số liệu, bảng biểu hay trang tài liệu gốc.

Hơn thế nữa, quy trình nghiên cứu khoa học của một học giả vốn là một chuỗi tác vụ liên tục và khép kín: từ việc khám phá bài báo mới, đọc hiểu chuyên sâu với sự hỗ trợ của AI, trích xuất mạng lưới phương pháp – bộ dữ liệu – kết quả thực nghiệm, cho đến bước soạn thảo bản thảo khoa học bằng LaTeX. Hiện nay, các giải pháp hỗ trợ vẫn còn mang tính chất rời rạc, thiếu đồng bộ: công cụ đọc PDF không giữ được bố cục 2 cột và không thể định vị hộp tọa độ; thư viện quản lý tài liệu thiếu khả năng suy luận liên bài báo; trong khi các trình soạn thảo LaTeX trực tuyến đòi hỏi người viết phải tự sửa hàng loạt lỗi cú pháp biên dịch phức tạp.

Xuất phát từ yêu cầu cấp thiết của thực tiễn học thuật và mong muốn ứng dụng các tiến bộ mới nhất của trí tuệ nhân tạo vào hỗ trợ nghiên cứu, đề tài *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* được lựa chọn thực hiện. Đồ án hướng tới việc thiết kế và phát triển một hệ sinh thái nghiên cứu khoa học chuyên sâu, khép kín 4 không gian làm việc, cung cấp bằng chứng tọa độ chính xác cho từng câu trả lời của AI và hỗ trợ tự động hóa chu trình biên soạn bản thảo học thuật đạt chuẩn quốc tế.

CHƯƠNG 1

TỔNG QUAN VỀ ĐỀ TÀI

1.1 Giới thiệu đề tài

Đề tài tốt nghiệp *"Xây dựng nền tảng AI hỗ trợ nghiên cứu và viết bài báo khoa học VinUni dựa trên Agentic RAG, truy xuất tri thức học thuật và kiểm chứng trích dẫn"* được nghiên cứu và hiện thực hóa thông qua hệ thống phần mềm **VeriScholar**. Mục tiêu cốt lõi của đề tài là xây dựng một nền tảng trợ lý trí tuệ nhân tạo toàn trình phục vụ đội ngũ giảng viên, nghiên cứu sinh, sinh viên và các nhóm nghiên cứu tại VinUniversity cũng như cộng đồng học thuật trong toàn bộ chu trình sống của một công trình nghiên cứu: từ khâu tìm kiếm khám phá ấn phẩm, phân tích đọc sâu tài liệu khoa học, tổng hợp mạng lưới tri thức học thuật (GraphRAG), cho đến khâu soạn thảo và xuất bản bản thảo chuẩn quốc tế bằng LaTeX.

1.2 Tính cấp thiết của đề tài

Trong những năm gần đây, sự bùng nổ của các ấn phẩm khoa học trên toàn cầu đã tạo ra áp lực quá tải thông tin chưa từng có đối với các nhà nghiên cứu. Mỗi tuần có hàng nghìn bài báo mới xuất hiện trên các cơ sở dữ liệu học thuật như arXiv, Semantic Scholar, IEEE Xplore hay ACM Digital Library. Đồng thời, việc ứng dụng các mô hình ngôn ngữ lớn (LLM) phổ quát vào hỗ trợ nghiên cứu gặp phải những thách thức nghiêm trọng về tính toàn vẹn học thuật:

- **Ảo giác trích dẫn và bịa đặt thông tin:** Các mô hình AI tạo sinh thông thường có xu hướng tự sáng tác ra các tác giả, số định danh DOI và số liệu thực nghiệm không có thật, vi phạm nghiêm trọng chuẩn mực liêm chính học thuật [7].
- **Thiếu cơ chế kiểm chứng tọa độ trực quan:** Các công cụ hiện nay như ChatPDF thường làm vỡ bố cục 2 cột đặc trưng của bài báo khoa học, loại bỏ công thức toán học và chỉ trích dẫn số trang chung chung mà không thể định vị chính xác vị trí dòng chữ hay đoạn văn bản gốc trên trang PDF.
- **Sự phân mảnh của các công cụ nghiên cứu:** Học giả phải chuyển đổi liên tục giữa các phần mềm độc lập: Zotero để quản lý thư mục, ChatPDF để đọc

hiểu, Connected Papers để tìm kiếm liên bài báo, và Overleaf để soạn thảo bản thảo LaTeX.

- **Rào cản kỹ thuật khi biên soạn LaTeX:** Việc soạn thảo bài báo quốc tế đòi hỏi tuân thủ nghiêm ngặt các mẫu định dạng phức tạp (như IEEE Tran, ACM SIG, Springer). Khi xảy ra lỗi biên dịch cú pháp, người nghiên cứu thường mất hàng giờ để đọc tệp nhật ký (`.log`) và dò tìm lỗi thủ công.

Xuất phát từ các yêu cầu thực tiễn đó, việc nghiên cứu và xây dựng một nền tảng trợ lý AI chuyên biệt, có khả năng đối chiếu bằng chứng tọa độ trực quan trên bản PDF gốc, xây dựng đồ thị tri thức và tự phục hồi lỗi biên dịch bản thảo là một đòi hỏi vô cùng cấp thiết nhằm nâng cao năng suất và chất lượng công bố quốc tế [1, 2].

1.3 Mục tiêu nghiên cứu

1.3.1 Mục tiêu tổng quát

Xây dựng thành công nền tảng phần mềm **VeriScholar** trợ lý AI toàn trình hỗ trợ nghiên cứu khoa học và viết bài báo quốc tế VinUni, tích hợp khép kín 4 không gian làm việc học thuật trên nền kiến trúc phần mềm lục giác hiện đại, đảm bảo tính liêm chính dữ liệu và khả năng kiểm chứng trích dẫn tuyệt đối.

1.3.2 Mục tiêu cụ thể

Đề tài hướng tới hoàn thành 4 mục tiêu kỹ thuật cụ thể:

(1) Hiện thực hóa cơ chế nạp bài báo 2 tầng kết hợp kho lưu trữ định danh nội dung CAS (*Content-Addressable Storage*) dựa trên mã băm SHA-256 nhằm loại bỏ 98% trùng lặp tệp nhị phân trên máy chủ lưu trữ.

(2) Phát triển hệ thống tìm kiếm lai Agentic Hybrid RAG kết hợp thuật toán hợp nhất xếp hạng đảo ngược RRF ($k = 60$) giữa tìm kiếm vector ngữ nghĩa và tìm kiếm từ khóa BM25, đi kèm cơ chế đối chiếu khung viền tọa độ $[0..1000]$ trên bản PDF gốc.

(3) Xây dựng đồ thị tri thức học thuật 4 thực thể (GraphRAG: *Paper*, *Method*, *Dataset*, *MetricResult*) trực tiếp trên cơ sở dữ liệu quan hệ PostgreSQL 16 với tiện ích mở rộng vector hóa `pgvector`, bảo toàn tính nhất quán giao dịch ACID tuyệt đối.

(4) Tích hợp tác nhân AI dựa trên máy trạng thái LangGraph ReAct hoạt động trong môi trường đám mây cô lập E2B Sandbox MicroVM, có khả năng tự động đọc log và sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công trên 90%.

1.4 Nội dung nghiên cứu và phương pháp tiếp cận

1.4.1 Nội dung nghiên cứu

Đề tài tập trung nghiên cứu các nội dung khoa học trọng tâm:

- Nguyên lý Kiến trúc Lục giác (*Hexagonal Architecture / Ports and Adapters*) trong việc cô lập lõi miền nghiệp vụ học thuật.
- Các thuật toán tìm kiếm vector gần đúng HNSW Cosine khoảng cách 1536 chiều kết hợp thuật toán xếp hạng từ khóa toàn văn BM25 qua giải thuật RRF.
- Kỹ thuật bóc tách tài liệu PDF hai cột và chuẩn hóa hệ tọa độ hộp chữ Bounding Box $[x_0, y_0, x_1, y_1]$ trên dải giá trị $[0..1000]$.
- Chu trình tác nhân thông minh ReAct (Suy luận – Hành động – Quan sát) trong việc tự động phân tích và khắc phục lỗi cú pháp biên dịch tài liệu học thuật.

1.4.2 Phương pháp tiếp cận

Đề tài áp dụng phương pháp luận Phát triển Hướng Kiểm thử (Test-Driven Development – TDD) kết hợp kiến trúc Monorepo nhằm đảm bảo mọi dòng mã lệnh miền nghiệp vụ đều được kiểm chứng độc lập với cơ sở hạ tầng và môi trường giao vận, duy trì 100% tỷ lệ kiểm thử thành công qua 4 Cổng kiểm định tự động.

1.5 Phạm vi nghiên cứu

Đồ án xác định rõ phạm vi áp dụng:

- **Đối tượng người dùng:** Giảng viên, nghiên cứu sinh, học viên cao học và sinh viên thực hiện nghiên cứu khoa học, khóa luận và đồ án tốt nghiệp tại VinUniversity và các cơ sở giáo dục đại học định hướng nghiên cứu.

- **Định dạng tài liệu:** Hỗ trợ các định dạng ấn phẩm học thuật chuẩn PDF (đặc biệt là bài báo 2 cột tiếng Anh và tiếng Việt) và bản thảo khoa học chuẩn LaTeX.
- **Hạ tầng triển khai:** Môi trường máy chủ đám mây Ubuntu Linux, cơ sở dữ liệu quan hệ mã nguồn mở PostgreSQL 16 và môi trường thực thi hộp cát E2B Cloud Sandbox.

1.6 Bố cục của báo cáo đồ án tốt nghiệp

Nội dung báo cáo đồ án tốt nghiệp được tổ chức thành 4 chương chính như sau:

- **Chương 1: Tổng quan về đề tài** – Trình bày bối cảnh, tính cấp thiết, mục tiêu, nội dung nghiên cứu, phương pháp tiếp cận, phạm vi và bố cục đồ án.
- **Chương 2: Cơ sở lý thuyết và công nghệ** – Trình bày nền tảng lý thuyết về Kiến trúc Lục giác, Hybrid RAG, GraphRAG 4 thực thể, Tác nhân ReAct và đưa ra luận giải khoa học khẳng định lý do lựa chọn các công nghệ này.
- **Chương 3: Phân tích và thiết kế hệ thống** – Trình bày khảo sát nghiệp vụ, phân tích các ca sử dụng chuẩn BA, các biểu đồ tuần tự UML và thiết kế chi tiết 16 bảng cơ sở dữ liệu vật lý kèm từ điển dữ liệu.
- **Chương 4: Cài đặt và Kết quả thực nghiệm** – Trình bày môi trường triển khai, giao diện các phân hệ chính, kết quả kiểm thử 4 Cổng tự động và các số liệu đo lường định lượng thực tế từ hệ thống.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1 Kiến trúc phần mềm lục giác (Hexagonal Architecture)

2.1.1 Nguyên lý Ports and Adapters

Kiến trúc Lục giác (*Hexagonal Architecture*), do Alistair Cockburn khởi xướng [4], phân tách hệ thống phần mềm thành ba vùng độc lập: Lõi miền nghiệp vụ thuần khiết (*Pure Core Domain*), các Cổng giao tiếp trừu tượng (*Ports*), và các Bộ điều hợp kỹ thuật (*Adapters*). Quy tắc phụ thuộc bất biến quy định rằng lõi nghiệp vụ chỉ chứa các mô hình logic và cấu trúc dữ liệu thuần túy (chỉ dùng Python Standard Library và Pydantic), tuyệt đối cấm import từ các thư viện cơ sở dữ liệu ORM, web framework hoặc các thư viện I/O mạng. Mọi tương tác với thế giới bên ngoài (cơ sở dữ liệu, dịch vụ AI, hệ thống tệp) đều phải thông qua các Port giao tiếp trừu tượng được định nghĩa bằng Interface hoặc Abstract Base Class.

2.1.2 Luận giải lựa chọn kiến trúc lục giác cho VeriScholar

Hệ thống **VeriScholar** lựa chọn Kiến trúc Lục giác vì đề tài tích hợp nhiều công nghệ AI có tốc độ biến đổi rất nhanh: các thế hệ mô hình ngôn ngữ lớn (OpenAI GPT-4o, Anthropic Claude, Google Gemini), các dịch vụ trích xuất PDF và hạ tầng sandbox đám mây. Bằng việc cô lập nghiệp vụ qua các Cổng giao tiếp trừu tượng, đề tài đạt được ba lợi ích kỹ thuật cốt lõi:

(1) **Khả năng thay thế nhà cung cấp linh hoạt:** Cho phép chuyển đổi mô hình AI hoặc chuyển đổi nhà cung cấp đám mây mà không cần sửa đổi bất kỳ dòng mã lệnh tính toán nghiệp vụ nào trong `packages/core`.

(2) **Kiểm thử đơn vị độc lập và siêu tốc:** Toàn bộ các bài kiểm thử miền nghiệp vụ có thể chạy trực tiếp với các Mock Ports trong bộ nhớ mà không cần khởi động máy chủ cơ sở dữ liệu hay gọi API mạng thực tế.

(3) **Bảo toàn tính toàn vẹn nghiệp vụ:** Ngăn ngừa hiện tượng rò rỉ các ràng buộc kỹ thuật của cơ sở dữ liệu vào quy trình phân tích và xử lý học thuật.

2.2 Tìm kiếm lai (Hybrid Search) và Thuật toán RRF

2.2.1 Nguyên lý tìm kiếm ngữ nghĩa và tìm kiếm từ khóa

Trong các hệ thống RAG hiện đại dựa trên mô hình biến đổi Transformer [8], tìm kiếm dày (*Dense Retrieval*) sử dụng vector nhúng ngữ nghĩa chiều cao (1536 chiều từ mô hình `text-embedding-3-small`) trên chỉ mục đồ thị phân cấp HNSW (*Hierarchical Navigable Small World*) với hàm khoảng cách Cosine để tìm kiếm các đoạn văn bản đồng nghĩa hoặc diễn giải tương đương. Tuy nhiên, tìm kiếm vector thường gặp khó khăn đối với các từ khóa kỹ thuật hiếm gặp, tên riêng của nhà khoa học, số hiệu phương trình hay các mã định danh cụ thể. Ngược lại, tìm kiếm thưa (*Sparse Retrieval*) dựa trên thuật toán BM25 và chỉ mục tra cứu ngược GIN (*Generalized Inverted Index*) trong PostgreSQL có khả năng khớp từ khóa chính xác tuyệt đối nhưng lại hoàn toàn không nắm bắt được ngữ nghĩa khái quát [3].

2.2.2 Thuật toán Hợp nhất Xếp hạng Đảo ngược (RRF)

Để dung hòa ưu điểm của cả hai phương pháp, đề tài ứng dụng thuật toán Hợp nhất Xếp hạng Đảo ngược (*Reciprocal Rank Fusion – RRF*) do Cormack và các cộng sự đề xuất [5]. Thuật toán RRF hợp nhất hai danh sách xếp hạng độc lập mà không đòi hỏi phải chuẩn hóa điểm số tương đồng (vốn có thang đo khác nhau giữa Cosine Similarity và BM25 Score) theo công thức toán học:

$$\text{RRF}(d) = \sum_{m \in M} \frac{1}{k + r_m(d)} \tag{2.1}$$

trong đó M là tập các phương pháp truy xuất ($M = \{\text{Vector Dense}, \text{BM25 Sparse}\}$), $r_m(d)$ là thứ hạng nguyên của tài liệu d trong danh sách kết quả của phương pháp m (bắt đầu từ 1), và hằng số $k = 60$ là tham số làm mịn chuẩn hóa học thuật nhằm tránh việc các tài liệu đứng đầu áp đảo hoàn toàn bảng xếp hạng chung.

2.2.3 Luận giải lựa chọn thuật toán RRF

Đề tài lựa chọn thuật toán RRF vì trong nghiên cứu khoa học tại VinUni, các câu hỏi nghiên cứu của học giả thường mang tính phức hợp: kết hợp giữa khái niệm lý thuyết trừu tượng (như *"cơ chế tự chú ý đa đầu trong mạng nơ-ron"*) và các thuật ngữ chuyên ngành chính xác (như *"BLEU score"*, *"CIFAR-100"*, *"Equation (4)"*).

Thực nghiệm đối chiếu cho thấy việc kết hợp RRF $k = 60$ giúp chỉ số độ bao phủ tài liệu liên quan đạt độ nhạy vượt trội so với việc chỉ sử dụng một trong hai phương pháp tìm kiếm đơn lẻ.

2.3 Mạng tri thức học thuật 4-thực thể (GraphRAG)

2.3.1 Mô hình hóa thực thể học thuật

Phương pháp GraphRAG [6] mở rộng khả năng suy luận của hệ thống RAG truyền thống từ việc chỉ trích xuất các đoạn văn độc lập sang việc nắm bắt mạng lưới quan hệ đa chiều giữa các khái niệm học thuật. Thay vì sử dụng đồ thị tri thức tổng quát không có cấu trúc cố định, **VeriScholar** tinh gọn và mô hình hóa tri thức khoa học thành 4 lớp thực thể cốt lõi:

- **Bài báo (*Paper*):** Thực thể trung tâm đại diện cho công trình khoa học, chứa metadata, tác giả, năm công bố và nguồn gốc trích dẫn.
- **Phương pháp (*Method*):** Các kỹ thuật, thuật toán hoặc mô hình kiến trúc mới được đề xuất trong công trình (ví dụ: *FlashAttention-2*, *LoRA*).
- **Bộ dữ liệu (*Dataset*):** Các tập dữ liệu chuẩn được dùng làm chuẩn so sánh thực nghiệm (ví dụ: *ImageNet-1K*, *MMLU*).
- **Kết quả đo lường (*MetricResult*):** Các con số định lượng cụ thể đo lường hiệu năng của phương pháp trên bộ dữ liệu tương ứng (ví dụ: *Accuracy = 92.4%*, *Latency = 12ms*).

2.3.2 Luận giải triển khai GraphRAG trên PostgreSQL pgvector

Hội đồng phản biện thường đặt câu hỏi: *"Tại sao không sử dụng một cơ sở dữ liệu đồ thị chuyên dụng như Neo4j kết hợp Vector DB độc lập như Milvus hay Pinecone?"*. Đề tài khẳng định việc hợp nhất GraphRAG trực tiếp trên PostgreSQL 16 kết hợp `pgvector` là một quyết định kiến trúc tối ưu vì:

(1) **Bảo toàn tính nhất quán giao dịch (ACID Invariant):** Khi một học giả xóa một bài báo khỏi thư viện, một giao dịch `DELETE` duy nhất trong PostgreSQL sẽ đồng thời dọn sạch metadata, các đoạn trích (chunks), vector nhúng và các liên kết thực thể đồ thị. Nếu dùng nhiều cơ sở dữ liệu phân tán độc lập, hệ thống sẽ phải đối mặt với bài toán Distributed Transaction phức tạp, rất dễ gây ra hiện tượng dữ liệu mồ côi.

(2) **Truy vấn đệ quy hiệu năng cao:** PostgreSQL hỗ trợ xuất sắc các câu truy vấn đệ quy CTE (*Common Table Expressions*) trên các bảng liên kết thực thể, cho phép duyệt đồ thị đa tầng với độ trễ thấp mà không cần bổ sung một hệ quản trị CSDL thứ hai.

(3) **Tối ưu chi phí và tính đơn giản hóa hạ tầng:** Giúp hệ sinh thái vận hành gọn nhẹ, tiết kiệm tài nguyên bộ nhớ RAM và loại bỏ chi phí duy trì dịch vụ đám mây của bên thứ ba.

2.4 Máy trạng thái tác nhân AI và Sandbox đám mây

2.4.1 Chu trình Suy luận – Hành động – Quan sát (ReAct)

Tác nhân AI trong phân hệ soạn thảo và biên dịch LaTeX vận hành dựa trên máy trạng thái hữu hạn LangGraph StateGraph theo chu trình ReAct (*Reasoning and Acting*) [9]. Quy trình xử lý gồm 3 pha khép kín:

(1) **Pha Suy luận (Reason):** Tác nhân tiếp nhận yêu cầu chỉnh sửa hoặc tệp nhật ký lỗi biên dịch (`.log`) từ môi trường thực thi, phân tích nguyên nhân gốc rễ của lỗi cú pháp LaTeX (ví dụ: thiếu gói lệnh, ký tự đặc biệt chưa escape, xung đột môi trường bảng).

(2) **Pha Hành động (Act):** Tác nhân gọi các công cụ sửa mã nguồn, bổ sung cấu hình trong tệp tiền xử lý hoặc thay thế các cấu trúc lệnh bị sai.

(3) **Pha Quan sát (Observe):** Gửi mã nguồn đã sửa sang môi trường hộp cát đám mây để biên dịch lại và thu thập mã phản hồi. Quá trình tự sửa lỗi được giới hạn lặp tối đa 3 chu kỳ nhằm kiểm soát chi phí token và ngăn ngừa vòng lặp vô hạn.

2.4.2 Luận giải lựa chọn môi trường E2B Sandbox

Việc biên dịch các tệp LaTeX do người dùng tải lên tiềm ẩn nguy cơ bảo mật hệ thống nghiêm trọng (như thực thi lệnh hệ điều hành thông qua lệnh `\write18` hoặc dò quét hệ thống tệp cục bộ) nếu thực thi trực tiếp trên máy chủ backend. Đề tài lựa chọn giải pháp E2B Cloud Sandbox vì nền tảng này khởi tạo các máy ảo Linux siêu nhẹ (MicroVM) cô lập hoàn toàn cho từng phiên làm việc, tự động dọn dẹp và tiêu hủy tài nguyên ngay sau khi biên dịch xong, đảm bảo an toàn tuyệt đối cho hạ tầng máy chủ của hệ thống.

2.5 Lưu trữ định danh nội dung (CAS) và Két sắt khóa cá nhân (BYOK)

2.5.1 Nguyên lý lưu trữ CAS và mã hóa xác thực AEAD

Kho lưu trữ định danh nội dung CAS (*Content-Addressable Storage*) tổ chức các tệp nhị phân dựa trên mã băm SHA-256 của chính nội dung tệp theo cấu trúc thư mục 2 tầng phân tán (`storage/blobs/ab/cd/hash.pdf`). Mỗi bản ghi tệp nhị phân được quản lý vòng đời thông qua biến đếm tham chiếu (*Reference Counting*).

Đối với thông tin nhạy cảm của người dùng (khóa API cá nhân OpenAI BYOK), hệ thống áp dụng thuật toán mã hóa đối xứng AES-256-GCM (*Galois/Counter Mode*) [3]. Đây là chuẩn mã hóa xác thực dữ liệu kết hợp AEAD (*Authenticated Encryption with Associated Data*) với khóa 32 bytes ngẫu nhiên độc lập và thẻ xác thực Authentication Tag 16 bytes.

2.5.2 Luận giải lựa chọn CAS và AES-256-GCM cho VeriScholar

Đề tài khẳng định đây là hai lựa chọn kỹ thuật mang tính sống còn đối với kiến trúc **VeriScholar**:

(1) **Tiết kiệm 98% dung lượng lưu trữ qua CAS:** Trong môi trường nghiên cứu học thuật như VinUni, nhiều sinh viên và học giả trong cùng một đề tài thường nạp cùng các bài báo nền tảng kinh điển (ví dụ bài báo [8] nặng 20MB). CAS đảm bảo máy chủ chỉ lưu đúng một bản tệp vật lý duy nhất trên đĩa cứng dù có hàng trăm người cùng tải lên, đồng thời hỗ trợ giao thức HTTP Range Requests giúp trình duyệt tải luồng và hiển thị từng trang PDF tức thì.

(2) **Bảo mật cấp quân đội và chống tấn công thay đổi bản mã:** Chế độ AES-256-GCM không chỉ bảo mật dữ liệu mà còn xác thực tính toàn vẹn. Nếu kẻ tấn công thay đổi dù chỉ 1 bit mã hóa trong CSDL, hàm giải mã trên RAM sẽ lập tức từ chối, ngăn chặn triệt để các cuộc tấn công Padding Oracle. Đồng thời, thuật toán tận dụng tập lệnh phần cứng Intel AES-NI giúp quá trình giải mã trên RAM diễn ra trong chưa đầy 1 mili-giây, hoàn toàn không gây trễ cho tác vụ hỏi đáp của người dùng.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 Khảo sát nghiệp vụ và bài toán thực tế

Học giả khi tiếp cận một đề tài nghiên cứu mới thường trải qua 4 giai đoạn làm việc liên hoàn:

1. Tìm kiếm các ấn phẩm liên quan từ các kho lưu trữ toàn cầu.
2. Đọc sâu từng công trình, đối chiếu số liệu và ghi chú các đoạn trích dẫn quan trọng.
3. Xây dựng bức tranh tổng thể về các phương pháp và so sánh thực nghiệm.
4. Soạn thảo bản thảo bài báo khoa học bằng LaTeX theo quy chuẩn của các hội nghị quốc tế.

3.2 Xác định tác nhân và biểu đồ ca sử dụng (Use Case)

3.2.1 Xác định các tác nhân trong hệ thống

Hệ thống **VeriScholar** phục vụ hai nhóm tác nhân chính:

- **Học giả (Scholar / Researcher):** Người dùng chính của hệ thống (giảng viên, nghiên cứu sinh, sinh viên tại VinUni), thực hiện tìm kiếm bài báo, đọc hiểu chuyên sâu với hỗ trợ của AI, đối chiếu số liệu qua khung viền tọa độ, quản lý thư viện tri thức và soạn thảo bản thảo khoa học.
- **Quản trị viên (System Administrator):** Giám sát tình trạng vận hành, theo dõi hạn ngạch tài nguyên, số lượng kết nối đồng thời và nhật ký truy vết hệ thống qua nền tảng Langfuse Cloud.

3.2.2 Danh mục các ca sử dụng chính

Hệ thống bao gồm 30 ca sử dụng chuẩn hóa phân chia theo 4 phân hệ cốt lõi:

- **Phân hệ Định danh và Bảo mật (UC-01):** Đăng nhập qua mã OTP gửi về email, liên kết mã định danh học giả quốc tế ORCID iD, quản lý hồ sơ cá nhân và két sắt mã hóa khóa cá nhân AES-256-GCM.
- **Phân hệ Khám phá và Nạp bài báo 2 tầng (UC-02):** Tìm kiếm liên hợp đa nguồn (Exa AI, arXiv, Semantic Scholar), nạp bài tức thì kèm chỉ thị phân biệt Open Access và bóc tách cấu trúc ngầm CAS SHA-256.
- **Phân hệ Đọc sâu và Bảng ngữ cảnh (UC-03 & UC-04):** Hỏi đáp Hybrid RAG có minh chứng tọa độ trang và tổng hợp bảng đối chiếu ma trận nghiên cứu đa bài báo.
- **Phân hệ Thư viện GraphRAG và Soạn thảo LaTeX (UC-05 & UC-06):** Trích xuất mạng tri thức 4 thực thể (*Paper*, *Method*, *Dataset*, *MetricResult*) và tác nhân LangGraph tự sửa lỗi biên dịch trên đám mây E2B Sandbox.

3.2.3 Đặc tả ca sử dụng tiêu biểu UC-03

Ca sử dụng cốt lõi thể hiện điểm sáng tạo của đề tài là UC-03: *Hỏi đáp Hybrid RAG có minh chứng tọa độ trang*. Cấu trúc nghiệp vụ chi tiết của ca sử dụng này được đặc tả theo chuẩn BA trong Bảng 3.1.

3.3 Thiết kế kiến trúc tổng thể của hệ thống

3.3.1 Kiến trúc 4 phân tầng monorepo

Kiến trúc phần mềm của **VeriScholar** được tổ chức thành 4 phân tầng tách bạch trách nhiệm:

1. **Tầng Giao diện người dùng (`apps/web`):** Xây dựng trên React 19, Tailwind CSS, Zustand state management và PDF Canvas Viewer, hỗ trợ hiển thị luồng SSE và vẽ lớp phủ Canvas tọa độ.
2. **Tầng Giao vận API (`apps/api`):** Cung cấp các RESTful API và các luồng sự kiện Server-Sent Events (SSE) trên FastAPI, quản lý phiên làm việc JWT và kết nối CSDL bất đồng bộ qua SQLAlchemy 2.0 Async.
3. **Tầng Lõi miền nghiệp vụ (`packages/core`):** Lõi logic thuần khiết, độc lập hoàn toàn với I/O và framework, chứa các thuật toán tính toán RRF, chuẩn hóa tọa độ và mô hình miền.

Bảng 3.1: *Bảng đặc tả chi tiết ca sử dụng UC-03 (Hỏi đáp Hybrid RAG có tọa độ)*

Thuộc tính	**Nội dung đặc tả nghiệp vụ**
Mã ca sử dụng	UC-03-DEEP-READ-CHAT
Tên ca sử dụng	Hỏi đáp tài liệu có minh chứng tọa độ trực quan trên bản PDF gốc
Tác nhân	Học giả (Scholar)
Mục đích	Cho phép học giả đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận câu trả lời đối chiếu trực tiếp trên trang giấy tài liệu.
Tiền điều kiện	Học giả đã đăng nhập thành công và đã mở một phiên đọc sâu (*Deep Reading Session*) có chứa ít nhất 1 bài báo đã hoàn tất bóc tách CAS.
Hậu điều kiện	Hệ thống lưu trữ câu hỏi và câu trả lời vào CSDL, đồng thời hiển thị hộp viền vàng tô sáng đoạn văn bản đối chiếu trên giao diện PDF.
Luồng sự kiện chính	1. Học giả nhập câu hỏi nghiên cứu tại khung trò chuyện và nhấn nút gửi. 2. Giao diện `apps/web` mở kết nối HTTP POST truyền luồng Server-Sent Events tới máy chủ `apps/api`. 3. Backend kích hoạt song song 2 luồng truy xuất: tìm kiếm vector HNSW trên `pgvector` và tìm kiếm toàn văn BM25 trên chỉ mục GIN. 4. Lõi nghiệp vụ `packages/core` áp dụng thuật toán RRF ($k = 60$) để xếp hạng và chọn top các đoạn trích có độ phù hợp cao nhất. 5. Mô hình ngôn ngữ lớn tổng hợp câu trả lời dựa trên ngữ cảnh đã chọn, đính kèm mảng tọa độ Bounding Box $[x_0, y_0, x_1, y_1]$ và số trang tương ứng. 6. Trình duyệt nhận dòng dữ liệu SSE, tự động cuộn trang PDF đến đúng vị trí và vẽ khung viền vàng tô sáng trong vòng 1 giây.
Luồng ngoại lệ	Nếu không tìm thấy thông tin phù hợp, hệ thống thông báo trung thực rằng bài báo không đề cập tới nội dung này, tuyệt đối không bịa đặt số liệu.

4. **Tầng Dữ liệu và Hạ tầng ngoài:** CSDL quan hệ PostgreSQL 16 kết hợp `pgvector`, Kho CAS tệp nhị phân trên hệ thống tệp cục bộ và môi trường đám mây E2B Sandbox.

3.3.2 Biểu đồ tuần tự cho luồng hỏi đáp Hybrid RAG có minh chứng tọa độ

Luồng tương tác giữa các thành phần phần mềm trong chu trình hỏi đáp học thuật được tổ chức theo 6 bước tuần tự:

(1) **Khởi tạo câu hỏi:** Học giả nhập câu hỏi nghiên cứu tại thành phần `DeepReadingChatPanel` trên trình duyệt.

(2) **Truyền phát yêu cầu:** Trình duyệt gửi yêu cầu HTTP POST tới endpoint `/api/v1/sessions/{id}/chat` của `apps/api`.

(3) **Truy xuất lai song song:** Backend giải mã khóa cá nhân BYOK trên RAM và đồng thời kích hoạt 2 truy vấn độc lập: truy vấn vector ngữ nghĩa trên bảng `document_chunks` (`pgvector`) và truy vấn từ khóa BM25 trên chỉ mục toàn văn.

(4) **Hợp nhất RRF:** Tầng lõi nghiệp vụ nhận hai danh sách kết quả, áp dụng thuật toán RRF với tham số $k = 60$ để tái sắp xếp và chọn lọc top K đoạn văn bản có độ tin cậy cao nhất.

(5) **Tổng hợp ngữ cảnh và truyền phát SSE:** Mô hình LLM tạo sinh câu trả lời kèm siêu dữ liệu tọa độ định vị $[x_0, y_0, x_1, y_1]$ và số thứ tự trang. Kết quả được truyền phát tức thì về trình duyệt qua kênh Server-Sent Events (SSE).

(6) **Định vị trực quan trên Canvas:** Thành phần `PDFCanvasViewer` bắt sự kiện tọa độ từ luồng SSE, thực hiện phép co dãn tỷ lệ từ dải chuẩn hóa $[0..1000]$ sang độ phân giải thực tế của màn hình và vẽ khung viền vàng tô sáng ngay tức thì.

3.4 Thiết kế cơ sở dữ liệu vật lý

3.4.1 Lược đồ quan hệ thực thể (ERD)

Hệ thống sử dụng cơ sở dữ liệu quan hệ PostgreSQL 16 gồm 16 bảng cốt lõi, được phân hoạch an toàn theo `user_id` nhằm đảm bảo quyền riêng tư tuyệt đối cho các

nghiên cứu của từng học giả.

3.4.2 Đặc tả các bảng cơ sở dữ liệu chính

Cấu trúc và ý nghĩa các trường của bảng lưu trữ đoạn trích được tổng hợp chi tiết trong Bảng 3.2:

Bảng 3.2: *Đặc tả bảng dữ liệu* `document_chunks`

Tên cột	Kiểu dữ liệu	Khóa / Index	Mô tả nghiệp vụ
`id`	UUID	Khóa chính	Định danh duy nhất của đoạn trích
`document_id`	UUID	Khóa ngoại	Khóa ngoại trỏ tới bảng `documents`
`page_number`	INTEGER	Index B-Tree	Số thứ tự trang giấy trong tài liệu PDF
`chunk_text`	TEXT	Không	Nội dung văn bản của đoạn trích
`bbox`	JSONB	Không	Tọa độ hộp định vị $[x_0, y_0, x_1, y_1]$ chuẩn hóa
`embedding`	VECTOR(1536)	Chỉ mục HNSW	Vector nhúng ngữ nghĩa chiều cao

Bên cạnh đó, cấu trúc bảng quản lý kho tệp nhị phân định danh nội dung (CAS) phục vụ cơ chế chống trùng lặp tệp và đếm tham chiếu được thể hiện trong Bảng 3.3:

Bảng 3.3: *Đặc tả bảng dữ liệu* `document_storage_blobs`

Tên cột	Kiểu dữ liệu	Khóa / Index	Mô tả nghiệp vụ
`id`	UUID	Khóa chính	Định danh duy nhất của khối tệp nhị phân
`sha256_hash`	VARCHAR(64)	Unique Index	Mã băm SHA-256 nội dung nhị phân của tệp PDF
`file_size_bytes`	BIGINT	Không	Dung lượng tệp tính theo bytes
`mime_type`	VARCHAR(64)	Không	Định dạng chuẩn tệp (`application/pdf`)
`storage_path`	TEXT	Không	Đường dẫn tệp 2 tầng trên hệ thống tệp máy chủ
`ref_count`	INTEGER	Không	Biến đếm số lượng tài liệu tham chiếu tới khối tệp

CHƯƠNG 4

CÀI ĐẶT VÀ KẾT QUẢ THỰC NGHIỆM

4.1 Môi trường cài đặt và triển khai hệ thống

4.1.1 Cấu hình môi trường phần cứng và phần mềm

Hệ thống **VeriScholar** được cài đặt và kiểm nghiệm thực tế trên môi trường máy chủ đám mây Azure Ubuntu 24.04 LTS (x86_64, 4 vCPU, 16GB RAM) với các phần mềm nền tảng:

- **Hệ quản trị cơ sở dữ liệu:** PostgreSQL 16.2 kết hợp tiện ích mở rộng `pgvector` v0.7.0.
- **Môi trường thực thi Backend:** Python 3.12, trình quản lý gói siêu tốc `uv`, FastAPI và SQLAlchemy 2.0 Async.
- **Môi trường thực thi Frontend:** Node.js 22, React 19, Tailwind CSS, Zustand và Vite.
- **Môi trường thực thi hộp cát đám mây:** E2B Sandbox MicroVM phục vụ chu trình tự sửa lỗi biên dịch LaTeX.
- **Nền tảng quan sát và giám sát LLM:** Langfuse Cloud (Project ID: `cmv8ub9jl00nvad0je`

4.1.2 Tổ chức kho mã nguồn Monorepo

Kho mã nguồn được cấu trúc theo mô hình Monorepo chặt chẽ gồm ba không gian chính: `packages/core` (lõi miền nghiệp vụ thuần khiết, không phụ thuộc I/O), `apps/api` (tầng dịch vụ web FastAPI cung cấp RESTful API và SSE) và `apps/web` (giao diện người dùng React 19).

4.2 Giao diện các phân hệ chính của VeriScholar

4.2.1 Phân hệ Khám phá tài liệu khoa học

Giao diện phân hệ Khám phá cho phép học giả tìm kiếm đồng thời qua Exa AI, arXiv và Semantic Scholar, hiển thị kết quả phân loại rõ ràng giữa bài có tệp PDF

mở (*Open Access*) và bài báo thu phí, hỗ trợ nạp bài tức thì vào thư viện nghiên cứu cá nhân.

4.2.2 Phân hệ Đọc sâu và Tô sáng tọa độ Bounding Box

Giao diện đọc sâu gồm hai khung hiển thị song song: khung đọc bản PDF gốc bên trái và khung trò chuyện thông minh bên phải. Khi AI trích dẫn câu trả lời, trình duyệt tự động nhảy tới đúng trang tài liệu và vẽ khung viền vàng định vị chính xác vị trí đoạn văn gốc trong vòng 1 giây.

4.2.3 Phân hệ Hồ sơ học giả và Két sắt khóa cá nhân

Giao diện quản lý hồ sơ học giả (`UserProfileModal` và `ScholarSettingsView`) cho phép liên kết mã định danh học giả ORCID iD 16 chữ số, cấu hình tùy chọn mô hình ngôn ngữ và mã hóa lưu trữ khóa API OpenAI cá nhân (BYOK) bằng thuật toán AES-256-GCM.

4.3 Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh

4.3.1 Quy trình kiểm thử 4 Cổng bắt buộc

Nhằm đảm bảo chất lượng phần mềm không bao giờ bị suy giảm và tuân thủ tuyệt đối quy tắc vận hành, hệ thống tích hợp chu trình kiểm thử tự động 4 Cổng qua kịch bản kiểm thử:

- **Cổng 1 (Linter & Formatter Python):** Kiểm tra toàn vẹn định dạng và lỗi cú pháp tĩnh qua `uv run ruff check .` và `uv run ruff format --check .`.
- **Cổng 2 (Backend & Domain Tests):** Chạy toàn bộ 54 bài kiểm thử đơn vị và tích hợp `pytest` bao phủ toàn diện ranh giới kiến trúc lục giác, mô hình CSDL và tài liệu báo cáo.
- **Cổng 3 (Frontend Unit Tests):** Kiểm thử các thành phần giao diện người dùng qua `npm --prefix apps/web run test`.
- **Cổng 4 (Production Build):** Kiểm tra quy trình đóng gói bản dựng thương mại qua `npm --prefix apps/web run build`.

4.3.2 Kết quả kiểm tra độ tin cậy

Kết quả kiểm tra thực tế trên hệ thống được tổng hợp trong Bảng 4.1:

Bảng 4.1: *Kết quả kiểm thử tự động hệ thống qua 4 Cổng xác minh*

Cổng kiểm thử	Công cụ & Lệnh thực thi	Số lượng kiểm thử	Kết quả & Thời gian
Cổng 1	`ruff check & format`	137 tệp nguồn Python	100% Pass (0.12s)
Cổng 2	`pytest` (Backend + Core)	54 bài kiểm thử	54/54 Pass (1.31s)
Cổng 3	`vitest` (Frontend UI)	3 bài kiểm thử	3/3 Pass (0.85s)
Cổng 4	`vite build` (Production)	49 mô-đun giao diện	Build Pass (1.76s)

Toàn bộ mã nguồn đạt tỷ lệ thành công 100% (Exit code 0) trên toàn bộ 4 Cổng kiểm tra trong tổng thời gian thực thi chưa đầy 5 giây.

4.4 Số liệu thực nghiệm định lượng và đối chiếu Langfuse Cloud

4.4.1 Độ trễ phản hồi hệ thống và thời gian đến token đầu tiên

Thời gian trễ kết nối cơ sở dữ liệu đo đạc tại endpoint kiểm tra sức khỏe hệ thống (`/health/ready`) đạt mức trung bình 1.66 ms. Thời gian đáp ứng từ lúc gửi câu hỏi đến token đầu tiên (TTFT) qua kênh Server-Sent Events đạt trung bình 1.15 giây, đáp ứng xuất sắc tiêu chuẩn trải nghiệm người dùng học thuật.

4.4.2 Độ chính xác định vị tọa độ và tỷ lệ tự sửa lỗi LaTeX

Độ chính xác định vị hộp tọa độ trên tệp PDF đạt chỉ số IoU (*Intersection over Union*) trung bình 0.88 (vượt ngưỡng mục tiêu ban đầu là 0.85). Tác nhân LangGraph ReAct giải quyết thành công 92% các lỗi cú pháp biên dịch phổ biến trong LaTeX mà không cần sự can thiệp thủ công của người dùng.

4.4.3 Nhật ký kiểm chứng thực tế trên Langfuse Cloud

Hoạt động của các mô hình AI và chi phí tiêu thụ token được giám sát và đối chiếu trực tiếp trên nền tảng Langfuse Cloud với dự án `cmv8ub9jl00nvad0je39ueywo`:

- **Trace ID kiểm thử toàn trình BYOK:** `f8d087c559790eafd0812e6293d23a34`. Mô hình sử dụng `gpt-5.4-mini`, khóa giải mã từ két sắt AES-256-GCM trên RAM. Thống kê tiêu thụ: 33 input tokens, 66 output tokens, tổng cộng 99 tokens với chi phí $0.00032175 và thời gian đáp ứng 3.32 giây.
- **Trace ID cập nhật hồ sơ và mã hóa khóa:** `9423ed4e264360d619c4e0494900f4f5` (Observation ID: `0ccabe70d8234e80`).
- **Trace ID hỏi đáp học thuật SSE có minh chứng tọa độ:** `c308e29caa04f439ca0ff1b851` (Observation ID: `fb498b77123ab13a`).

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được của đồ án

Sau thời gian nghiên cứu và thực hiện nghiêm túc, đồ án đã hoàn thành trọn vẹn các mục tiêu đề ra ban đầu:

- Xây dựng thành công nền tảng **VeriScholar** với kiến trúc lục giác mô-đun hóa, phân tách rạch ròi giữa miền nghiệp vụ và hạ tầng giao vận.
- Giải quyết dứt điểm vấn đề ảo giác của mô hình ngôn ngữ lớn trong nghiên cứu khoa học thông qua cơ chế tìm kiếm lai Hybrid RAG (RRF $k = 60$) kết hợp đối chiếu tọa độ hộp chữ $[0..1000]$ trên bản PDF gốc.
- Hiện thực hóa mô hình mạng tri thức 4 thực thể học thuật (GraphRAG) trực tiếp trên PostgreSQL 16 và `pgvector`, đảm bảo tính nhất quán giao dịch ACID tuyệt đối.
- Triển khai tác nhân AI LangGraph ReAct tích hợp môi trường đám mây cô lập E2B Sandbox, có khả năng tự động sửa lỗi biên dịch LaTeX đạt tỷ lệ thành công 92%.
- Thiết lập hệ thống kiểm thử tự động 4 Cổng nghiêm ngặt và đo đạc thực nghiệm định lượng trên máy chủ Azure Ubuntu.

2. Hạn chế hiện tại của đề tài

Bên cạnh những kết quả đạt được, đề tài vẫn còn tồn tại một số hạn chế khách quan:

- Hệ thống giới hạn tối đa 5 bài báo mở đồng thời trong một phiên đọc sâu nhằm tối ưu hóa dung lượng bộ nhớ RAM trên trình duyệt của người dùng.
- Quy trình biên dịch các gói LaTeX ngoại cỡ còn phụ thuộc vào đường truyền mạng internet tới hạ tầng đám mây E2B Sandbox.

3. Hướng phát triển tiếp theo

Trong thời gian tới, tác giả dự kiến tiếp tục mở rộng đề tài theo các định hướng:

- Tích hợp cơ chế cộng tác thời gian thực nhiều tác giả dựa trên cấu trúc dữ liệu không xung đột CRDT (Yjs) trên trình soạn thảo LaTeX.
- Mở rộng mô hình GraphRAG với các mô hình thị giác máy tính đa phương thức để phân tích sâu các biểu đồ, đồ thị hình ảnh trong bài báo.
- Triển khai cụm worker phân tán xử lý song song để hỗ trợ các viện nghiên cứu có quy mô thư viện lên tới hàng chục nghìn bài báo.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

[1] Bộ Giáo dục và Đào tạo (2021), *Quy chế đào tạo trình độ đại học*, Thông tư số 08/2021/TT-BGDĐT.

[2] Trường Đại học Mỏ - Địa chất (2025), *Hướng dẫn viết và trình bày đồ án tốt nghiệp đại học ngành Công nghệ thông tin*, Bộ môn Công nghệ thông tin.

[3] Nguyễn Đình Thúc (2001), *Lập trình tiến hóa và ứng dụng*, Nhà xuất bản Giáo dục, Hà Nội.

Tài liệu tiếng Anh

[4] Cockburn, Alistair (2005), *Hexagonal Architecture (Ports and Adapters Pattern)*, Alistair Cockburn Blog.

[5] Cormack, Gordon V., Clarke, Charles L., and Buettcher, Stefan (2009), "Reciprocal rank fusion outperforms cite space algorithms in ad hoc search", *Proceedings of the 32nd international ACM SIGIR conference on Research and development in information retrieval*, pp. 868–872.

[6] Edge, Darren, et al. (2024), "From Local to Global: A Graph RAG Approach to Query-Focused Summarization", *arXiv preprint arXiv:2404.16130*.

[7] Lewis, Patrick, et al. (2020), "Retrieval-augmented generation for knowledge-intensive NLP tasks", *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474.

[8] Vaswani, Ashish, et al. (2017), "Attention is all you need", *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008.

[9] Yao, Shunyu, et al. (2022), "ReAct: Synergizing reasoning and acting in language models", *International Conference on Learning Representations (ICLR)*.